Predicción probabilística del resultado 1X2 en partidos de fútbol mediante Machine Learning

José Luis Alva Espinoza
Departamento de Computación
Universidad de Ingeniería y Tecnología
Lima, Perú
jose.alva.e@utec.edu.pe

Juan Carlos Ticlia Maqui
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
juan.ticlia@utec.edu.pe

Elmer José Manuel Villegaz Suárez
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
elmer.villegas@utec.edu.pe

Joseph Anderson Cose Rojas
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
joseph.cose@utec.edu.pe

Resumen—Este trabajo estima la probabilidad de cada resultado 1X2 de un partido de fútbol usando solo información disponible antes del partido, y evalúa si alguna fuente distinta de las cuotas de apuestas aporta información que el mercado no tenga. Se construyó un dataset propio de 36,150 partidos de nueve ligas europeas (2014/15–2025/26) que combina cuotas de varias casas, estadísticas de partido, ratings FIFA/FC de los jugadores y 33 habilidades individuales del once titular. La evaluación usa validación cruzada temporal con ventana expansiva (8 folds), hiperparámetros elegidos en una ventana disjunta y métricas probabilísticas (log loss, Ranked Probability Score y calibración). Se comparan regresión logística, boosting, Random Forest, XGBoost, SVM, MLP y ensembles, tanto para clasificar el resultado como para regresar la diferencia de goles, además de MI y PCA como técnicas de selección de variables. El mejor modelo es una regresión logística de tres variables derivadas de las cuotas (log loss 0.9656, frente a 0.9665 del mercado crudo y 1.0726 de la frecuencia base); ni la plantilla, ni la forma reciente, ni las habilidades individuales, ni modelos más complejos lo superan. Un modelo sin cuotas acierta el ganador en el 70.0 % de los partidos sin empate frente al 71.8 % del modelo con cuotas, y no contiene información adicional (R^2 del residuo $= -0{,}0007$). El cierre del mercado subsume a la apertura, las desviaciones de calibración (1–4 puntos porcentuales) dependen del método de normalización del margen y el backtest no arroja un retorno significativamente positivo. Se concluye que, en 2014–2026, el mercado es eficiente respecto a la información de fundamentos disponible. El repositorio del proyecto está disponible en https://github.com/jcarlos-t/MLProject.git.

Index Terms—Machine Learning, predicción de fútbol, 1X2, cuotas de apuestas, eficiencia del mercado, validación temporal, calibración, selección de características.

I. Introducción y formulación del problema

I-A. Contexto y motivación

La predicción del resultado de un partido de fútbol es un problema de gran interés académico y comercial. A diferencia de otros deportes con muchas anotaciones, el fútbol marca pocos goles: tiene un componente de azar elevado y depende mucho del contexto (localía, estado de la plantilla, calendario). Esto hace que incluso los modelos más avanzados rara vez superen el 55 % de acierto en la clase ganadora [1], [2]. La literatura ha abordado el problema tanto con modelos estadísticos de conteo, como los modelos de Poisson de Dixon y Coles [3] y Karlis y Ntzoufras [4], como con enfoques de machine learning.

En las apuestas deportivas, las cuotas reflejan información agregada de múltiples fuentes. Un modelo de machine learning (ML) es útil solo si estima probabilidades calibradas (coincidentes con la frecuencia real) y, opcionalmente, detecta discrepancias con el mercado: apuestas donde la cuota paga más de lo que la probabilidad real justifica (value bets). Por eso no basta con maximizar el accuracy: se requieren métricas probabilísticas y un análisis de calibración. Más aún, la pregunta relevante no es solo qué tan bien se predice, sino si existe información que las cuotas no tengan.

I-B. Definición del problema

Dado un partido con local H y visitante A, se busca estimar la distribución de probabilidad

$$P(\mathrm{FTR} = c \mid \mathbf{x}), \quad c \in \{H, D, A\}, \tag{1}$$

donde $\mathbf{x}$ agrupa exclusivamente información disponible antes del partido: forma reciente de ambos equipos, calidad y habilidades de la plantilla, ventaja de localía y cuotas de apertura. La variable objetivo es FTR, con valores H (gana el local), D (empate) y A (gana el visitante).

I-C. Tarea de Machine Learning

El problema se formula de dos maneras complementarias: (a) clasificación multiclase de tres clases con salida probabilística; y (b) regresión de la diferencia de goles $GD = \mathrm{FTHG} - \mathrm{FTAG}$, a partir de la cual se derivan probabilidades 1X2, siguiendo el enfoque de Stübinger

et al. [2]. La métrica principal es el log loss; como complemento se reportan el Ranked Probability Score, el accuracy, el error de calibración esperado (ECE) y diagramas de fiabilidad.

I-D. Métricas de evaluación probabilística

Sea N el número de partidos evaluados, $y_{ic} \in \{0, 1\}$ el indicador de que el resultado del partido i sea la clase c, y $\hat{p}_{ic}$ la probabilidad estimada.

I-D1. Log loss (entropía cruzada multinomial):

$$\mathrm{LL} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{c \in \{H,D,A\}} y_{ic} \log \hat{p}_{ic}. \tag{2}$$

Penaliza fuertemente asignar probabilidad baja a la clase real y es sensible a la calibración: es la métrica primaria.

I-D2. Ranked Probability Score: Como los resultados están ordenados ($H > D > A$), el RPS compara las distribuciones acumuladas:

$$\mathrm{RPS} = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{2} \sum_{k=1}^{2} \Big(\sum_{c \le k} \hat{p}_{ic} - \sum_{c \le k} y_{ic} \Big)^2. \tag{3}$$

Penaliza más un error de dos categorías (predecir victoria local y perder) que uno de una (empatar) [5].

I-D3. Calibración: Un modelo está calibrado si, entre los partidos donde predice $\approx q$ para una clase, la frecuencia observada es $\approx q$. Se evalúa con diagramas de fiabilidad y con el ECE sobre diez tramos, y se resume con la pendiente de una regresión logística del resultado sobre $\mathrm{logit}(\hat{p})$ (pendiente > 1: el modelo es poco confiado; < 1: demasiado confiado).

I-D4. De cuota a probabilidad y value bet: La cuota o_c de una casa implica una probabilidad bruta $1/o_c$; tras eliminar el margen (overround) con la normalización proporcional se obtiene la probabilidad implícita del mercado:

$$p_c = \frac{1/o_c}{\sum_{j \in \{H,D,A\}} 1/o_j}. \tag{4}$$

Un value bet surge cuando $\hat{p}_c \cdot o_c > 1 + \tau$ para un umbral τ. El edge puede aparecer en cualquiera de los tres resultados. La regla se evalúa en un backtest con las cuotas observadas de apertura, que son las que realmente se pueden apostar, y se usa el cierre como referencia de eficiencia del mercado.

I-E. Preguntas de investigación e hipótesis

Las preguntas que guían el proyecto son:

1. ¿El desempeño se mantiene estable a lo largo de las temporadas en el split cronológico, o se degrada por concept drift?
2. ¿La calidad de la plantilla mejora la predicción respecto a usar únicamente estadísticas históricas de partido?
3. ¿Qué técnica de selección de variables (mutual information o PCA) preserva mejor la señal predictiva, como en Tammouch et al. [1]?
4. ¿Un ensemble de modelos calibrados permite detectar value bets rentables?

Las hipótesis de trabajo son: (i) las cuotas dominan sobre las demás variables; (ii) la plantilla aporta señal complementaria, sobre todo al inicio de temporada; (iii) un modelo mal calibrado puede acertar más pero perder dinero en el backtest. Las respuestas se presentan en las Secciones VI y VIII.

I-F. Contribuciones

- Un pipeline reproducible con control explícito de fugas de información (calentamiento del historial, estadísticas observadas sin imputar, mapeo de clubes auditado).
- Una evaluación temporal con hiperparámetros elegidos en una ventana disjunta de los folds de evaluación y comparaciones pareadas con intervalos bootstrap.
- Cuatro pruebas independientes de eficiencia del mercado: modelo de residuo, movimiento apertura→cierre, valor frente a la línea de cierre y backtest.
- La réplica, en un periodo distinto (2014–2026), del enfoque de habilidades individuales de Stübinger et al. [2].

II. Datos y análisis exploratorio de datos (EDA)

II-A. Fuente y descripción del dataset

El dataset es de construcción propia y combina dos fuentes públicas:

- football-data.co.uk [9]: 117 archivos CSV (9 ligas × 13 temporadas) de la Premier League, Bundesliga, La Liga, Serie A, Ligue 1, Eredivisie, Primeira Liga, Süper Lig y Pro League. Las temporadas 2014/15 a 2025/26 (12) son las que se modelan; 2013/14 se usa solo como calentamiento para que los equipos tengan historial de forma desde la primera jornada de 2014/15. Aporta resultados, estadísticas de juego y cuotas de varias casas, de apertura y de cierre.
- Ratings FIFA/EA FC [10]: 12 snapshots anuales (FIFA 15 a EA FC 26) de la plataforma sofifa distribuidos en Kaggle, con un único snapshot por temporada. De ellos se derivan la calidad de plantilla por club y 33 habilidades individuales del once titular (club_position distinta de suplente o reserva).

El snapshot de FC 25 (temporada 2024/25) corresponde a julio de 2025: es de final de temporada y no contiene fichajes de verano (la fecha de incorporación más reciente es el 25 de mayo de 2025). Su posible efecto de look-ahead se evalúa con una prueba de sensibilidad (Sección VI).

La Tabla I resume el dataset consolidado.

Cuadro I
Resumen del dataset consolidado matches_sq.csv.

Aspecto	Valor
Partidos modelables	36,150
Partidos de calentamiento (2013/14)	2,918
Partidos sin ninguna cuota (excluidos)	31
Columnas crudas	225 (222 útiles)
Columnas tras la limpieza de nulos	80
Ligas / temporadas / equipos	9 / 12 / 296
Cobertura squad quality	100 % (72,300 team-slots)
Valores nulos tras limpieza	0

La cobertura de calidad de plantilla es del 100 % porque el mapeo entre los nombres de clubes de EA y los de football-data se auditó: se detectaron y corrigieron 110 colisiones (dos clubes de EA apuntando al mismo equipo, p. ej. Arsenal y Arsenal de Sarandí), que afectaban al 9.9 % de los partidos.

II-B. Variables y variable objetivo

El dataset se organiza en cinco bloques: identificación (Tabla II), resultado (Tabla III), estadísticas de partido (Tabla IV), cuotas (Tabla V) y calidad de plantilla (Tabla VI).

Cuadro II
Variables de identificación del partido.

Variable	Qué significa
Div	Liga (código de football-data; ej. E0 = Premier League).
Season	Temporada (ej. 1415 = 2014/15).
Date	Fecha del partido (dd/mm/aa).
HomeTeam / AwayTeam	Equipo local / visitante.

Cuadro III
Variables de resultado. FTR es el target del modelo.

Variable	Qué significa
FTHG / FTAG	Goles del local / visitante (su diferencia es el target de regresión).
FTR	Resultado final 1X2 (H, D, A).
HTHG / HTAG / HTR	Goles y resultado al medio tiempo (post-partido, no son features).

Cuadro IV
Estadísticas de partido (post-partido; solo alimentan el historial).

Variable	Qué significa
HS / AS, HST / AST	Tiros y tiros a puerta (local / visitante).
HC / AC, HF / AF	Córners y faltas.
HY / AY, HR / AR	Tarjetas amarillas y rojas.

Cuadro V
Cuotas de mercado.

Mercado	Variables	Uso
1X2 (apertura)	B365H/D/A, BWH/D/A, PSH/D/A, WHH/D/A	Consenso de probabilidades implícitas (feature del modelo).
1X2 (cierre)	PSCH/D/A (Pinnacle)	Referencia de eficiencia y backtest; no es feature.
Medias de mercado	AvgH/D/A	Solo desde 2019/20 (41.4 % de nulos estructurales): no se usan.

Regla del proyecto: las cuotas de apertura son features; las de cierre solo sirven como referencia. Si el modelo viera el cierre, copiaría la opinión final del mercado.

Cuadro VI
Calidad de plantilla por lado (se repite con prefijo AwayTeam_).

Feature	Descripción
_sq_top11_mean	Media de los 11 jugadores mejor valorados del plantel
_sq_overall_mean, _sq_overall_max	Media y máximo de la plantilla
_sq_{gk,def,mid,att}_*	Medias y máximos por línea
_sq_mapped	Bandera de mapeo club–equipo
SK_* (33 variables)	Diferencia local − visitante del promedio de los 4 mejores jugadores de campo del once titular (28 habilidades) y del portero titular (5)

La variable objetivo FTR presenta la distribución de la Tabla VII. El desbalance es estructural del fútbol y no se corrige: se busca probabilidad calibrada y la frecuencia base es información útil (prior).

Cuadro VII
Distribución de la variable objetivo FTR.

Clase	Frecuencia	Proporción
H (gana local)	16,044	44.4 %
A (gana visitante)	11,093	30.7 %
D (empate)	9,013	24.9 %
Total	36,150	100 %

II-C. Calidad de los datos

Valores faltantes en cuotas. Las 159 columnas de cuotas se clasificaron por su proporción de nulos (Tabla VIII, Fig. 1). Las que superan el 40 % corresponden a casas o mercados con cobertura parcial; las tres del 20 %–40 % (IWH/D/A) se convirtieron en banderas; las restantes se imputaron con KNNImputer.

Cuadro VIII
Tratamiento de los nulos en las 159 columnas de cuotas.

Rango de nulos	Acción	Columnas
$> 40\,\%$ (14,460 filas)	Eliminadas	138
$20\,\%$–$40\,\%$	Bandera *_Ausente	3
$0 < \cdot \leq 20\,\%$	Imputación KNN ($k = 5$)	18
Total		159

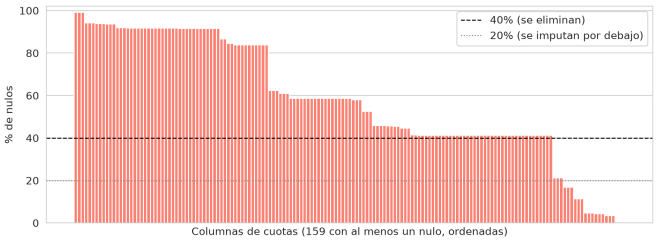


Figura 1. Porcentaje de nulos por columna de cuotas.

Dos hallazgos matizan el tratamiento: (i) las banderas *_Ausente no miden "mercado suspendido", sino la temporada en que la fuente dejó de publicar la cuota (son un proxy de la temporada), por lo que se descartan en el modelado; (ii) AvgH/D/A solo existen desde 2019/20, de modo que el mercado se construye a partir de las cuotas de cuatro casas (Sección III).

Valores faltantes en otras variables (Fig. 2):

- Unnamed: 105, 119, 120: $100\,\%$ nulos; artefactos de concatenación, eliminados.
- HFKC, AFKC: 35,672 nulos ($98.7\,\%$), eliminadas.
- Referee: 31,590 nulos ($87.4\,\%$); solo la Premier League lo publica. Eliminada.
- Time: 14,920 nulos ($41.3\,\%$); solo existe desde 2019/20. Su ausencia es estructural y se descarta en lugar de imputarla.
- HTR: 39 nulos, reconstruida a partir de HTHG y HTAG.
- B365CH: un valor no numérico (#) en 2022/23; la columna se elimina por exceso de nulos.

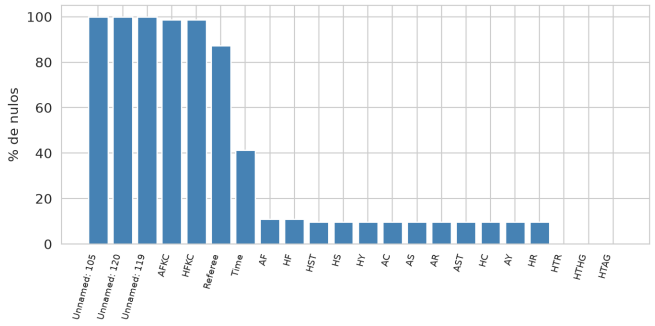


Figura 2. Nulos de las columnas distintas de las cuotas.

Ausencias estructurales en estadísticas de partido. Tiros, córners, faltas y tarjetas tienen 3,513 y 3,993 nulos ($9.7\,\%$ y $11.0\,\%$) y no son aleatorios: la fuente no las publica para Bélgica, Países Bajos, Portugal y Turquía antes de 2017/18 (3,474 partidos sin ninguna estadística), ni las faltas de Bélgica en 2017/18 y 2018/19 (480 partidos). Imputarlas con KNN produce valores casi constantes y fabricados, por lo que en el cálculo de la forma reciente no se imputan: quedan como NaN y se tratan con modelos que los toleran (Sección III).

Duplicados e integridad. No hay duplicados exactos; la clave (Div, Season, Date, HomeTeam, AwayTeam) identifica cada partido.

Outliers. Se aplicó la regla IQR (Figs. 3 y 4). Los extremos de goles (hasta 10 y 13) y tiros (hasta 46) son partidos reales; las cuotas largas (hasta 26 para el local y 41 para el visitante en Bet365) corresponden a partidos muy desequilibrados. No se eliminan ni se acotan: son justamente donde se concentra el valor en un backtest.

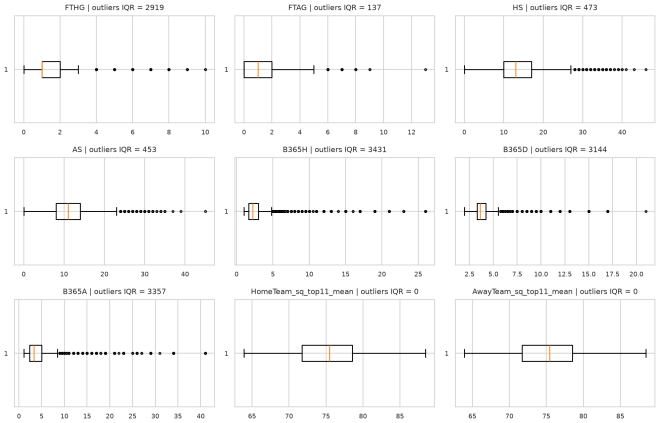


Figura 3. Boxplots de variables representativas (valores observados).

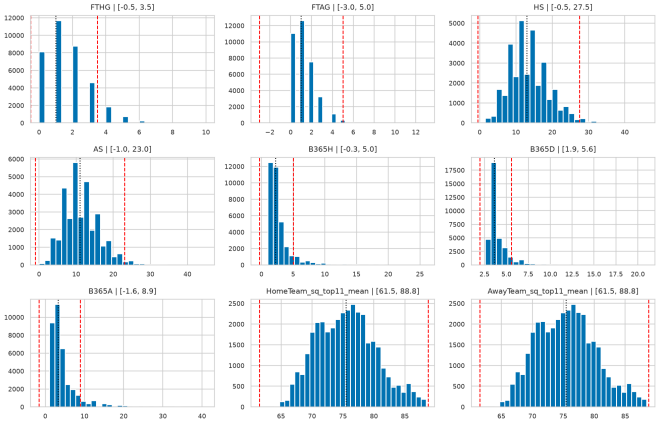


Figura 4. Histogramas con vallas IQR (rojo) y mediana (negro).

II-D. Análisis univariado

Las variables siguen las distribuciones esperadas del fútbol (Tablas IX y X). La localía se refleja en que el local anota 0.32 goles más que el visitante (1.56 frente

a 1.24), diferencia también visible al medio tiempo (0.69 frente a 0.55).

Cuadro IX
Estadísticas descriptivas de las variables de fútbol (valores observados).

Variable	Media	DE	Mín.	Mediana	Máx.
FTHG	1.56	1.31	0	1	10
FTAG	1.24	1.17	0	1	13
HTHG	0.69	0.84	0	0	6
HTAG	0.55	0.75	0	0	7
HS	13.55	5.35	0	13	46
AS	11.12	4.75	0	11	45
HST	4.87	2.61	0	5	20
AST	4.01	2.36	0	4	23
HC	5.44	2.97	0	5	26
AC	4.45	2.63	0	4	19
HF	12.45	4.14	0	12	33
AF	12.71	4.19	0	12	34
HY	1.94	1.39	0	2	10
AY	2.18	1.43	0	2	10
HR	0.10	0.32	0	0	3
AR	0.12	0.34	0	0	3

Cuadro X
Estadísticas descriptivas de cuotas y calidad de plantilla.

Variable	Media	DE	Mín.	Mediana	Máx.
B365H (apertura)	2.76	1.95	1.02	2.20	26.00
B365D (apertura)	4.05	1.29	1.95	3.60	21.00
B365A (apertura)	4.47	3.72	1.05	3.30	41.00
PSCH (cierre)	2.89	2.22	1.02	2.26	48.58
PSCD (cierre)	4.22	1.58	2.30	3.71	29.31
PSCA (cierre)	4.83	4.46	1.02	3.47	54.14
HomeTeam_sq_overall_mean	70.38	3.91	60.38	70.34	82.58
HomeTeam_sq_overall_max	78.96	5.18	67	79	94
HomeTeam_sq_top11_mean	75.50	4.76	63.91	75.45	88.45

Las cuotas tienen una distribución fuertemente asimétrica hacia la derecha (media > mediana) por los partidos de favoritos claros. Las variables categóricas tienen la cardinalidad de la Tabla XI.

Cuadro XI
Cardinalidad, moda y nulos de las variables categóricas (datos crudos).

Variable	Únicos	Moda	Frec. moda	Nulos
Div	9	E0	4,560	0
Date	2,634	22/12/2018	53	0
HomeTeam	296	Arsenal	228	0
AwayTeam	296	Crystal Palace	228	0
FTR	3	*H*	16,044	0
HTR	3	*D*	14,679	39
Referee	53	A Taylor	356	31,590
Time	47	20:00	2,033	14,920

II-E. Análisis bivariado

Relación entre cuotas y resultado. Las cuotas son la señal más informativa y anticipan con precisión el resultado (Fig. 5): la cuota media del local es 2.11 cuando gana el local y 3.77 cuando gana el visitante, y la del visitante es 5.85 y 2.95 respectivamente. El favorito acierta el 54.0 % de los partidos con la cuota de apertura de Bet365 y el 54.1 % con el cierre de Pinnacle. En información mutua con el resultado, la variable de mercado más informativa (MKT_logit, definida en la Sección III) alcanza 0.098, frente a 0.083 de la ventaja de plantilla y menos de 0.03 de cualquier variable de forma.

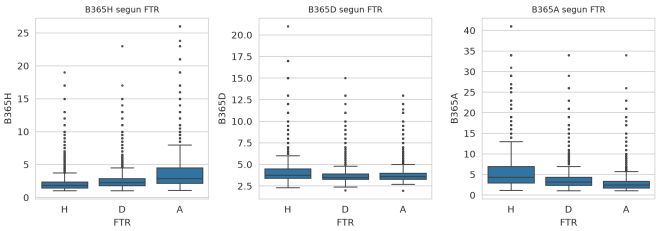


Figura 5. Cuotas de apertura de Bet365 según el resultado real.

Relación entre plantilla y resultado. La diferencia de calidad del once (HomeTeam_sq_top11_mean − AwayTeam_sq_top11_mean) vale en media +1,97 cuando gana el local, −0,33 en empates y −2,58 cuando gana el visitante (Fig. 6), con magnitud menor que la de las cuotas.

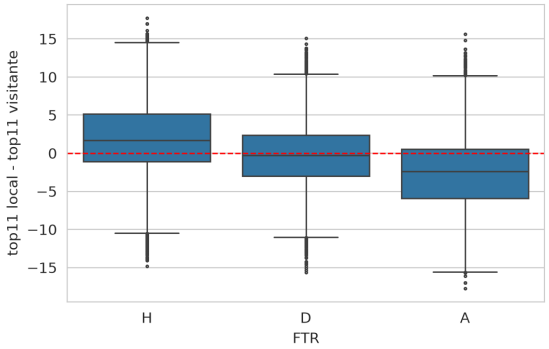


Figura 6. Diferencia de calidad del once según el resultado.

II-F. Matriz de correlación

La Fig. 7 muestra la matriz completa y la Fig. 8 el detalle de las variables clave. Las cuotas de distintas casas para el mismo resultado tienen $|r|$ entre 0.96 y 0.99, lo que confirma la multicolinealidad del mercado y justifica construir un único consenso en lugar de usar varias casas. La cuota del local y la del visitante están correlacionadas negativamente (−0,47), y la apertura de Bet365 con el cierre de Pinnacle del local, en 0.96.

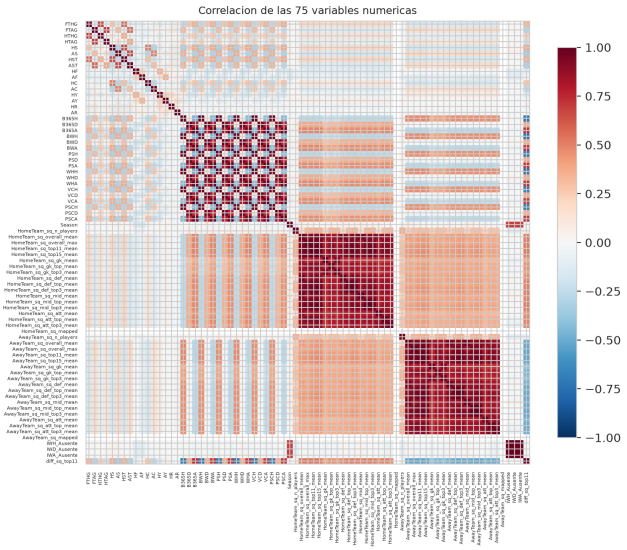


Figura 7. Matriz de correlación de las variables numéricas del dataset limpio.

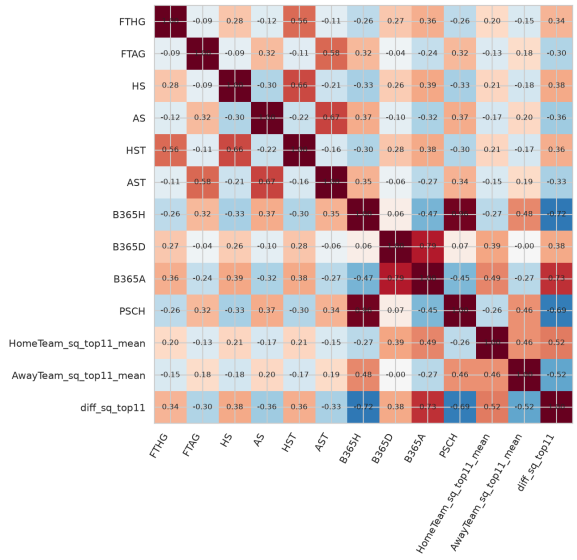


Figura 8. Detalle de la correlación entre variables clave.

II-G. Posibles sesgos y data leakage

Este es el punto más crítico del análisis:

- Fuga por estadísticas post-partido. Goles, tiros, córners, faltas y tarjetas del propio partido se conocen después. Se transforman en medias móviles de los últimos cinco partidos de cada equipo, sin incluir el actual.
- Fuga por look-ahead. Toda agregación usa información estrictamente anterior a la fecha; el split es cronológico; los hiperparámetros y los umbrales se eligen en ventanas disjuntas de las de evaluación. Un recálculo independiente de 600 valores del historial coincide exactamente con el calculado.
- Fuga por imputación. Una versión inicial imputaba la calidad de plantilla junto con estadísticas del propio partido; se corrigió usando la media de la liga y temporada.
- Calidad de plantilla. Los snapshots de FIFA 15 a FC 24 y FC 26 son de lanzamiento; el de FC 25 es de final de temporada (sensibilidad en la Sección VI).
- Sesgo de cobertura. Cinco ligas aportan 4,560 partidos y las tres con menos historia entre 3,285 y 3,672; las estadísticas de partido no existen para cuatro ligas antes de 2017/18.
- Sesgo de cuotas. Las ausencias de cuotas son estructurales (por temporada) y no una señal del partido; por eso no se usan como features.

II-H. Hallazgos principales del EDA

1. La variable objetivo está levemente desbalanceada (44.4 %/30.7 %/24.9 %) y se usa como prior.
2. La calidad de datos es buena tras una limpieza explícita (de 225 a 80 columnas, sin nulos), pero con ausencias estructurales que no se deben imputar (estadísticas de cuatro ligas hasta 2016/17, Time, AvgH/D/A).
3. Las cuotas son la señal pre-partido más fuerte y están altamente correlacionadas entre casas ($|r| \geq 0{,}96$).
4. La plantilla tiene señal propia, pero menor, y está muy correlacionada con las cuotas.
5. Los outliers de goles, tiros y cuotas son legítimos y no se eliminan.
6. El mayor riesgo metodológico es la fuga temporal: estadísticas post-partido, imputación con datos del propio partido y elección de umbrales con los datos de evaluación.

III. Preprocesamiento e ingeniería de características

La construcción de features sigue los principios de Zheng y Casari [6]: verificar la escala y la distribución antes de transformar, filtrar con criterios que no miran el target, usar estadísticas acotadas, no fabricar datos y controlar la fuga de información. Cada paso se documenta y verifica en feature.ipynb.

III-A. Forma reciente con calentamiento

Cada partido se descompone en dos registros (local y visitante) y, para cada equipo, se calcula la media de sus últimos cinco partidos sin incluir el actual: goles a favor y en contra (GF, GA), puntos (Pts), portería a cero (CS), y, donde existan, tiros, tiros a puerta, córners, faltas y tarjetas. El resultado se une al partido como H_*_5 (local) y A_*_5 (visitante). Tres decisiones evitan fabricar datos o mirar el futuro:

- Calentamiento. Los 2,918 partidos de 2013/14 alimentan el historial pero no se modelan; así, el 97.9 %

de los registros de 2014/15 tiene ventana completa y solo el 0.4 % (ascendidos sin historial en el dataset) carece de partidos previos.
- Estadísticas observadas. Donde la fuente no publica tiros, córners, faltas o tarjetas el valor queda como NaN y no se imputa.
- Ventana acolchada (back-off). Si en los últimos cinco partidos solo hay $n < 5$ valores observados, los $5 - n$ restantes toman la media de la liga estrictamente anterior a la fecha, en línea con el back-off hacia el prior de [6]. Una ventana completa no cambia.

Un recálculo independiente de 600 valores (300 partidos $\times$ 2 variables) coincide con el historial calculado con diferencia máxima 0.0.

III-B. Ausencias estructurales: F1 y F2

Las variables de tiros, córners, faltas y tarjetas quedan en NaN para 3,959 partidos (11.0 %): todas las estadísticas de Bélgica, Países Bajos, Portugal y Turquía en 2014/15–2016/17 (3,474), las faltas de Bélgica en 2017/18 y 2018/19 (480) y cinco partidos de primera jornada sin prior. Como la ausencia es estructural, no se imputa (Sección II-C) y se definen dos conjuntos:

- F1 (13 variables, sin NaN): para regresión logística, SVM y MLP.
- F2 (33 variables, 20 con NaN): para árboles y boosting, que toleran valores faltantes.

III-C. Consenso de mercado

Para cada casa $b \in \{\text{B365, BW, PS, WH}\}$ con las tres cuotas observadas se calcula la probabilidad implícita normalizada (Ecuación 4), y se promedia solo entre las casas disponibles (nanmean; mediana de cuatro casas por partido). Nunca se usan cuotas imputadas con KNN: esa versión producía márgenes negativos de hasta −0,17. A partir del consenso (p_H, p_D, p_A) se derivan:

$$\text{MKT_logit} = \ln \frac{p_H}{p_A}, \tag{5}$$

$$\text{MKT_pD} = p_D, \qquad \text{MKT_margin} = \overline{\textstyle\sum_c 1/o_c} - 1. \tag{6}$$

MKT_logit es lineal en log-odds, y MKT_margin (overround, de 0.023 a 0.181, mediana 0.052) recoge el margen de la casa. Los 31 partidos sin cuota en ninguna casa (29 de la Süper Lig 2022/23 y 2 de la Serie A) se excluyen del modelado tras haber aportado a la forma de sus equipos, lo que deja 36,119 partidos. Las cuotas de cierre de Pinnacle no son features: se exportan aparte para el backtest y las pruebas de eficiencia.

III-D. Calidad de plantilla

De las 17 medidas de plantilla por lado, las medias por línea (porteros, defensas, medios, delanteros) correlacionan entre 0.88 y 0.96 con la media del mejor once, por lo que se conserva top11_mean. Como lo relevante para el resultado es la ventaja neta, se crea

$$\text{DIF_sq_top11} = \text{top11}_H - \text{top11}_A, \tag{7}$$

y se conserva solo el nivel del local HomeTeam_sq_top11_mean. Se descartaron 24 medidas granulares y las banderas *_sq_mapped (constantes con cobertura 100 %).

Corrección del mapeo de clubes. La auditoría detectó 110 colisiones donde dos clubes de EA se asignaban al mismo equipo (p. ej. Inter e Inter Miami), afectando a 3,588 partidos (9.9 %). Se resolvieron con una prioridad (alias manual > coincidencia exacta > subconjunto de tokens > difusa; luego misma liga; luego nombre más corto). Tras la corrección, la MI de DIF_sq_top11 con el resultado pasó de 0.067 a 0.083.

III-E. Habilidades individuales del once titular

Siguiendo a Stübinger et al. [2], cada equipo se describe por las habilidades individuales de su once, no por el overall agregado:

1. Se toman los titulares de cada club y temporada con club_position distinta de suplente o reserva.
2. Se armonizan 33 habilidades presentes en los 12 snapshots (28 de campo y 5 de portero). Se descarta composure, inexistente en FIFA 15 y 16.
3. Para cada habilidad de campo se promedian los cuatro mejores jugadores no porteros; para las de portero se usa el portero titular. Los 4 clubes sin portero marcado reciben la media de su liga y temporada.
4. Se calcula la diferencia local − visitante (SK_*, 33 variables).

Se cubren 29,777 titulares en 2,708 pares (temporada, equipo) y el 100 % de los partidos. Seis pares elegidos al azar coinciden exactamente con un recálculo manual. Las habilidades son muy redundantes con el overall: la correlación con DIF_sq_top11 va de 0.38 (strength) a 0.94 (reactions), con $|r|$ medio 0.73, y ninguna supera a la referencia en información mutua (0.085 con FTR y 0.108 con GD, frente a 0.072 y 0.093 de la mejor habilidad). Para la regresión se añade el target $GD = \text{FTHG} - \text{FTAG}$ (media +0,32, desvío 1.84, rango −13 a +10).

III-F. Eliminación de redundancia y selección

- Variables post-partido. Se eliminaron 17 columnas del propio partido (goles, tiros, córners, faltas, tarjetas) para evitar fuga trivial.
- Banderas *_Ausente. Se descartan porque delatan la temporada, no el partido.
- Poda por correlación ($|r| > 0{,}95$, calculada con el primer 80 % por fecha y sin usar el target). Eliminó 14 variables: MKT_pH y MKT_pA (redundantes con MKT_logit), las tasas de victoria (redundantes con los puntos) y ocho medidas de plantilla.

- Ranking por información mutua (primer 80 % por fecha, 24,939 filas completas). MKT_logit lidera con 0.098, seguida de DIF_sq_top11 con 0.083; todas las de forma están por debajo de 0.027 y cinco son ≈ 0. Con valores tan bajos las diferencias de milésimas están dentro del ruido, por lo que el ranking no se usa para truncar: la decisión de qué bloques conservar se toma con validación temporal (Sección VI).

III-G. Conjuntos finales

El dataset congelado tiene 36,119 filas y 33 variables (F2), con la distribución $H = 44{,}4\,\%$, $D = 25{,}0\,\%$, $A = 30{,}7\,\%$. La Tabla XII resume los bloques y la composición de F1 y F2.

Cuadro XII
Bloques de features finales y su pertenencia a F1 y F2.

Bloque	Variables	F1	F2
Mercado	MKT_logit, MKT_pD, MKT_margin	3	3
Plantilla	HomeTeam_sq_top11_mean, DIF_sq_top11	2	2
Forma (goles, pts., portería a cero)	H/A_GF_5, GA_5, Pts_5, CS_5	8	8
Forma (tiros, córners, faltas, tarjetas)	H/A_SGF_5, SOTF_5, CF_5, …	0	20
Total		13	33

Las 33 habilidades SK_* forman un conjunto aparte (SK_habilidades) que se evalúa como bloque adicional.

IV. Metodología y modelos

IV-A. Referencias sin aprendizaje

Todo modelo se compara con dos referencias evaluadas sobre los mismos partidos: el prior (frecuencias $H/D/A$ del conjunto de entrenamiento) y el mercado crudo (probabilidades implícitas del consenso, Ecuación 4). Un modelo aporta valor solo si mejora al prior (hay señal) y, sobre todo, al mercado (hay información que las casas no usan).

IV-B. Modelos de clasificación

Se estiman directamente las probabilidades $\hat{p}_H, \hat{p}_D, \hat{p}_A$ con:

- Regresión logística multinomial (LR), con estandarización dentro del pipeline y regularización ℓ_2 de fuerza C. Es el modelo base, y el que recibe F1.
- Gradient boosting con histogramas (HGB), que tolera NaN y por eso recibe F2 [7].
- Random Forest (RF) con bagging y submuestreo de variables.
- XGBoost, SVM con núcleo RBF (con probabilidades) y MLP, que cierran la lista del enfoque original del proyecto. El MLP se promedia sobre tres semillas.
- Ensemble por promedio de probabilidades de los modelos anteriores.

IV-C. Regresión de la diferencia de goles

Siguiendo a Stübinger et al. [2], se predice GD y de ella se derivan probabilidades 1X2, porque la diferencia de goles contiene más información por partido que el signo (un 4–0 y un 1–0 son ambos H). Los modelos son regresión lineal (LIN), Random Forest (RF), boosting (HGB) y su promedio ALL (el ensemble del trabajo original). La salida $\hat{y}$ se convierte en probabilidades con una regresión logística multinomial entrenada en la temporada inmediatamente anterior a la evaluada, con un modelo que solo vio temporadas previas a esa; así no se usan predicciones in-sample sobreconfiadas.

IV-D. Bloques de variables

Se mide el aporte de cada fuente de información por separado y combinada:

- M: mercado (MKT_logit, MKT_pD, MKT_margin).
- S: plantilla (DIF_sq_top11, HomeTeam_sq_top11_mean).
- G: forma de goles, puntos y portería a cero (8 variables).
- E: estadísticas de partido (tiros, córners, faltas, tarjetas; 20 variables con NaN).
- SK: 33 habilidades individuales del once titular.

F1 equivale a M+S+G; F2, a M+S+G+E. El bloque sin cuotas es S+G+SK (43 variables).

IV-E. Combinación con el mercado

Para responder si un modelo sin cuotas aporta algo sobre el mercado, se emplean tres construcciones:

- Apilado: regresión logística sobre $[\text{MKT_logit}, \hat{y}_{NM}]$ frente al mercado solo, con el mismo calibrador.
- Modelo de residuo: predecir $GD - \hat{y}_M$ con variables sin cuotas; un R^2 fuera de muestra ≈ 0 implica que no hay información adicional.
- Promedio simple de $\hat{y}_M$ y $\hat{y}_{NM}$.

IV-F. Selección de características: MI frente a PCA

Como en Tammouch et al. [1], se comparan dos formas de reducir dimensión sobre dos conjuntos (F1 con 13 variables y el bloque ampliado con habilidades), con tres modelos y nueve métodos (sin reducción, MI con distintos k y PCA con distintas varianzas explicadas). La MI es un filtro supervisado que conserva variables interpretables; PCA es no supervisado y combina variables, con la desventaja de mezclar señal del mercado con ruido de forma [6]. Ambos se ajustan solo con el conjunto de entrenamiento de cada fold.

IV-G. Selección de hiperparámetros

Los hiperparámetros no se eligen en los folds de evaluación. El procedimiento es:

1. Rejilla corta por modelo, en escala logarítmica o de complejidad creciente.

2. Validación temporal en la ventana de ajuste (2016/17 y 2017/18): para cada una se entrena con todo lo anterior y se mide el error en ella.
3. Criterio: menor log loss (clasificación) o menor RMSE (regresión), promediado en las dos temporadas.
4. Desempate: ante diferencias menores a 0,0005 de log loss o 0,002 de RMSE, la configuración más simple (menos profundidad e iteraciones, más regularización), siguiendo la regla de una desviación estándar de [7].
5. Los valores se congelan antes de ejecutar los folds de evaluación.

La Tabla XIII resume los valores elegidos. La ventana de ajuste es pequeña (unos 6,000 partidos de validación), por lo que la selección es ruidosa; LR y RF son insensibles (rango de 0.0005 de log loss y de 0.003 de RMSE entre la mejor y la peor configuración), mientras que HGB prefiere sistemáticamente árboles de profundidad 2 y pocas iteraciones, coherente con una relación casi lineal.

Cuadro XIII
Hiperparámetros elegidos en la ventana de ajuste 2016/17–2017/18.

Modelo	Valores elegidos
LR (clasificación)	$C = 0{,}05$
HGB (clasificación)	learning_rate=0.03, max_depth=2, min_samples_leaf=50, max_iter=100
RF (regresión de GD)	min_samples_leaf=20, max_features=0.5
HGB (regresión de GD)	learning_rate=0.1, max_depth=2, min_samples_leaf=50, max_iter=100
SVM (RBF)	$C = 0{,}1$, $\gamma = 0{,}01$
XGBoost	learning_rate=0.03, max_depth=2, n_estimators=100, min_child_weight=5
MLP	capas $(32, 16)$, $\alpha = 1{,}0$

El SVM se entrena con un máximo de 9,000 filas por fold por su coste cuadrático.

V. Diseño experimental y evaluación

V-A. Validación temporal con ventana expansiva

Un partido de hoy no puede explicarse con partidos del futuro, así que la validación cruzada aleatoria queda descartada. Para cada una de las ocho temporadas de evaluación (2018/19–2025/26) se entrena con todas las temporadas anteriores y se predice la temporada siguiente. El primer fold entrena con cuatro temporadas y el último con once; cada uno valida con unos 3,000 partidos (24,183 predicciones fuera de muestra en total). La ventana de ajuste de hiperparámetros (2016/17–2017/18) no se solapa con ningún fold de evaluación. Como las cuotas de cada partido se usan solo para ese partido, no hay fuga entre filas.

V-B. Métricas

La métrica primaria es el log loss (Ecuación 2) y la secundaria el RPS (Ecuación 3). Se reportan también el accuracy 1X2, el acierto del ganador en partidos sin empate (74.9 % de los partidos, n = 18,124), RMSE y MAE de GD, ECE y pendiente de calibración. Todas las métricas se promedian entre folds y se reporta además la dispersión entre ellos.

V-C. Inferencia estadística

- Comparaciones pareadas: diferencia de log loss por partido y bootstrap con remuestreo, sobre los mismos partidos, y número de folds en que un modelo mejora al otro.
- Desacuerdo: prueba exacta de McNemar sobre los pares discordantes.
- Subconjuntos: $z = (O-E)/\sqrt{\sum p(1-p)}$ y corrección de Benjamini–Hochberg al 5 % [8], porque se prueban decenas de subconjuntos (53 pruebas).
- Calibración: intervalos de Wilson por tramo, intervalos bootstrap para el ECE y la pendiente, con normalización proporcional y por potencia del margen.

V-D. Pruebas de eficiencia del mercado

Cuatro análisis independientes miden si existe información fuera del precio:

1. Modelo de residuo sobre $GD - \hat{y}_M$.
2. Movimiento apertura→cierre: con las cuotas de Pinnacle (apertura PSH/D/A, cierre PSC*), correlación entre la discrepancia del modelo respecto a la apertura y el movimiento posterior, y prueba de encompassing (regresión del resultado sobre logit de apertura y de cierre).
3. Valor de la línea de cierre (CLV): promedio de $p_{cierre} - p_{apertura}$ en el lado donde el modelo supera a la apertura por más de τ.
4. Backtest de apuestas.

V-E. Diseño del backtest

Se apuesta una unidad al resultado con mayor valor esperado EV $= \hat{p} \cdot o - 1$ si EV $> \tau$ (a lo sumo una apuesta por partido), con las cuotas de apertura observadas de Bet365 y Pinnacle. El umbral τ se elige con los cuatro primeros folds (2018/19–2021/22) como el de mayor ROI con al menos 200 apuestas y se reporta en los cuatro últimos (2022/23–2025/26). Las referencias son: siempre local, siempre favorito, apuesta aleatoria (200 simulaciones) y la regla de Stübinger et al. (local si $\hat{y} > 2$, visitante si $\hat{y} < -2$). Los intervalos son bootstrap sobre las apuestas (500 remuestreos). Con 40 configuraciones (4 modelos × 2 casas × 5 umbrales) es esperable que alguna resulte positiva por azar, por lo que los resultados se leen con el intervalo, no con el valor puntual.

V-F. Sensibilidad al snapshot de 2024/25

Como el snapshot de FC 25 es de fin de temporada, el aporte de las habilidades se compara en tres variantes: (1) con 2024/25 y ocho folds; (2) siete folds, con 2024/25 en entrenamiento; (3) sin 2024/25 en entrenamiento ni validación.

V-G. Reproducibilidad

Todo el flujo está en cuatro cuadernos ejecutables en orden (eda, feature, mercado, modelo), con semillas fijas y versiones de librerías en requirements.txt; las salidas intermedias (dataset_final.csv, predicciones_oof.csv, hiperparametros.json) se guardan para auditar cada paso.

VI. Resultados y análisis

Todos los valores son medias de los ocho folds temporales (2018/19–2025/26) sobre los mismos partidos; entre corchetes, intervalos bootstrap pareados al 95 %.

VI-A. Referencias y aporte de cada bloque

El prior obtiene un log loss de 1.0726 y el mercado crudo 0.9665: el mercado mejora al prior en 0.106. La Tabla XIV muestra el aporte de cada bloque con hiperparámetros fijos.

Cuadro XIV
Log loss por bloque de variables (media de 8 folds). Mercado crudo: 0.9665.

Modelo	Bloque	Log loss	Accuracy
LR	M	0.9655	0.538
LR	M+S	0.9657	0.538
LR	M+S+G (F1)	0.9662	0.539
HGB	M	0.9677	0.537
HGB	M+S	0.9680	0.536
HGB	M+S+G (F1)	0.9681	0.536
HGB	M+S+G+E (F2)	0.9691	0.538

Ningún bloque adicional mejora al mercado: la plantilla cambia −0,0002 (LR) y −0,0004 (HGB), la forma −0,0005 y las estadísticas de partido −0,0010, con mejora en 1 a 4 de 8 folds. La LR sobre solo el mercado mejora al mercado crudo en 0.0009 (6/8 folds), lo que es una recalibración y no información nueva.

VI-B. Comparación de modelos

La Tabla XV compara los modelos finales. El mejor es la regresión logística sobre tres variables del mercado, con el menor log loss, RPS y ECE.

Cuadro XV
Comparación de modelos (media y desvío entre folds).

Modelo	Log loss	DE	RPS	Acc.	ECE
Prior	1.0726	0.0084	0.2306	0.437	—
Mercado crudo	0.9665	0.0117	0.1948	0.538	0.0134
LR (cuotas)	0.9656	0.0127	0.1946	0.538	0.0071
HGB (F1)	0.9676	0.0129	0.1950	0.538	0.0081
MLP (F1)	0.9675	0.0130	0.1951	0.535	0.0093
ALL (promedio)	0.9684	0.0121	0.1952	0.537	0.0147
XGBoost (F2)	0.9694	0.0116	0.1955	0.537	0.0171
SVM (F1)	0.9927	0.0110	0.2008	0.532	0.0215

La diferencia por partido respecto a la LR es positiva (peor) en todos los casos: HGB +0,0021 [+0,0013, +0,0028], MLP +0,0019 [+0,0012, +0,0027], ALL +0,0028 [+0,0020, +0,0037], XGBoost +0,0039 [+0,0029, +0,0049] y SVM +0,0271 [+0,0245, +0,0296]; ninguno supera a la LR en más de 1 de 8 folds. A mayor flexibilidad, peor resultado: la relación entre las cuotas y el resultado es casi lineal y el resto de variables funciona como ruido. La LR sobre cuotas reduce a la mitad el ECE del mercado (0.0134 a 0.0071), mientras que XGBoost y SVM quedan peor calibrados que el mercado y arrastran al ensemble.

VI-C. Habilidades individuales y regresión de la diferencia de goles

Clasificación. Añadir las 33 habilidades al mercado empeora el log loss: −0,0014 con LR (mejora en 1/8 folds) y −0,0007 con HGB (2/8). El resultado es el mismo con 2024/25 en 8 folds (−0,0014), con 2024/25 solo en entrenamiento (−0,0015) y sin ella (−0,0015): el posible look-ahead del snapshot de FC 25 no explica la ausencia de mejora.

Regresión. La Tabla XVI resume la predicción de GD.

Cuadro XVI
Regresión de GD (media de 8 folds).

Modelo	Bloque	RMSE	MAE	LL con $\hat{y}$
(media)	—	1.8400	1.4294	—
LIN	mercado	1.6106	1.2464	0.9679
LIN	SK	1.6640	1.2893	0.9922
ALL	SK	1.6623	1.2864	0.9916
LIN	S+G+SK	1.6510	1.2797	0.9872
ALL	S+G+SK	1.6509	1.2782	0.9867
ALL	M+SK	1.6117	1.2480	0.9687

Las habilidades por sí solas tienen información sobre los goles (RMSE de 1.840 a 1.662, −9,7 %, y log loss 0.992 frente a 1.0726 del prior), pero el mercado predice mejor (1.611) y añadirlas no ayuda (1.612). LIN, RF y HGB rinden casi igual: la relación es prácticamente lineal. En el apilado con MKT_logit, ninguna predicción de goles mejora al mercado (delta entre −0,0009 y 0,0000, en 1 a 3 de 8 folds); la correlación entre $\hat{y}$ (sin cuotas) y MKT_logit es 0.91.

VI-D. ¿Quién gana: con cuotas o sin cuotas?

Cuadro XVII
Acierto del ganador en partidos sin empate (n = 18,124).

Regla	Acierto
Siempre local	0.583
Con cuotas ($\hat{y}_M > 0$)	0.718
Sin cuotas ($\hat{y}_{NM} > 0$)	0.700
Promedio	0.711

El modelo sin cuotas alcanza el 97 % del acierto del mercado. Los dos eligen distinto ganador en el 12.2 % de los partidos sin empate (2,207): cuando discrepan, acierta el modelo con cuotas en el 57.5 % (1,270 casos contra 937; McNemar exacto $p < 0{,}0001$), patrón que se repite en los 8 folds y las 9 ligas. Combinarlos no ayuda: el promedio

(0.9726) y el apilado (0.9683) no mejoran al mercado (0.9665), y la correlación entre $\hat{y}_M$ y $\hat{y}_{NM}$ es 0.914. El modelo de residuo obtiene un R^2 fuera de muestra de −0,0007, positivo solo en 2 de 8 folds: lo que las cuotas no explican no es predecible con estas variables.

VI-E. Calibración del mercado

Con normalización proporcional, los favoritos ganan más y los longshots menos de lo que implica el mercado (Tabla XVIII): en el local, +1,9 a +3,6 pp en probabilidades de 0.5 a 0.8 o más y −1,4 pp en $p \leq 0{,}2$. Las pendientes de calibración son 1,11 [1.08, 1.14] (H), 1,25 [1.16, 1.35] (D) y 1,13 [1.10, 1.17] (A), y ninguna incluye 1.

Cuadro XVIII
Pendiente de calibración según el método de normalización del margen (Bet365).

Resultado	Proporcional	Potencia
H	1.10 [1.07, 1.14]	1.02 [0.99, 1.05]
D	1.22 [1.13, 1.33]	1.07 [1.00, 1.16]
A	1.12 [1.09, 1.15]	1.04 [1.01, 1.08]

Con la normalización por potencia, que reparte más margen a los longshots, las pendientes caen a 1.02–1.07 y los intervalos casi incluyen 1: una parte importante del sesgo favorito–longshot es consecuencia del método de eliminación del margen y no necesariamente un error del mercado.

De las 53 pruebas por temporada, liga y tramo, 15 resultan significativas sin corregir y 9 tras Benjamini–Hochberg. Solo 2016/17 sobrevive entre las temporadas (+2,9 pp, $p_{BH} = 0{,}006$); en 2020/21, con estadios vacíos, el local gana 40.4 % frente a 42.2 % implícito (−1,8 pp, $p = 0{,}024$ sin corregir y $p_{BH} = 0{,}12$): no es significativo. Ninguna de las 27 pruebas liga × resultado es significativa tras la corrección. En el ROI de apostar al local por tramo ninguno es significativamente positivo; el mejor, −0,7 % en 0.65–0.8 (IC [−2,3 %, +1,1 %]).

VI-F. Información entre la apertura y el cierre

Con Pinnacle, en 22,586 partidos (93.4 %) con apertura y cierre, el log loss baja de 0.9640 a 0.9603: el cierre incorpora información nueva (movimiento medio absoluto de 0.116 en logit, ≈2.4 pp). En la prueba de encompassing el coeficiente de la apertura es ≈ 0 en los tres resultados (H −0,06 [−0,27, +0,15]; D +0,23; A +0,07) y el del cierre ≈ 1 (H 1.15, D 1.01, A 1.05): el cierre subsume a la apertura.

El modelo sin cuotas no anticipa el movimiento: la correlación entre su discrepancia con la apertura y el movimiento posterior es $r = -0{,}0024$ [−0,016, +0,011], y el mercado se mueve en la dirección del modelo en el 49.5 % de los partidos ($p = 0{,}10$), sin desviarse del 50 % en ningún quintil de discrepancia. El CLV es ligeramente negativo y no mejora con el umbral (Tabla XIX); el del lado contrario del modelo es −0,10 pp, igual que el del modelo.

Cuadro XIX
Valor de la línea de cierre del modelo sin cuotas frente a la apertura de Pinnacle.

τ	Apuestas	Ventaja	CLV (pp)	IC 95 %
0.00	21,072	6.1 pp	−0,12	[−0,16, −0,08]
0.04	12,574	8.9 pp	−0,10	[−0,16, −0,05]
0.08	5,925	12.3 pp	−0,15	[−0,22, −0,06]

VI-G. Backtest de apuestas

En el periodo de prueba (2022/23–2025/26) el margen medio es 5.96 % en Bet365 y 3.36 % en Pinnacle (Tabla XX).

Cuadro XX
ROI en el periodo de prueba con $\tau = 0$ (cuotas de apertura).

Casa	Modelo	Apuestas	ROI	EV prom.
B365	Sin cuotas	10,448	−9,5 %	+19,8 %
B365	HGB (F1)	4,896	−6,0 %	+5,2 %
B365	Apilado	7,443	−3,5 %	+5,6 %
B365	LR (cuotas)	2,071	+5,1 %	+2,1 %
Pinnacle	LR (cuotas)	4,247	−4,5 %	+2,2 %

El modelo sin cuotas pierde en toda la rejilla (−8,5 % a −14,8 %) y empeora al subir τ: promete un valor esperado de +20 % a +36 % y obtiene −10 %, el patrón de sobreconfianza de la "maldición del ganador". Es negativo en los 8 folds (−2,7 % a −15,7 %). El único ROI puntual positivo (LR con Bet365, +5,1 %, IC [−1,8 %, +11,8 %]) no es significativo, y el umbral elegido en validación ($\tau = 0{,}05$, +17,2 % en 342 apuestas) rinde −17,6 % en prueba: selección con ruido. Siempre apostar al favorito es −2,1 % en Bet365 y −0,0 % en Pinnacle. La regla de Stübinger et al. genera solo 824 apuestas (3.4 %) con ROI −0,8 % [−3,4 %, +1,8 %] en Bet365 y +0,3 % [−2,8 %, +3,7 %] en Pinnacle: su +1,58 % cae dentro de ambos intervalos y no se puede confirmar ni descartar.

La única ventaja positiva proviene del precio, no del modelo. Apostando en Bet365 sin ningún modelo cuando su cuota supera la probabilidad justa de Pinnacle, el ROI es +6,3 % con la apertura (IC [−1,4 %, +14,4 %], no significativo) y +6,9 % con el cierre (IC [+4,0 %, +10,5 %]), pero esto último no es implementable porque usa el cierre para decidir una apuesta colocada en la apertura.

VI-H. Selección de características: MI frente a PCA

Cuadro XXI
Log loss con todas las variables, MI (mejor k) y PCA (mejor k); k elegida en la ventana de ajuste.

Conjunto	Modelo	Todas	MI	PCA	Δ MI−PCA
Con cuotas (46)	LR	0.9676	0.9678	0.9815	−0,0138
	HGB	0.9679	0.9682	0.9823	−0,0141
	MLP	0.9697	0.9688	0.9832	−0,0144
Sin cuotas (43)	LR	0.9877	0.9909	0.9871	+0,0038
	HGB	0.9876	0.9908	0.9885	+0,0024
	MLP	0.9873	0.9906	0.9876	+0,0031

Con cuotas, MI supera a PCA en 8 de 8 folds (Tabla XXI): conserva MKT_logit, mientras que PCA la mezcla con 45 variables ruidosas y necesita al menos 20 componentes. Sin cuotas, el resultado se invierte: PCA $\geq$ MI por 0.002 a 0.004, con MI mejor solo en 1 a 3 de 8 folds. En ambos casos ninguna técnica supera a usar todas las variables: con 36,000 partidos y 43–46 variables no hay maldición de la dimensionalidad. El PCA al 95 % y 99 % de varianza necesita 25–27 y 37–39 componentes.

VI-I. Preguntas de investigación e hipótesis

P1: estabilidad temporal. El log loss del mercado oscila entre 0.9486 (2023/24) y 0.9855 (2020/21) sin tendencia (pendiente −0,001 por temporada, $p = 0{,}62$). La diferencia LR − mercado es ≤ 0 en 7 de 8 temporadas y su magnitud crece (de −0,0006 a −0,0020; Spearman −0,81, $p = 0{,}015$, con solo 8 puntos). Entrenar con las últimas tres temporadas en vez de todo el pasado no mejora (+0.0003; mejor en 3/8). No hay concept drift detectable.

P2: plantilla frente a forma. Sin cuotas, la plantilla sola obtiene 0.9908 frente a 1.0275 de la forma sola, y añadirla a la forma reduce el log loss en 0,041 [−0,045, −0,037] (LR). Con cuotas, el efecto es nulo: M → M+S, +0,0002 [−0,0001, +0,0005].

P3: MI frente a PCA. Véase la sección anterior: MI gana solo cuando hay una variable dominante.

P4: value bets con un ensemble. No: el ensemble ALL empeora a la LR (+0,0028) y el ROI sin cuotas es −8,5 % a −14,8 %.

(i) Las cuotas dominan: confirmada. (ii) Plantilla complementaria, sobre todo al inicio: parcial. Sin cuotas, la plantilla aporta un 40 % más en las semanas 1–6 (−0,056 frente a −0,037/−0,040), cuando la forma aún no existe; con cuotas, el efecto es ≈ 0 en todos los grupos, incluido el inicio. (iii) Mal calibrado que acierta más y pierde dinero: no en esa forma. El modelo sin cuotas acierta 1.5 pp menos y su ECE medio (0.0096) es mejor que el del mercado (0.0134); lo que pierde dinero es su error condicional donde discrepa del mercado, y 1.5 pp de accuracy equivalen a 14.6 pp de ROI (de −9,5 % a +5,1 %).

VII. Discusión y limitaciones

VII-A. Interpretación

El resultado central es negativo y consistente por varias vías independientes: ninguna fuente de información distinta de las cuotas mejora al mercado. Las cuotas concentran la señal (MI de 0.098 frente a 0.083 de la plantilla y menos de 0.03 de cualquier variable de forma), un modelo lineal de tres variables las explota por completo, y todo lo que se añade (plantilla, forma, estadísticas de partido, 33 habilidades individuales, regresión de la diferencia de goles, modelos más complejos) aporta cero o resta. El modelo sin cuotas reproduce la ordenación del mercado (correlación 0.91) con una pérdida pequeña, lo que es coherente con que el mercado agrega los mismos fundamentos y algo más: la información que aparece entre apertura y cierre. Esa información adicional no es predecible con los fundamentos disponibles (residuo $R^2 = -0{,}0007$) ni el mercado se mueve hacia el modelo (49.5 %).

La plantilla es informativa por sí sola, y muy: sin cuotas reduce el log loss en 0.041 respecto a la forma de cinco partidos. Pero su información ya está en el precio, desde la primera jornada. Las 33 habilidades correlacionan 0.73 en promedio con el overall del que provienen, de modo que ampliar el vector sin ampliar la información solo añade varianza. Esto es coherente con los modelos de mercado eficiente, y la diferencia con Stübinger et al. [2], que reportan un retorno de 1.58 % con la regla $|\hat{y}| > 2$, no es una contradicción: nuestro intervalo para esa regla (−3,4 % a +1,8 % en Bet365) contiene su cifra y, con solo 824 apuestas, no permite confirmarla ni descartarla.

VII-B. Coherencia con la literatura

- Tammouch et al. [1]. Se replica que MI supera a PCA cuando hay una variable dominante (las cuotas), por la misma razón que ellos dan. No se replica sin esa variable, donde PCA $\geq$ MI. Con 36,000 partidos y 43–46 variables, la mejor opción es no reducir.
- Stübinger et al. Se replica que las habilidades predicen la diferencia de goles (RMSE −9,7 % frente a la media) y que LIN, RF y HGB rinden casi igual. No se replica una ganancia sobre el mercado.
- Sesgo favorito–longshot. Aparece con normalización proporcional, pero casi desaparece con la normalización por potencia; no debe afirmarse sin ese matiz.

VII-C. Limitaciones

- Calidad temporal de las habilidades. Cada temporada tiene un único snapshot de EA. El de FC 25 es de fin de temporada (julio de 2025, sin fichajes de verano) y el resto de lanzamiento, con ratings que no cambian dentro de la temporada. La sensibilidad con y sin 2024/25 no cambia la conclusión, pero no elimina la limitación.
- Plantilla aproximada. Se usa el once por defecto del juego, no el realmente alineado, y las habilidades no se normalizan por liga. El top11 es el promedio de los 11 mejores del plantel.
- Ventana de ajuste pequeña. Los hiperparámetros se eligen con dos temporadas (unos 6,000 partidos de

validación), por lo que la selección es ruidosa. LR y RF son insensibles, pero SVM y XGBoost lo son bastante, y una selección distinta podría reducir la brecha de esos modelos con la LR.

- SVM con submuestra. Se entrena con las 9,000 filas más recientes por coste cuadrático; su desempeño (+0.027) puede reflejar en parte esa restricción.
- Cuotas. Las ausencias son estructurales; AvgH/D/A solo existen desde 2019/20 y el mercado se construye con cuatro casas. Pinnacle dejó de publicar cierre para parte de 2025/26 (cobertura 47.7 % en ese fold).
- Backtest. Supone apuestas de una unidad sin límites de cuenta ni deslizamiento. El mejor ROI positivo depende de poder apostar a la apertura en la casa que paga más; las casas limitan a quien explota esa ventaja.
- Pruebas múltiples. Se hicieron 53 pruebas de subconjuntos y 40 configuraciones de backtest; las conclusiones se apoyan en intervalos y en la corrección de Benjamini–Hochberg, no en valores puntuales.
- Cobertura. Nueve ligas europeas de 2014 a 2026; no se generaliza a otras ligas, a mercados distintos del 1X2 ni a apuestas en directo.
- Tendencia de la ventaja. El crecimiento de la ventaja de la LR sobre el mercado (Spearman −0,81) se basa en ocho puntos y no se interpreta como efecto establecido.

VII-D. Validez

El diseño controla las fugas más habituales: el historial usa solo partidos anteriores y se verificó por recálculo independiente; el split es cronológico; los hiperparámetros y el umbral del backtest se eligen en ventanas disjuntas; MI y PCA se ajustan con el entrenamiento de cada fold; las estadísticas de partido no se imputan. Las cuotas de apertura son features, no así las de cierre. Una limitación de validez que persiste es que el cierre de Pinnacle es referencia de eficiencia, no un oráculo de la probabilidad real.

VIII. Conclusiones

1. El mercado es eficiente respecto a los fundamentos disponibles. El mejor modelo es una regresión logística de tres variables derivadas de las cuotas (log loss 0.9656, frente a 0.9665 del mercado y 1.0726 del prior); ni la plantilla, ni la forma, ni las 33 habilidades, ni modelos más complejos lo superan.
2. Sin cuotas se predice casi tan bien, pero no mejor. El modelo sin cuotas acierta el ganador en el 70.0 % de los partidos sin empate frente al 71.8 % con cuotas, y no contiene información adicional (residuo $R^2 = -0{,}0007$). Combinarlos no mejora.
3. Los fundamentos sí tienen señal, pero ya está en el precio. La plantilla reduce el log loss en 0.041 sin cuotas y no aporta nada con cuotas, incluso al inicio de la temporada.
4. El cierre subsume a la apertura y el modelo sin cuotas no anticipa el movimiento (CLV −0,12 pp, igual que el lado contrario).
5. No hay ventaja rentable demostrable. El modelo sin cuotas pierde entre −8,5 % y −14,8 % y promete +20 % a +36 %; el único ROI positivo proviene de comparar precios entre casas y no es significativo con una referencia implementable.
6. La calibración depende de la normalización. El sesgo favorito–longshot de 1 a 4 pp casi desaparece con la normalización por potencia. La LR sobre cuotas reduce a la mitad el ECE del mercado (0.0134 a 0.0071).
7. MI frente a PCA: MI gana con una variable dominante y PCA ≥ MI sin ella; en ningún caso reducir supera a usar todas las variables.
8. No hay concept drift detectable entre 2018/19 y 2025/26.

Trabajo futuro. (a) Alineaciones reales y lesiones previas al partido, que son la información que el mercado incorpora entre apertura y cierre; (b) snapshots de habilidades con varias fechas por temporada; (c) comparación con modelos de conteo de Poisson [3], [4]; (d) mercados menos eficientes (ligas inferiores, hándicap asiático, totales de goles); (e) selección de hiperparámetros con una ventana de ajuste mayor y validación anidada.

Referencias

[1] I. Tammouch, A. Elouafi, and I. Essadik, "Betting on Machine Learning: Extracting Patterns from Football's Anarchic Odds," 2024.

[2] J. Stübinger, B. Mangold, and J. Knoll, "Machine Learning in Football Betting: Prediction of Match Results Based on Player Characteristics," Applied Sciences, vol. 10, no. 1, art. 46, 2020.

[3] M. J. Dixon and S. G. Coles, "Modelling Association Football Scores and Inefficiencies in the Football Betting Market," Journal of the Royal Statistical Society: Series C (Applied Statistics), vol. 46, no. 2, pp. 265–280, 1997.

[4] D. Karlis and I. Ntzoufras, "Analysis of sports data using bivariate Poisson models," The Statistician, vol. 52, no. 3, pp. 381–393, 2003.

[5] E. S. Epstein, "A scoring system for probability forecasts of ranked categories," Journal of Applied Meteorology, vol. 8, no. 6, pp. 985–987, 1969.

[6] A. Zheng and A. Casari, Feature Engineering for Machine Learning. O'Reilly Media, 2018.

[7] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor, An Introduction to Statistical Learning with Applications in Python. Springer, 2023.

[8] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: a practical and powerful approach to multiple testing," Journal of the Royal Statistical Society: Series B, vol. 57, no. 1, pp. 289–300, 1995.

[9] football-data.co.uk, "Football Data Historical Results and Betting Odds," https://football-data.co.uk/data.php, 2025.

[10] Kaggle, "FIFA / EA Sports FC Player Ratings Datasets (sofifa)," https://www.kaggle.com/datasets/, 2025.