Predicción probabilística del resultado 1X2 en partidos de fútbol mediante Machine Learning

José Luis Alva Espinoza
Departamento de Computación
Universidad de Ingeniería y Tecnología
Lima, Perú
jose.alva.e@utec.edu.pe

Juan Carlos Ticlia Maqui
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
juan.ticlia@utec.edu.pe

Elmer José Manuel Villegaz Suárez
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
elmer.villegas@utec.edu.pe

Joseph Anderson Cose Rojas
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
joseph.cose@utec.edu.pe

Resumen—Se estima la probabilidad de victoria local, empate y victoria visitante (1X2) de un partido de fútbol con información previa al partido, y se evalúa si algo distinto de las cuotas de apertura aporta información que el mercado no tenga. El dataset, de construcción propia, reúne 36,150 partidos de nueve ligas europeas (2014/15–2025/26) con cuotas de varias casas, estadísticas de partido y ratings FIFA/FC de los jugadores. La validación es temporal (6 temporadas, 2018/19–2023/24) y las dos últimas temporadas (5,999 partidos) se reservan como test que se evalúa una sola vez. Se compara un baseline (regresión logística sobre las cuotas) con boosting, XGBoost, SVM, MLP y ensembles, con log loss, RPS, AUC y calibración, e intervalos bootstrap. El modelo final, una regresión logística de dos variables sobre la cuota de apertura de Pinnacle, obtiene log loss 0.9653 en validación y 0.9651 en el test, frente a 0.9664 y 0.9667 del mercado crudo (mejora de 0.0011 y 0.0016; p ajustado 0.004). Frente a Pinnacle cruda y al baseline la diferencia es mínima, y el AUC (0.684) es el del mercado: el modelo recalibra el precio, no ordena mejor los partidos. Ni la plantilla, ni la forma, ni Elo, ni goles esperados, ni las habilidades individuales, ni modelos más complejos mejoran al precio, y el backtest no da un retorno significativamente positivo: el mercado es eficiente respecto a la información disponible. El código está en https://github.com/jcarlos-t/MLProject.git.

Index Terms—Machine Learning, predicción de fútbol, 1X2, cuotas de apuestas, eficiencia del mercado, validación temporal, calibración.

I. Introducción y formulación del problema

I-A. Contexto y motivación

El fútbol marca pocos goles y tiene un componente de azar elevado, por lo que incluso los modelos más avanzados rara vez superan el 55 % de acierto [1], [2]. Las cuotas de las casas de apuestas agregan información de muchas fuentes; un modelo de machine learning (ML) es útil solo si estima probabilidades calibradas (que se cumplen en la práctica) y, opcionalmente, detecta discrepancias con el mercado (value bets). Por eso no basta con maximizar el acierto: se evalúan las probabilidades, su calibración y la rentabilidad.

I-B. Tarea de Machine Learning

Dado un partido con local H y visitante A, se estima $P(\text{FTR} = c \mid \mathbf{x})$, $c \in \{H, D, A\}$, donde $\mathbf{x}$ agrupa solo información previa al partido: forma reciente, calidad y habilidades de la plantilla, localía y cuotas de apertura. Es (a) una clasificación multiclase con salida probabilística y (b) una regresión de la diferencia de goles $GD = \text{FTHG} - \text{FTAG}$, de la que se derivan probabilidades 1X2 como en Stübinger et al. [2].

I-C. Métricas

Con $y_{ic} \in \{0, 1\}$ el indicador de la clase real y $\hat{p}_{ic}$ la probabilidad estimada, la métrica principal es el log loss

$$\text{LL} = -\frac{1}{N} \sum_i \sum_c y_{ic} \log \hat{p}_{ic}, \tag{1}$$

que penaliza las probabilidades mal calibradas. Se reportan también el RPS [5], que penaliza más fallar por dos categorías ordenadas ($H > D > A$); el AUC uno-contra-el-resto, que mide solo si el modelo ordena bien los partidos; y el ECE (error de calibración esperado, sobre diez tramos de igual ancho; el test usa tramos de igual masa y se indica). Una cuota o_c implica la probabilidad

$$p_c = \frac{1/o_c}{\sum_j 1/o_j}, \tag{2}$$

que elimina el margen de la casa, y una value bet existe si $\hat{p}_c \, o_c > 1 + \tau$.

I-D. Preguntas de investigación e hipótesis

- P1: ¿el desempeño es estable entre temporadas o hay concept drift?
- P2: ¿la plantilla mejora la predicción frente a solo estadísticas históricas?

Cuadro I
Bloques de variables del dataset.

Bloque	N.º	Ejemplos
Identificación	5	liga, temporada, fecha, equipos
Resultado (target)	3	FTR, goles locales y visitantes
Estadísticas de partido (posteriores)	12	tiros, córners, faltas, tarjetas
Cuotas observadas	18	apertura de cinco casas; cierre de Pinnacle
Calidad de plantilla	36	medias por línea, mejor once, overall
Habilidades del once titular	33	definición, regate, pase, portero

- P3: ¿mutual information (MI) o PCA preserva mejor la señal, como en [1]?
- P4: ¿un ensemble calibrado detecta value bets rentables?
- Hipótesis: (i) las cuotas dominan sobre las demás variables; (ii) la plantilla aporta señal complementaria, sobre todo al inicio de temporada; (iii) un modelo mal calibrado puede acertar más y perder dinero.

II. Datos y análisis exploratorio (EDA)

II-A. Fuente y variable objetivo

El dataset combina dos fuentes públicas: football-data.co.uk [10] (Premier League, Bundesliga, La Liga, Serie A, Ligue 1, Eredivisie, Primeira Liga, Süper Lig y Pro League; resultados, estadísticas de partido y 159 columnas de cuotas) y los ratings FIFA/EA FC [11] (12 versiones anuales, de las que se derivan la calidad de la plantilla y 33 habilidades del once titular). Se cubren las temporadas 2014/15–2025/26: 36,150 partidos y 296 equipos, de los cuales 36,119 son modelables tras excluir 31 partidos sin ninguna cuota de apertura; la temporada 2013/14 se usa solo para iniciar el historial de cada equipo. La Tabla I resume las variables. La variable objetivo FTR está levemente desbalanceada (local 44.4 %, visitante 30.7 %, empate 24.9 %) y no se rebalancea: se usa como probabilidad previa.

Los ratings de FC 25 (julio de 2025) y FC 26 (septiembre de 2025) se capturaron con la temporada ya avanzada o terminada, por lo que reflejan parte del rendimiento de las temporadas del test. Ninguno de los resultados reportados usa esas habilidades (el modelo final solo usa cuotas), de modo que esto no los afecta.

II-B. Calidad de los datos

Faltantes. De las 159 columnas de cuotas, 141 se eliminan (más del 20 % de nulos) y 18 se conservan sin imputar (Fig. 1): la ausencia depende de la casa y de la temporada (Pinnacle falta en el 52 % de 2025/26 y William Hill en el 100 %), de modo que imputar inventaría un precio que no existió. Las estadísticas de partido tienen 11.1 % de nulos no aleatorios, porque la fuente no las publica para cuatro ligas antes de 2017/18; tampoco se imputan. Se eliminan Time, Referee y los datos del descanso por ser estructurales o posteriores al partido. No hay duplicados, y la plantilla no tiene nulos tras corregir 110 casos de nombres de club mal emparejados (9.9 % de los partidos).

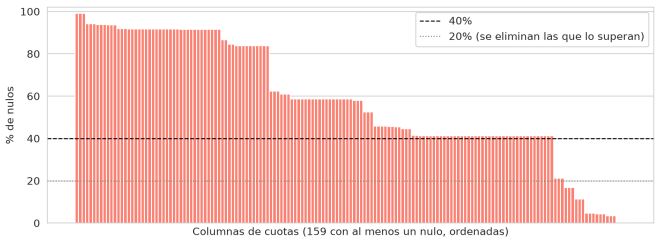


Figura 1. Porcentaje de nulos por columna de cuotas, con los umbrales de 20 % y 40 %.

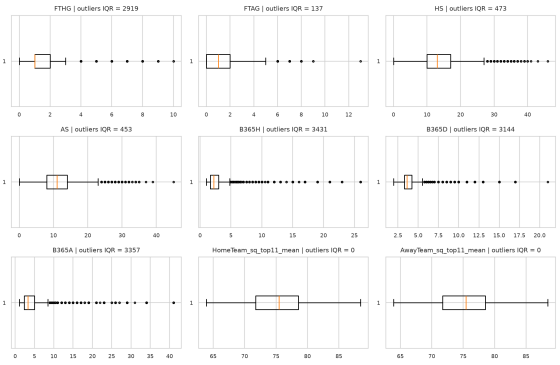


Figura 2. Boxplots de variables representativas (puntos = valores extremos según IQR).

Valores extremos. La regla IQR marca menos del 2 % de los goles y tiros (hasta 13 goles y 46 tiros) y las cuotas largas (hasta 41) corresponden a partidos muy desequilibrados (Fig. 2). Son partidos reales y no se acotan: la cola es justo donde se concentra el valor en un backtest.

II-C. Relaciones entre variables

Las cuotas anticipan el resultado: la cuota del local es menor cuando gana el local (Fig. 3), y las casas correlacionan entre sí con $|r| > 0{,}95$, por lo que conviene resumir el mercado en un único consenso. La calidad del once también separa los resultados (la diferencia local–visitante es mayor cuando gana el local), pero correlaciona poco con las cuotas en bruto (Fig. 4); las estadísticas de partido correlacionan entre sí ($r \approx 0{,}6$–$0{,}7$).

II-D. Sesgos y data leakage

Los riesgos de fuga y cómo se evitan: (i) las estadísticas del propio partido se usan solo como medias de partidos anteriores; (ii) toda agregación mira solo el pasado, la partición es cronológica, los hiperparámetros se eligen en una ventana disjunta de la evaluación, el umbral τ del backtest se fija a priori y las dos últimas temporadas quedan como test sin participar en ninguna decisión; (iii)

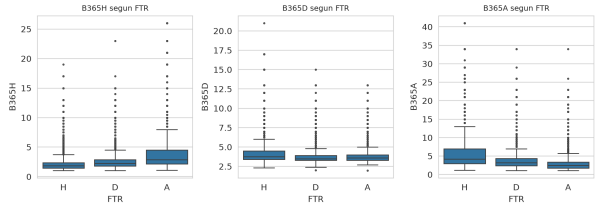


Figura 3. Cuotas de apertura de Bet365 según el resultado real.

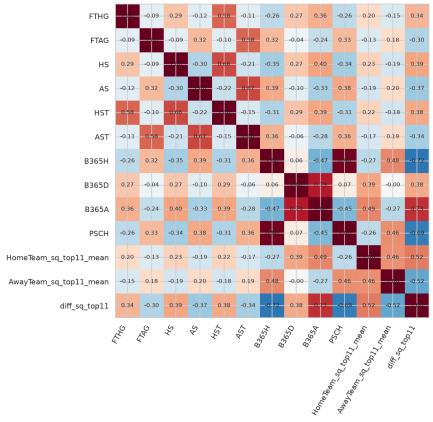


Figura 4. Correlación entre variables clave (goles, tiros, cuotas medias y plantilla).

la imputación de la plantilla se corrigió para no mezclarla con estadísticas del partido; (iv) las cuotas de cierre se publican justo antes del partido y no se usan como variables; (v) hay sesgo de cobertura: las estadísticas no existen en cuatro ligas antes de 2017/18 y Pinnacle cubre solo el 48 % de 2025/26. Dos salvedades no afectan al test pero rompen la regla de "todo dentro de la validación": el ranking de información mutua se calcula con partidos anteriores a febrero de 2024, que incluyen algunos de validación, y las habilidades faltantes se rellenan con la media de su liga y temporada (ratings de otros clubes, nunca resultados).

III. Preprocesamiento e ingeniería de características

Forma y mercado. La forma de cada equipo es la media de sus últimos cinco partidos, sin incluir el actual. De ahí salen dos conjuntos: F1 (13 variables sin nulos, para modelos lineales, SVM y MLP) y F2 (33 variables, 20 con nulos, para árboles). El mercado se resume en el consenso de las probabilidades implícitas (Ec. 2) de cuatro casas, con $\ln(p_H/p_A)$, p_D y el margen. La plantilla se resume en la media del mejor once y su diferencia local–visitante, más 33 habilidades individuales. Una poda por correlación ($|r| > 0{,}95$, sin usar el target) elimina 14 variables redundantes.

Variables nuevas. Siguiendo a Zheng y Casari [6] se construyeron 27 variables previas al partido: el precio de apertura de Pinnacle (con respaldo del consenso), dispersión entre casas, Elo por liga, medias exponenciales de puntos y de diferencia de goles, goles esperados al estilo

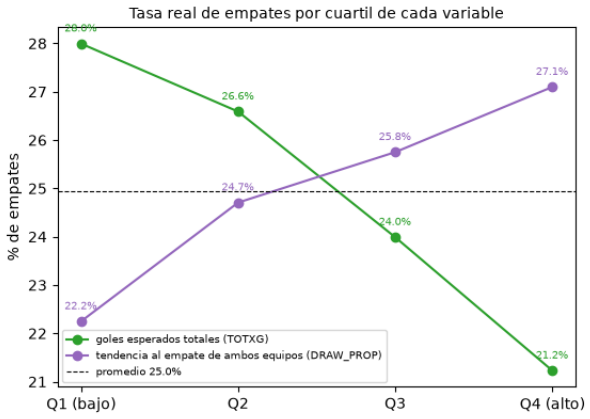


Figura 5. Tasa real de empates por cuartil de goles esperados totales y de tendencia al empate: solo los goles esperados totales muestran una relación clara.

Dixon–Coles [3], tiros a puerta ponderados, tendencia al empate, contexto (descanso, congestión, fase de la temporada) y la plantilla normalizada por liga. La ausencia de fuga se comprobó alterando el resultado de 15 partidos y recalculando el Elo, sin cambios en el rating previo.

Cómo se eligió cada decisión. Cada alternativa se evaluó con la validación temporal de la Sección V y se aceptó solo si mejoraba de forma consistente (Tabla II). Convertir las cuotas a probabilidad es la única transformación que importa; el escalado, el tratamiento de nulos, las transformaciones de asimetría y el binning WOE [8] no mejoran. El margen de las casas cambia con el tiempo (PSI 0.6–1.5) y se descarta. Sin cuotas, la forma de cinco partidos era una mala elección: la memoria larga (Elo, medias exponenciales) la supera (Tabla III); con cuotas ninguna variable nueva aporta. Los goles esperados totales muestran una relación clara con los empates (su tasa baja de 28 % a 21 % entre cuartiles, Fig. 5), pero no mejoran al precio.

Qué entra al modelo final. Solo sobrevive el precio: dos variables, $\ln(p_H/p_A)$ y p_D de la apertura de Pinnacle. Las demás no mejoran al precio, pero eso no significa que carezcan de información: sin cuotas la plantilla y los tiros a puerta sí predicen, solo que el mercado ya las incorpora. Por eso el preprocesamiento se evaluó siempre con y sin cuotas.

IV. Metodología y modelos

Hay tres puntos de comparación. Dos son referencias sin aprendizaje: el prior (frecuencias de $H/D/A$ del entrenamiento) y el mercado crudo (probabilidades implícitas del consenso, Ec. 2). El tercero es el baseline: una regresión logística (LR) sobre las tres variables de mercado (logit local/visitante, probabilidad de empate y margen), el modelo más simple con aprendizaje. Un modelo aporta valor solo si mejora al prior, al baseline y, sobre todo, al mercado.

Cuadro II
Alternativas de preprocesamiento (Δ de log loss frente a la opción vigente; positivo = peor).

Decisión	Alternativas	Resultado
Cuota → variable	cuotas crudas, $1/o$, proporcional, potencia, logit	crudas +0,0057; el resto ≤ 0,0006
Casa de apuestas	B365, Pinnacle, consenso	Pinnacle −0,0006
Escalado	5 escaladores	diferencias ≤ 0,0007
Faltantes	nativo, mediana, indicador, excluir	irrelevante en árboles
Asimetría, extremos	$\log(1+x)$, Yeo–Johnson, winsorizing	ninguna ayuda ($\lvert\Delta\rvert \le 0{,}0001$)
Binning/WOE	10 tramos	peor con cuotas (+0,0026)
Plantilla	mejor once, normalizada, once titular	ninguna mejora con cuotas

Cuadro III
Fuerza de equipo: Δ de log loss (IC 95 % por bloques). Sin cuotas, frente a plantilla + forma de cinco partidos (≈ 0,9884); con cuotas, frente a solo cuotas (0.9657).

Variante	**Δ**	IC 95 %
Sin cuotas (LR)		
plantilla + media de 20 partidos	−0,0018	[−0,0033, −0,0002]
plantilla + media exp. de puntos	−0,0031	[−0,0044, −0,0017]
plantilla + Elo	−0,0055	[−0,0074, −0,0038]
plantilla normalizada + Elo + medias exp.	−0,0068	[−0,0085, −0,0050]
Con cuotas (LR)		
cuotas + plantilla	+0,0002	[−0,0001, +0,0006]
cuotas + Elo	−0,0001	[−0,0004, +0,0002]
cuotas + todo lo nuevo	+0,0004	[−0,0004, +0,0011]

Los modelos de clasificación son: LR (estandarizada, regularización ℓ_2); HGB (gradient boosting con histogramas, tolera nulos) y XGBoost, que reciben F2; SVM con núcleo RBF (entrenado con las 9,000 filas más recientes por su coste) y MLP (una capa oculta), que reciben F1; y un ensemble que promedia sus probabilidades. Para la regresión de GD se usan regresión lineal, Random Forest y HGB, promediados como en [2] y convertidos en probabilidades 1X2 con una regresión logística. Se añaden dos selecciones de variables, MI (las k de mayor información mutua) frente a PCA, calculadas solo con el entrenamiento de cada partición. Se consideran dos escenarios: con cuotas, donde el precio domina, y sin cuotas, el modelo de fundamentos que se compara con el mercado; este usa la mejor combinación de la Sección III (plantilla normalizada, Elo, medias exponenciales) más las 33 habilidades.

Modelo final. Con $x_1 = \ln(p_H/p_A)$ y $x_2 = p_D$ de la apertura de Pinnacle, la LR multinomial estima $P(c \mid x) = \exp(w_c^\top x + b_c)/\sum_k \exp(w_k^\top x + b_k)$ con penalización ℓ_2 de fuerza $1/C$, $C = 0{,}01$. Son nueve parámetros, de modo que no puede sobreajustar y su única función es reescalar el precio: dar más o menos confianza al mercado y ajustar la probabilidad de empate. Se eligió porque el log loss es una regla de puntuación propia y porque las pruebas con rejillas amplias indicaron que la relación es casi lineal. Los modelos más flexibles sirven de contraste: si existiera una relación no lineal entre precio y resultado, HGB, XGBoost o el MLP la habrían encontrado.

Cuadro IV
Hiperparámetros elegidos (ventana 2016/17–2017/18) y, entre paréntesis, con las rejillas amplias.

Modelo	Valores
LR	$C = 0{,}05$ (con validación anidada: 0,01 en 5 de 6 particiones)
HGB	lr=0.03, profundidad 2, leaf=50, 100 iter. (profundidad 1)
XGBoost	lr=0.03, profundidad 2, 100 árboles (profundidad 1, lr=0.1)
SVM (RBF)	$C = 0{,}1$, $\gamma = 0{,}01$ ($C = 0{,}3$, $\gamma = 10^{-4}$)
MLP	capa (16), $\alpha = 1$, 100 iteraciones

V. Diseño experimental y evaluación

Partición. Las 36,119 filas modelables se dividen por temporada. Train/val: 30,120 partidos de 2014/15 a 2023/24. Test: los 5,999 de 2024/25 y 2025/26, que no se usan para entrenar, validar ni elegir variables, hiperparámetros ni umbrales, y se evalúan una sola vez con el modelo ya entrenado (Sección VI-C).

Validación temporal. Para cada una de las seis temporadas de validación (2018/19–2023/24; 18,184 predicciones) se entrena con todas las anteriores y se predice la siguiente. Un K-fold aleatorio y leave-one-season-out dan un log loss entre 0.0001 y 0.0014 menor (más optimista, porque ven el futuro), con el mismo orden de modelos.

Hiperparámetros. Los modelos base (LR, HGB, XGBoost, SVM, MLP) se ajustan una sola vez con una rejilla corta en la ventana 2016/17–2017/18, disjunta de la evaluación, con criterio de menor log loss y desempate por la configuración más simple (Tabla IV). El C del modelo final se elige aparte con las dos últimas temporadas de train/val, porque es el único modelo que se despliega; por eso el baseline usa $C = 0{,}05$ y el modelo final $C = 0{,}01$. Repetir la elección dentro de cada partición reproduce el log loss con diferencia ≤ 0,0001, y las rejillas más amplias mostraron que el óptimo de los árboles tiene profundidad 1 y el del SVM tiende a $\gamma \to 0$: la relación entre precio y resultado es aditiva y casi lineal.

Inferencia. Las comparaciones son pareadas por partido, con bootstrap por bloques (temporada–semana) y corrección de Benjamini–Hochberg [9] dentro de cada familia de comparaciones. Como esa corrección no cubre todo lo probado durante el desarrollo, los p de validación deben leerse como descriptivos; el test es la única comparación sin selección previa. La calibración se mide con diagramas de fiabilidad (intervalos de Wilson) y con el ECE.

Eficiencia del mercado. Se aplican cuatro pruebas: un modelo del residuo $GD - \hat{y}_M$; la relación entre la discrepancia del modelo y el movimiento apertura→cierre

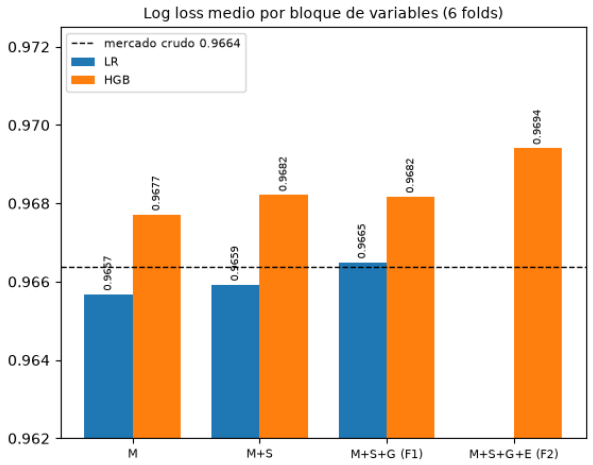


Figura 6. Aporte de cada bloque de variables (M mercado, S plantilla, G forma, E estadísticas de partido): log loss medio con LR y HGB; la línea punteada es el mercado crudo.

de Pinnacle; el valor frente a la línea de cierre (CLV); y un backtest de una unidad por apuesta con cuotas de apertura de Bet365 y Pinnacle, con $\tau = 0{,}02$ fijado a priori (elegirlo por el ROI de validación resultó inestable).

Control de fugas. Todo ajuste (escalado, selección de variables, PCA, recalibración, hiperparámetros) se hace dentro de la parte de entrenamiento y nunca ve la temporada que se predice; ninguna fila del test entra en un ajuste. Las reglas de aceptación del modelo final (IC que excluye 0 y mejora en al menos 5 de 6 temporadas) se escribieron tras explorar las mismas seis temporadas de validación, por lo que sus resultados tienen un sesgo de selección del que solo el test está libre. Las semillas son fijas.

VI. Resultados y análisis

VI-A. Bloques de variables y comparación de modelos

La Fig. 6 responde a la hipótesis (i) y a la pregunta P2: añadir plantilla, forma o estadísticas de partido a las cuotas no mejora el log loss en ningún modelo (mejora en 0–1 de 6 temporadas con LR y en 1–4 con HGB). Sin cuotas, la plantilla sí ayuda a la forma ($\Delta = -0{,}039$), pero con cuotas su efecto es nulo, incluso al inicio de la temporada. La Tabla V y la Fig. 7 comparan los modelos: la LR sobre las cuotas es la mejor en log loss, RPS y calibración, e indistinguible en AUC; los demás son significativamente peores que ella (el MLP por 0,0014) y ningún modelo flexible la supera. Con las rejillas amplias XGBoost baja a 0.9680 y el SVM a 0.9840 (el SVM original tenía la probabilidad de empate invertida, AUC 0,44), sin alcanzar a la LR.

VI-B. AUC, calibración y modelo final

El AUC por resultado es 0.73 para local y visitante y 0.59 para el empate, que casi nunca es la clase más probable (10 veces en 18,184 partidos); por eso la accuracy (53.8 %) es poco informativa. La LR es también el modelo

Cuadro V
Comparación de modelos en 6 temporadas de validación ($n = 18{,}184$). Δ: log loss frente al baseline (LR sobre cuotas). ECE de tramos de igual ancho.

Modelo	Log loss	RPS	AUC	ECE
Prior (referencia)	1.0720	0.2310	0.496	0.0096
Mercado crudo (referencia)	0.9664	0.1953	0.684	0.0126
LR (cuotas), baseline	0.9657	0.1951	0.684	0.0077
HGB (F1)	0.9680 (+0.0022)	0.1955	0.681	0.0084
MLP (F1)	0.9671 (+0.0014)	0.1954	0.682	0.0086
Ensemble	0.9686 (+0.0029)	0.1957	0.682	0.0142
XGBoost (F2)	0.9697 (+0.0039)	0.1961	0.681	0.0166
SVM (F1)	0.9940 (+0.0282)	0.2014	0.626	0.0233
Modelo final	0.9653 (−0,0011 vs. mercado)	0.1950	0.684	0.0079

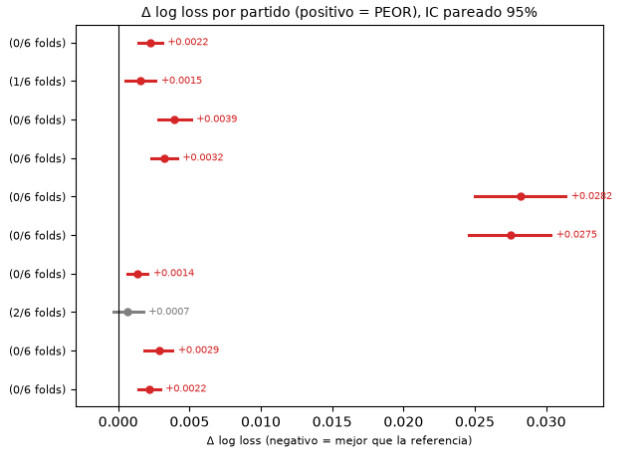


Figura 7. Δ por partido frente al baseline (LR) y frente al mercado (positivo = peor; IC 95 % por bloques; entre paréntesis, temporadas en que mejora). Los contrastes siguen siendo significativos tras Benjamini–Hochberg en 9 de 11; las excepciones son la LR y el MLP frente al mercado crudo.

mejor calibrado (ECE 0.0077), mientras que el mercado crudo es poco confiado (pendiente de calibración de 1.10, 1.27 y 1.13 para local, empate y visitante, es decir, los favoritos ganan más y los longshots menos de lo que implica el precio), y XGBoost, SVM y el ensemble quedan peor calibrados que el propio mercado.

El AUC mide solo el orden de las probabilidades; el log loss y el ECE miden también su escala. Por eso el modelo final y el mercado crudo tienen el mismo AUC (0.684, Fig. 8) y distinto log loss: el modelo no reordena los partidos, corrige la subconfianza del precio. La mejora es pequeña, pero es la que cabe esperar de una recalibración y no de información nueva.

El modelo final es la LR de dos variables descrita en la Sección IV (respaldo: consenso de las otras casas en el 4.6 % de los partidos). En validación mejora al mercado crudo en 0,0011 ([0,0004, 0,0018], p ajustado 0,004) en 5 de 6 temporadas. Frente a Pinnacle cruda la ventaja (0,0004) no se distingue de 0, y frente al baseline es de 0,0004 (p ajustado 0,015): el modelo final es ese mismo baseline sin el margen y con el precio de Pinnacle. Sus coeficientes son estables entre temporadas y el modelo queda dentro de la banda de confianza de la diagonal de fiabilidad (Fig. 9), mientras que el mercado se separa de ella en los extremos.

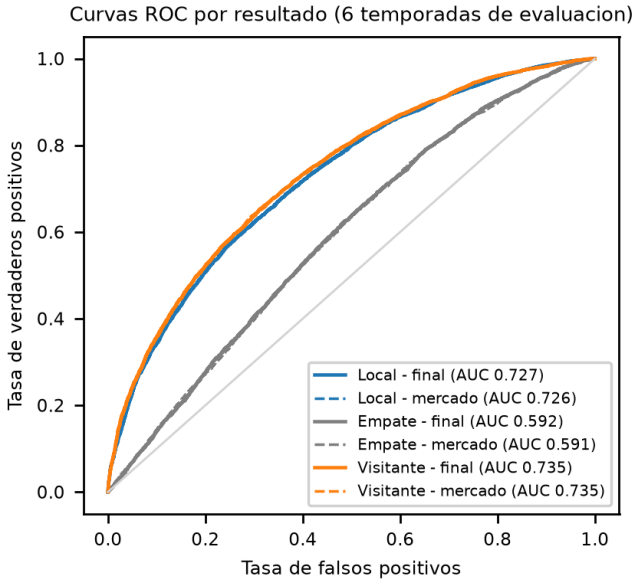


Figura 8. Curvas ROC de los tres resultados (validación): modelo final (continuo) y mercado crudo (discontinuo) se superponen; AUC macro 0.684 en ambos.

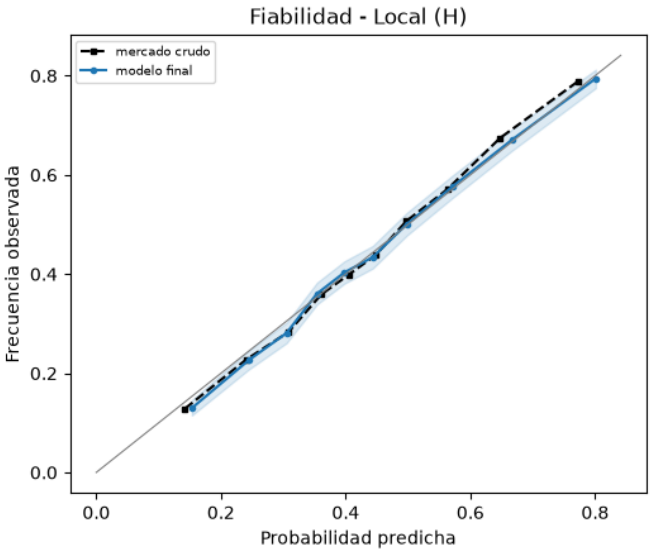


Figura 9. Diagrama de fiabilidad del resultado local (deciles de igual masa, banda de Wilson 95 %): el mercado se separa de la diagonal en los extremos y el modelo final queda dentro de la banda.

VI-C. Evaluación en el test

Las temporadas 2024/25 y 2025/26 (5,999 partidos) no participaron en ninguna decisión. El log loss en el test (0.9651) es igual al de validación (0.9653), de modo que no hay sobreajuste a la selección, y la ventaja sobre el mercado crudo se mantiene: −0,0016 ([−0,0027, −0,0006], p ajustado 0,004), igual en las dos temporadas (Tabla VI, Figs. 10 y 11). Pero esa es la comparación más favorable, porque el consenso es la referencia más débil. Frente a Pinnacle cruda la diferencia (−0,0009) está en el límite de

Cuadro VI
Test (2024/25–2025/26, $n = 5{,}999$): modelos entrenados solo con train/val. ECE de tramos de igual masa. Δ: log loss del modelo final frente a cada referencia, IC 95 % por bloques.

Modelo	Log loss	RPS	AUC	ECE
Prior (train/val)	1.0750	0.2298	0.500	—
Mercado crudo	0.9667	0.1934	0.684	0.0221
Pinnacle cruda (con respaldo)	0.9660	0.1933	0.684	0.0200
Baseline: LR (3 variables)	0.9652	0.1931	0.683	0.0156
Modelo final	0.9651	0.1930	0.683	0.0168

Δ vs. mercado −0,0016 [−0,0027, −0,0006]; vs. Pinnacle −0,0009 [−0,0018, −0,0001]; vs. LR −0,0001 [−0,0005, +0,0003]

Cuadro VII
Test separado por el origen del precio. Δ de log loss del modelo final (negativo = mejor), IC 95 % por bloques.

Precio	n	Δ vs. mercado	Δ vs. Pinnacle
Pinnacle observada	4,440	−0,0020 [−0,0034, −0,0007]	−0,0011 [−0,0022, +0,0000]
Respaldo (consenso)	1,559	−0,0004 [−0,0013, +0,0007]	−0,0004 [−0,0014, +0,0006]

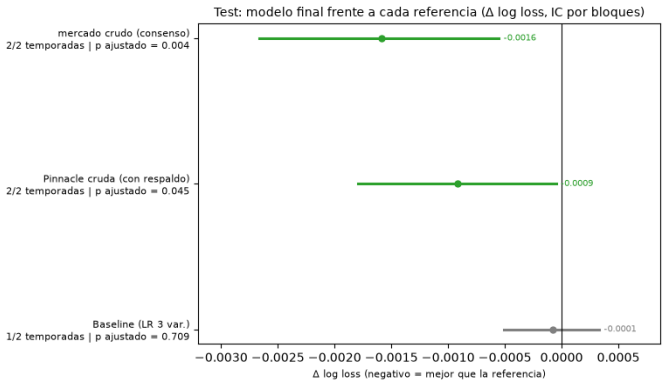


Figura 10. Test: Δ de log loss del modelo final frente a cada referencia (IC por bloques; entre paréntesis, temporadas en que mejora y p ajustado).

la significación (p ajustado 0,045, y 0,063 con otra semilla del bootstrap), y frente al baseline (−0,0001) no existe.

Como en 2025/26 Pinnacle cubre solo el 47.8 % de los partidos, se separó el test según el origen del precio (Tabla VII): con Pinnacle observada (4,440 partidos) el modelo mejora al consenso en 0,0020 y a Pinnacle cruda en 0,0011, y con el respaldo de consenso (1,559 partidos) las diferencias son 0,0004 y no se distinguen de 0. Es decir, casi toda la ventaja viene de los partidos con precio de Pinnacle. La discriminación es la del mercado (AUC 0.683) y el ECE (de igual masa) empeora respecto a validación (0.0168 frente a 0.0093), igual que el del mercado (0.0221 frente a 0.0143), pero el modelo sigue por debajo de él. Por liga solo Turquía es significativa tras la corrección (−0,0045), mientras que en validación lo era Portugal: la mejora por liga no se repite.

Con $\tau = 0{,}02$ fijado a priori, el backtest da −2,6 % con Pinnacle ([−17,9 %, +11,4 %], 482 apuestas) y +11,4 % con Bet365 ([−4,1 %, +29,0 %], 606 apuestas, Fig. 12): ambos intervalos incluyen pérdidas y no se puede afirmar rentabilidad.

VI-D. El mercado como referencia

Sin cuotas. Un modelo de fundamentos acierta el ganador en el 70.4 % de los partidos sin empate frente al 71.6 %

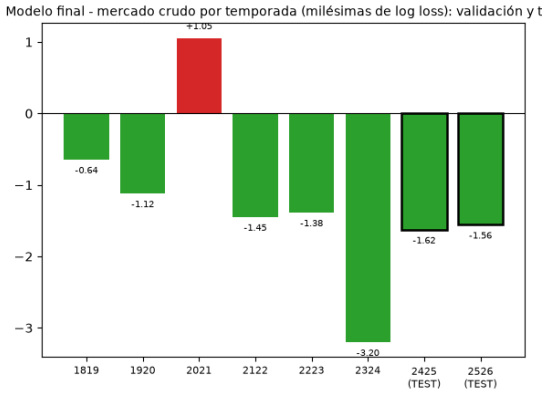


Figura 11. Modelo final — mercado crudo por temporada (milésimas de log loss): seis temporadas de validación y, con borde, las dos del test.

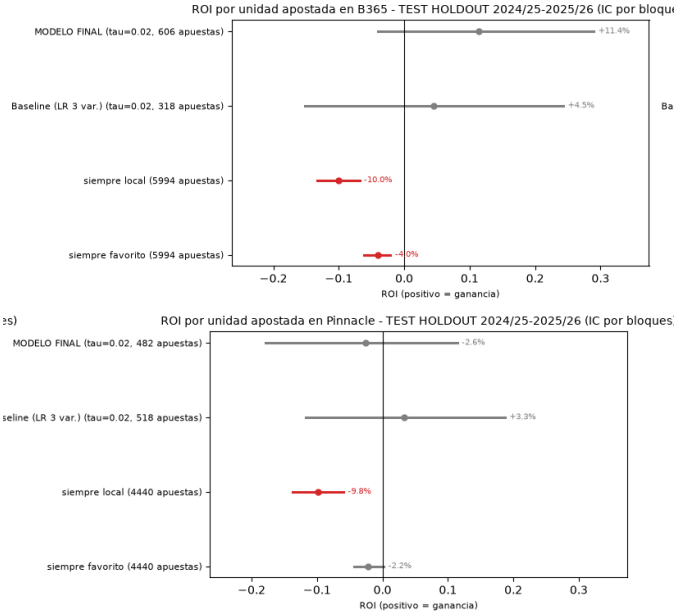


Figura 12. ROI por unidad apostada en el test con cuotas de apertura de Bet365 (arriba) y Pinnacle (abajo); $\tau = 0{,}02$ fijo, IC por bloques. Con Pinnacle solo se cubren los 4,440 partidos con precio observado.

del modelo con cuotas; cuando discrepan (9.6 %), acierta el modelo con cuotas el 56.1 % (McNemar $p < 0{,}0001$). Lo que las cuotas no explican no es predecible con estas variables: el R^2 fuera de muestra del residuo es $-0{,}0006$. Las 33 habilidades individuales reducen el error de GD (RMSE de 1.856 a 1.683), pero empeoran el log loss al añadirse al precio.

Apertura y cierre. El cierre contiene a la apertura (log loss de Pinnacle 0.9658 → 0.9620), y el modelo sin cuotas no anticipa el movimiento del precio: el cierre tiende a corregir sus discrepancias. La Tabla VIII resume las pruebas: ninguna encuentra información que el mercado no tenga.

Calibración del mercado. Los favoritos ganan entre 2 y 4 pp más de lo que implica el precio y los longshots menos

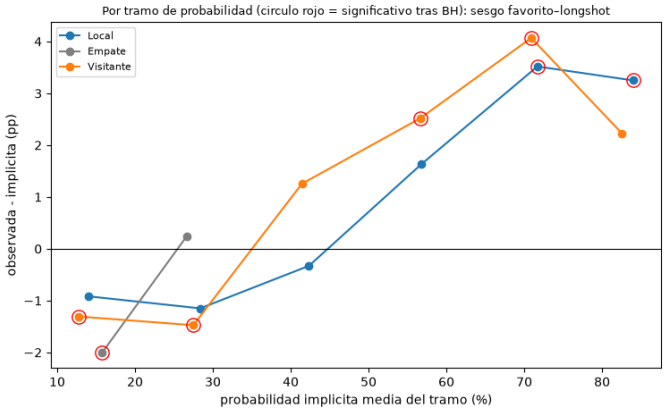


Figura 13. Diferencia entre la frecuencia observada y la implícita en el precio por tramo de probabilidad (sesgo favorito–longshot); círculos rojos = significativo tras Benjamini–Hochberg.

Cuadro VIII
Pruebas de eficiencia del mercado.

Prueba	Resultado
Modelo de residuo ($GD - \hat{y}_M$)	$R^2 = -0{,}0006$; positivo en 2/6 particiones
Apertura frente a cierre	log loss 0.9658 → 0.9620; el cierre domina
Movimiento del mercado	correlación con la discrepancia del modelo: $-0{,}030$
CLV	$-0{,}18$ pp (lado contrario: $-0{,}01$ pp)
Backtest sin cuotas	ROI $-7{,}7$ % a $-12{,}5$ %; promete $+15$ % a $+31$ %
Regla $\lvert\hat{y}\rvert > 2$	706 apuestas, ROI $-2{,}9$ % ($[-6{,}3\,\%, +0{,}1\,\%]$)
Modelo final (Pinnacle)	ROI $-6{,}2$ % ($[-15{,}9\,\%, +4{,}2\,\%]$) en validación; $-2{,}6$ % ($[-17{,}9\,\%, +11{,}4\,\%]$) en test

(Fig. 13). Con la normalización por potencia del margen la pendiente baja de 1,09–1,24 a 1,01–1,08, así que parte del sesgo es consecuencia del método con que se elimina el margen. Por liga ningún sesgo es significativo tras la corrección.

Backtest. Con cuotas de apertura en 2022/23–2023/24, el modelo sin cuotas pierde entre $-7{,}7$ % y $-12{,}5$ % por unidad apostada mientras promete entre $+15$ % y $+31$ % ("maldición del ganador": las apuestas que elige son justo aquellas donde su error es mayor); la regla $\lvert\hat{y}\rvert > 2$ de Stübinger et al. da $-2{,}9$ % en 706 apuestas, de modo que no reproduce el $+1{,}6$ % del artículo; y el modelo final obtiene $-6{,}2$ % con Pinnacle (1,280 apuestas) y $+13{,}8$ % con Bet365 (654 apuestas, $[-4{,}3\,\%, +30{,}8\,\%]$), que incluye pérdidas y no es evidencia de rentabilidad. Con Pinnacle, ningún modelo tiene un retorno significativamente positivo.

VI-E. Análisis de errores e interpretación

La matriz de confusión (Fig. 14) muestra dónde se equivoca el modelo: acierta al local en el 82 % de los casos (precisión 55 %) y al visitante en el 57 % (precisión 52 %), pero el empate casi nunca es la clase más probable (recall 0.1 %) aunque ocurra el 25 % de las veces: un modelo bien calibrado no predice empates aunque les

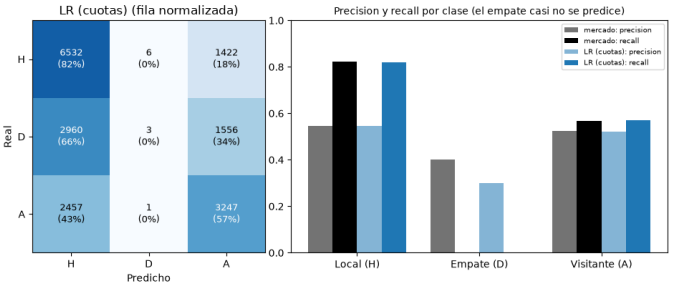


Figura 14. Matriz de confusión de la LR (filas normalizadas) y precisión/recall por clase: el empate casi no se predice.

asigne 25–30 % de probabilidad. En validación, el modelo final mejora al mercado en 7 de 9 ligas, pero solo de forma significativa en Portugal (−0,0038); en Francia el signo es contrario (no significativo). La interpretación es directa porque el modelo es lineal: una desviación estándar más de $\ln(p_H/p_A)$ sube la probabilidad del local (coeficiente +0,56) y baja la del visitante (−0,61), y p_D eleva el empate (+0,13). Por ejemplo, con cuotas de apertura 2.10/3.50/3.60 el modelo da $P(H) = 0{,}452$, $P(D) = 0{,}289$, $P(A) = 0{,}259$ frente a 0,458/0,275/0,267 del precio sin margen. Las conclusiones son robustas a la métrica (Brier y AUC dan el mismo orden) y al método de remuestreo (los intervalos de partidos sueltos son solo 2 % más estrechos).

VI-F. Variables más relevantes, con y sin cuotas

Se usan dos medidas. La información mutua (MI) mide cuánto se sabe del resultado conociendo una sola variable; no depende de ningún modelo y no distingue variables redundantes. La importancia por permutación de grupos mide cuánto sube el log loss de un HGB al barajar todas las variables de un grupo a la vez (Fig. 15); se barajan grupos porque la calidad del once y sus habilidades están muy correlacionadas.

Con cuotas, el precio domina: barajarlo sube el log loss en 0.153 y ningún otro grupo pasa de 0.0013. Sin cuotas, el aporte se ordena así: plantilla (+0.024), Elo (+0.016), tiros a puerta (+0.008), goles y puntos recientes (+0.005) y habilidades individuales (+0.003); córners, faltas, tarjetas y contexto aportan prácticamente nada. La MI coincide en la parte alta, pero asigna una MI alta a las habilidades aunque casi no aporten, porque son redundantes con la plantilla. Es decir, sin cuotas lo más relevante es la fuerza de largo plazo del equipo y los tiros a puerta, no los goles de los últimos partidos.

VII. Discusión y limitaciones

Interpretación. El mercado de apertura ya incorpora la fuerza de los equipos, la plantilla y la forma; lo que mejora al precio es una recalibración, no información nueva. Por eso los modelos más flexibles pierden: la relación entre el precio y el resultado es casi lineal y el resto de variables funciona como ruido. Coincide con la literatura: Tammouch et al. [1] reportan que MI supera a PCA con una variable dominante, y Stübinger et al. [2] encuentran

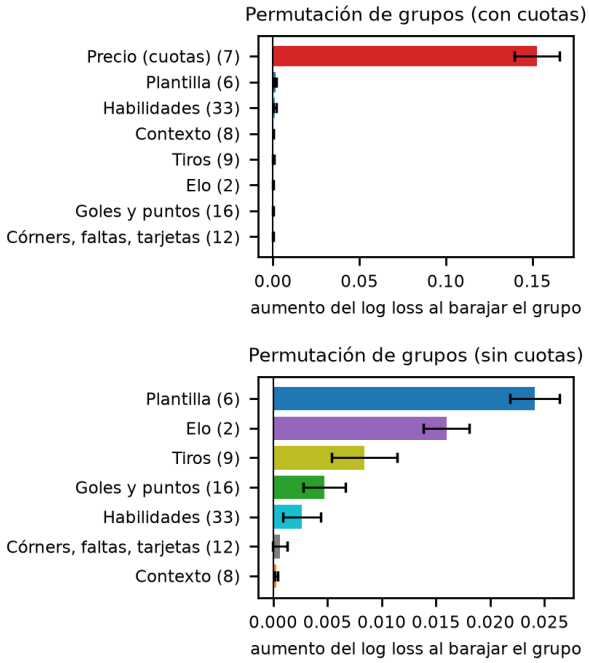


Figura 15. Aumento del log loss al barajar cada grupo (entre paréntesis, su número de variables); media de 6 temporadas e IC 95 %.

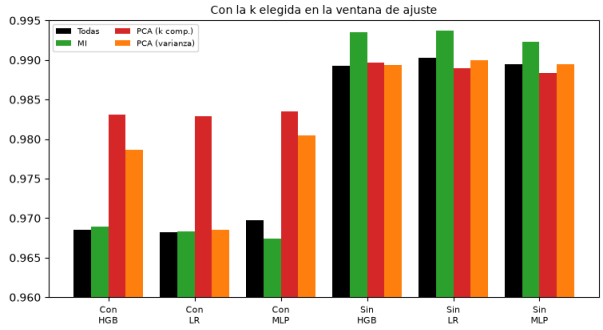


Figura 16. MI frente a PCA (pregunta P3): log loss medio por conjunto y modelo. Con cuotas gana MI; reducir variables casi nunca supera a usar todas.

una ventaja decreciente a medida que las casas adoptan ML.

Limitaciones.

- Se usa la cuota de apertura, no la información entre apertura y cierre (alineaciones, lesiones, dinero apostado), que no está en los datos.
- El "once titular" es el que el juego asigna a cada club, no la alineación de cada partido.
- Pinnacle cubre solo el 48 % de 2025/26 (temporada del test), y el test mezcla dos regímenes de precio; la Sección VI-C los separa.
- Solo hay partidos de liga: el descanso y la congestión no ven copas ni competiciones europeas.
- El test son solo dos temporadas (5,999 partidos) y

sus intervalos son amplios; la mejora por liga no se repite entre validación y test.

- Las diferencias entre modelos (0.001–0.004) son pequeñas frente a la variación entre temporadas (±0,013), por lo que se interpretan con intervalos y no con valores puntuales.
- Sesgo de selección: variables y modelo final se eligieron mirando las mismas seis temporadas con las que se reportan sus p. La ventaja sobre Pinnacle cruda y el baseline (0.0004–0.0009) está dentro del ruido de esa selección.
- La generalización a otras ligas, deportes u otro periodo no está probada.

Consideraciones éticas. Las apuestas pueden causar daño (adicción, pérdidas); este trabajo no es consejo financiero y su resultado apunta justamente a que no hay ventaja rentable demostrable, lo que desaconseja usarlo para apostar. Los datos son públicos (cuotas y ratings profesionales de jugadores, sin datos personales sensibles) y se obtienen respetando sus licencias; no se redistribuyen los datos crudos. No se midió ningún sesgo hacia personas, pero sí un sesgo de cobertura: las ligas con menos historia y las temporadas recientes tienen datos más incompletos.

VIII. Conclusiones

1. El mercado es eficiente respecto a los fundamentos disponibles. El mejor modelo es una regresión logística de dos variables sobre la apertura de Pinnacle (log loss 0.9653 en validación y 0.9651 en el test). Su ventaja es sobre el consenso de cuatro casas (−0,0011 y −0,0016, p ajustado 0,004); frente a Pinnacle cruda es de −0,0009 en test, en el límite de la significación, y frente al baseline no existe. Con el mismo AUC que el mercado, el modelo recalibra el precio: no aporta información nueva.
2. Ni la plantilla, ni la forma, ni Elo, ni los goles esperados, ni las habilidades, ni modelos más complejos mejoran al precio; los tiros a puerta aportan solo sin cuotas. Sin cuotas se predice casi tan bien (70.4 % frente a 71.6 % de acierto del ganador), pero no mejor.
3. P1: no hay concept drift: el log loss del mercado no tiene tendencia y la ventaja del modelo final se mantiene en 5 de 6 temporadas de validación y en las dos del test (Fig. 11). Lo que cambia es la composición de las casas del consenso (William Hill desaparece en 2025/26), por lo que el modelo no usa el margen.
4. P2: la plantilla ayuda sin cuotas (Fig. 6), no con cuotas. P3 (Fig. 16): con cuotas gana MI (6/6 particiones), porque conserva la variable dominante que PCA diluye; sin cuotas PCA $\geq$ MI; en ambos casos reducir variables casi no mejora a usar todas. P4: no hay value bets rentables demostrables.
5. Hipótesis: (i) confirmada; (ii) parcial: la plantilla pesa más al inicio solo sin cuotas, pero no complementa al precio; (iii) no en esa forma: el modelo sin cuotas está bien calibrado en promedio, pero no en los partidos donde discrepa del mercado, que son justo los que elige para apostar; el problema es la calibración condicional y no la global.

Trabajo futuro. (a) Alineaciones reales y lesiones previas al partido, la información que el mercado incorpora entre apertura y cierre; (b) xG de partidos pasados para las ligas que lo publican, que probablemente ayude sin cuotas pero no con el precio; (c) comparación con modelos de conteo de Poisson [3], [4]; (d) versiones de habilidades con varias fechas por temporada.

Referencias

[1] I. Tammouch, A. Elouafi, and I. Essadik, "Betting on Machine Learning: Extracting Patterns from Football's Anarchic Odds," 2024.

[2] J. Stübinger, B. Mangold, and J. Knoll, "Machine Learning in Football Betting: Prediction of Match Results Based on Player Characteristics," Applied Sciences, vol. 10, no. 1, art. 46, 2020.

[3] M. J. Dixon and S. G. Coles, "Modelling Association Football Scores and Inefficiencies in the Football Betting Market," Journal of the Royal Statistical Society: Series C (Applied Statistics), vol. 46, no. 2, pp. 265–280, 1997.

[4] D. Karlis and I. Ntzoufras, "Analysis of sports data using bivariate Poisson models," The Statistician, vol. 52, no. 3, pp. 381–393, 2003.

[5] E. S. Epstein, "A scoring system for probability forecasts of ranked categories," Journal of Applied Meteorology, vol. 8, no. 6, pp. 985–987, 1969.

[6] A. Zheng and A. Casari, Feature Engineering for Machine Learning. O'Reilly Media, 2018.

[7] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor, An Introduction to Statistical Learning with Applications in Python. Springer, 2023.

[8] N. Siddiqi, Intelligent Credit Scoring: Building and Implementing Better Credit Risk Scorecards, 2nd ed. Wiley, 2017.

[9] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: a practical and powerful approach to multiple testing," Journal of the Royal Statistical Society: Series B, vol. 57, no. 1, pp. 289–300, 1995.

[10] football-data.co.uk, "Football Data Historical Results and Betting Odds," https://football-data.co.uk/data.php, 2025.

[11] Kaggle, "FIFA / EA Sports FC Player Ratings Datasets (sofifa)," https://www.kaggle.com/datasets/, 2025.