Predicción probabilística del resultado 1X2 en partidos de fútbol mediante Machine Learning

José Luis Alva Espinoza
Departamento de Computación
Universidad de Ingeniería y Tecnología
Lima, Perú
jose.alva.e@utec.edu.pe

Juan Carlos Ticlia Maqui
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
juan.ticlia@utec.edu.pe

Elmer José Manuel Villegaz Suárez
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
elmer.villegas@utec.edu.pe

Joseph Anderson Cose Rojas
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
joseph.cose@utec.edu.pe

Resumen—Se estima la probabilidad de cada resultado 1X2 de un partido de fútbol con información disponible antes del partido y se evalúa si alguna fuente distinta de las cuotas de apertura aporta información que el mercado no tenga. Se construyó un dataset propio de 36,150 partidos de nueve ligas europeas (2014/15–2025/26) que combina cuotas de varias casas, estadísticas de partido y ratings FIFA/FC de los jugadores. La validación es temporal con ventana expansiva (6 temporadas, 2018/19–2023/24), con hiperparámetros elegidos en una ventana disjunta, y las dos últimas temporadas (2024/25 y 2025/26, 5,999 partidos) se reservan como test holdout que solo se evalúa una vez al final. Las métricas son son probabilísticas (log loss, RPS, AUC y calibración) con intervalos bootstrap por bloques y corrección de Benjamini–Hochberg. Se comparan, frente a dos baselines (frecuencia base y mercado crudo), regresión logística, boosting, XGBoost, SVM, MLP y ensembles. El modelo final es una regresión logística de dos variables sobre la cuota de apertura de Pinnacle, entrenada solo con 2014/15–2023/24: log loss 0.9653 en validación y 0.9651 en el test holdout, frente a 0.9664 y 0.9667 del mercado crudo y 1.0720 y 1.0750 de la frecuencia base (mejora de 0.0011 en validación y de 0.0016 en test, IC [0,0005, 0,0026], p ajustado 0,012), con el mismo AUC (0.684) que el mercado. Ni la plantilla, ni la forma, ni Elo, ni goles esperados, ni las habilidades individuales, ni modelos más complejos mejoran al precio; solo los tiros a puerta aportan, y únicamente sin cuotas. El cierre del mercado subsume a la apertura y el backtest no arroja un retorno significativamente positivo. En 2014–2026 el mercado es eficiente respecto a la información de fundamentos disponible. El código está en https://github.com/jcarlos-t/MLProject.git.

Index Terms—Machine Learning, predicción de fútbol, 1X2, cuotas de apuestas, eficiencia del mercado, validación temporal, calibración.

I. Introducción y formulación del problema

I-A. Contexto y motivación

El fútbol marca pocos goles y tiene un componente de azar elevado, por lo que incluso los modelos más avanzados rara vez superan el 55 % de acierto en la clase ganadora [1], [2]. Las cuotas de las casas de apuestas agregan información de muchas fuentes; un modelo de machine learning (ML) es útil solo si estima probabilidades calibradas y, opcionalmente, detecta discrepancias con el mercado (value bets). Por eso no basta con maximizar el acierto: se evalúan probabilidades, calibración y rentabilidad.

I-B. Tarea de Machine Learning

Dado un partido con local H y visitante A, se estima $P(\mathrm{FTR} = c \mid \mathbf{x})$, $c \in \{H, D, A\}$, donde $\mathbf{x}$ agrupa solo información previa al partido: forma reciente, calidad y habilidades de la plantilla, localía y cuotas de apertura. La tarea es (a) clasificación multiclase con salida probabilística y (b) regresión de la diferencia de goles $GD = \mathrm{FTHG} - \mathrm{FTAG}$, de la que se derivan probabilidades 1X2 como en Stübinger et al. [2].

I-C. Métricas

Con $y_{ic} \in \{0, 1\}$ el indicador de la clase real y $\hat{p}_{ic}$ la probabilidad estimada, la métrica principal es el log loss

$$\mathrm{LL} = -\frac{1}{N} \sum_i \sum_c y_{ic} \log \hat{p}_{ic}, \tag{1}$$

sensible a la calibración. Se reportan también el RPS [5], que penaliza más un error de dos categorías ordenadas ($H > D > A$), el Brier, el AUC uno-contra-el-resto, la accuracy, el ECE sobre diez tramos y la pendiente de calibración (regresión logística del resultado sobre $\mathrm{logit}\,\hat{p}$; > 1 indica un modelo poco confiado). Una cuota o_c implica la probabilidad

$$p_c = \frac{1/o_c}{\sum_j 1/o_j}, \tag{2}$$

que elimina el margen de la casa, y un value bet existe si $\hat{p}_c\, o_c > 1 + \tau$.

I-D. Preguntas de investigación e hipótesis

- P1: ¿el desempeño es estable entre temporadas o hay concept drift?
- P2: ¿la plantilla mejora la predicción frente a solo estadísticas históricas?
- P3: ¿mutual information (MI) o PCA preserva mejor la señal, como en [1]?
- P4: ¿un ensemble calibrado detecta value bets rentables?
- Hipótesis: (i) las cuotas dominan sobre las demás variables; (ii) la plantilla aporta señal complementaria, sobre todo al inicio de temporada; (iii) un modelo mal calibrado puede acertar más y perder dinero.

II. Datos y análisis exploratorio (EDA)

II-A. Fuente y variable objetivo

El dataset es de construcción propia con dos fuentes públicas: football-data.co.uk [10] (Premier League, Bundesliga, La Liga, Serie A, Ligue 1, Eredivisie, Primeira Liga, Süper Lig y Pro League; resultados, estadísticas de partido y 159 columnas de cuotas) y los ratings FIFA/EA FC [11] (12 snapshots anuales, de los que se derivan la calidad de plantilla y 33 habilidades del once titular). Se modelan las temporadas 2014/15–2025/26 (36,150 partidos, 296 equipos); la 2013/14 (2,918 partidos) se usa solo como calentamiento del historial. La variable objetivo FTR está levemente desbalanceada (Tabla II) y se usa como prior, sin rebalancear. El snapshot de FC 25 es de final de temporada; como 2024/25 queda fuera de entrenamiento y validación (es parte del test holdout, Sección V) y el modelo final solo usa cuotas, su posible look-ahead no afecta a ningún resultado.

Cuadro I
Bloques de variables del dataset (el diccionario completo está en el repositorio).

Bloque	N.º	Ejemplos
Identificación	5	liga, temporada, fecha, equipos
Resultado (target)	3	FTR, goles locales y visitantes
Estadísticas de partido (posteriores)	12	tiros, tiros a puerta, córners, faltas, tarjetas
Cuotas observadas	18	apertura de B365, BW, Pinnacle, WH, VC; cierre de Pinnacle
Calidad de plantilla	36	medias por línea, top11_mean, overall
Habilidades del once titular (derivadas)	33	definición, regate, pase, aceleración, portero

Cuadro II
Dataset: tamaño y variable objetivo FTR.

Aspecto	Valor	Prop.
Partidos (2014/15–2025/26)	36,150	—
Columnas: crudas → limpias	225 → 74	—
Ligas / temporadas / equipos	9 / 12 / 296	—
H (gana local)	16,044	44.4 %
A (gana visitante)	11,093	30.7 %
D (empate)	9,013	24.9 %

II-B. Calidad de los datos

Faltantes. De las 159 columnas de cuotas, 141 se eliminan (138 con más del 40 % de nulos y 3 entre 20 % y 40 %) y 18 se conservan sin imputar (Fig. 1): la ausencia depende de la casa y la temporada (Pinnacle falta en el 52 % de 2025/26, William Hill en el 100 %), de modo que imputar fabricaría un precio inexistente y crear banderas de "cuota ausente" delataría el año y no el partido. Las estadísticas de partido (tiros, córners, faltas, tarjetas) tienen 11.1 % de nulos no aleatorios: la fuente no las publica para Bélgica, Países Bajos, Portugal y Turquía antes de 2017/18; tampoco se imputan. Se eliminan Time, Referee, HFKC/AFKC y el resultado al descanso por ser estructurales o posteriores al partido; la plantilla no tiene nulos tras auditar el mapeo de clubes (110 colisiones corregidas, 9.9 % de los partidos). No hay duplicados.

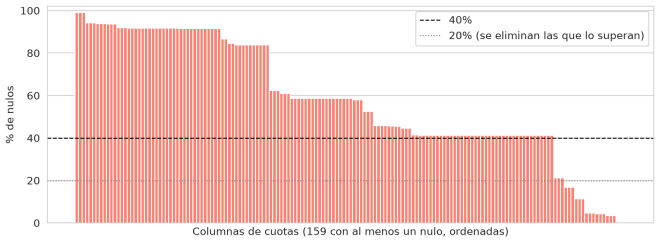


Figura 1. Porcentaje de nulos por columna de cuotas, con los umbrales de 20 % y 40 %.

Valores extremos. La regla IQR marca menos del 2 % de los goles y tiros (hasta 13 goles, 46 tiros) y las cuotas largas (hasta 41 en Bet365) corresponden a partidos muy desequilibrados (Fig. 2). Son partidos reales y no se acotan: la cola es justo donde se concentra el valor en un backtest.

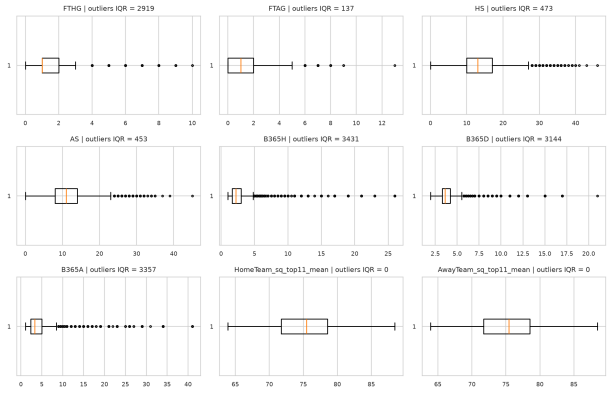


Figura 2. Boxplots de variables representativas (valores observados; puntos = valores IQR extremos).

II-C. Relaciones entre variables

Las cuotas anticipan el resultado: la cuota del local es sistemáticamente menor cuando gana el local (Fig. 3), y las casas correlacionan entre sí con $|r| > 0{,}95$, evidencia de multicolinealidad que justifica resumir el mercado en un único consenso. La plantilla (Fig. 5) correlaciona con el resultado pero poco con las cuotas en bruto, y las estadísticas de partido correlacionan entre sí ($r \approx 0{,}6$–$0{,}7$).

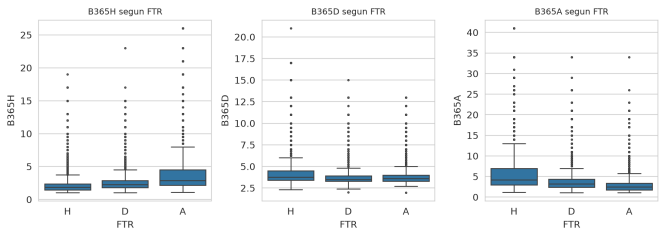


Figura 3. Cuotas de apertura de Bet365 según el resultado real.

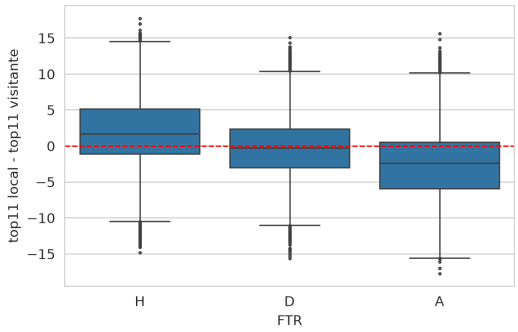


Figura 4. Diferencia de calidad del once (local − visitante) según el resultado: positiva cuando gana el local.

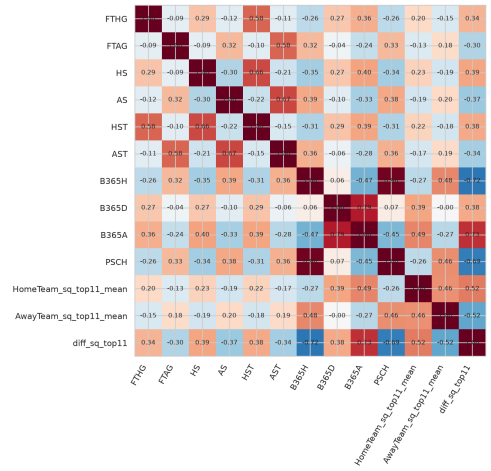


Figura 5. Correlación entre variables clave (goles, tiros, cuotas medias y plantilla).

II-D. Sesgos y data leakage

Los riesgos de fuga son: (i) estadísticas del propio partido, que se transforman en medias móviles que no incluyen el partido actual; (ii) look-ahead temporal: toda agregación usa solo partidos anteriores, el split es cronológico y hiperparámetros y umbrales se eligen en ventanas disjuntas de la evaluación, y las dos últimas temporadas quedan como test holdout que nunca participa en una decisión (un recálculo independiente de 600 valores del historial coincide exactamente); (iii) imputación: una versión inicial imputaba la plantilla junto con estadísticas del partido y se corrigió; (iv) cuotas de cierre, que se publican justo antes del partido y por eso no son features; (v) sesgo de cobertura: las estadísticas no existen en cuatro ligas antes de 2017/18 y Pinnacle cubre solo el 48 % de 2025/26.

III. Preprocesamiento e ingeniería de características

Forma y mercado. La forma de cada equipo es la media de sus últimos cinco partidos (sin incluir el actual), con la temporada de calentamiento y una ventana acolchada con la media de la liga anterior a la fecha; las estadísticas ausentes quedan como NaN. De ahí salen dos conjuntos: F1 (13 variables sin NaN, para modelos lineales, SVM y MLP) y F2 (33 variables, 20 con NaN, para árboles). El mercado se resume en el consenso de las probabilidades implícitas (Ec. 2) de B365, BW, Pinnacle y WH, con $\ln(p_H/p_A)$ (MKT_logit), p_D y el margen; 31 partidos sin ninguna cuota se excluyen del modelado. La plantilla se resume en la media del mejor once (top11_mean) y su diferencia local–visitante, y se añaden 33 habilidades individuales del once titular (top-4 de campo y portero, diferencia local–visitante). Una poda por correlación $|r| > 0{,}95$ (sin usar el target) elimina 14 variables redundantes.

Variables nuevas. Siguiendo a Zheng y Casari [6] se construyeron 27 variables previas al partido: el precio de apertura de Pinnacle con respaldo del consenso

(REF_logit, REF_pD), dispersión entre casas, Elo por liga, medias exponenciales de puntos y diferencia de goles, goles esperados al estilo Dixon–Coles [3], tiros a puerta ponderados, tendencia al empate, contexto (descanso, congestión, fase de temporada, equipos recién llegados) y la plantilla normalizada por liga, tanto con el mejor once como con el once titular. La ausencia de fuga se comprobó alterando el resultado de 15 partidos y recalculando el Elo (el rating previo no cambió en ninguno) y recalculando a mano 300 valores de una media exponencial.

Cómo se eligió cada decisión. Cada alternativa se evaluó con la validación temporal de la Sección V y se aceptó solo si mejoraba de forma consistente (Tabla III). Convertir las cuotas a probabilidad es la única transformación que importa; el escalado, el tratamiento de NaN, las transformaciones de asimetría y el binning WOE [8] no mejoran, y el margen de las casas es una variable de tiempo (PSI 0.6–1.5) que se descarta. Sin cuotas, la forma de cinco partidos era una mala elección: la memoria larga (Elo, medias exponenciales) la supera (Tabla IV); con cuotas ninguna variable nueva aporta, y una tabla de revisión de las 93 variables marca 25 como redundantes, inestables o sin información.

Qué entra al modelo final. De todo lo anterior solo sobrevive el precio: el modelo final usa dos variables, $\ln(p_H/p_A)$ y p_D de la apertura de Pinnacle. Las demás (plantilla, forma, Elo, goles esperados, habilidades individuales, contexto) se conservan en el repositorio y en los experimentos de la Sección VI, pero ninguna mejora al precio. Esto no significa que carezcan de información: sin cuotas la plantilla y los tiros a puerta sí predicen, solo que el mercado ya las incorpora. Por eso el preprocesamiento se evaluó siempre en los dos escenarios (con y sin cuotas) y no solo en el que da el mejor número.

Cuadro III
Alternativas de preprocesamiento (Δ de log loss frente a la opción vigente; positivo = peor).

Decisión	Alternativas	Resultado
Cuota → variable	cuotas crudas, $1/o$, proporcional, potencia, logit	crudas +0,0057; el resto ≤ 0,0006
Casa de apuestas	B365, Pinnacle, consenso	Pinnacle −0,0006; el consenso cubre 100 %
Escalado	5 escaladores × LR, HGB, SVM	HGB invariante; LR rango 0,0007
Faltantes	nativo, mediana, indicador, excluir	irrelevante en árboles; excluir mejor en LR (−0,0018)
Asimetría, extremos	$\log(1+x)$, Yeo–Johnson, winsorizing	ninguna ayuda ($\lvert\Delta\rvert \le 0{,}0001$)
Binning/WOE	10 tramos	peor con cuotas (+0,0026, 0/6 folds)
Plantilla	top-11, normalizada, once titular	≤ 0,0004 sin cuotas, ninguna con cuotas

Cuadro IV
Fuerza de equipo: Δ de log loss (IC 95 % por bloques). Sin cuotas, frente a plantilla + forma de cinco partidos (≈ 0,9884); con cuotas, frente a solo cuotas (0.9657).

Variante	Δ	IC 95 %
Sin cuotas (LR)		
plantilla + media de 10 partidos	−0,0004	[−0,0016, +0,0009]
plantilla + media de 20 partidos	−0,0018	[−0,0033, −0,0002]
plantilla + media exponencial de puntos	−0,0031	[−0,0044, −0,0017]
plantilla + media exponencial de dif. de goles	−0,0054	[−0,0068, −0,0040]
plantilla + Elo	−0,0055	[−0,0074, −0,0038]
plantilla normalizada + Elo + medias exp.	−0,0068	[−0,0085, −0,0050]
+ tiros a puerta (HGB)	−0,0027	[−0,0038, −0,0016]
Con cuotas (LR)		
cuotas + plantilla	+0,0002	[−0,0001, +0,0006]
cuotas + Elo	−0,0001	[−0,0004, +0,0002]
cuotas + medias exponenciales	−0,0001	[−0,0005, +0,0003]
cuotas + todo lo nuevo	+0,0004	[−0,0004, +0,0011]

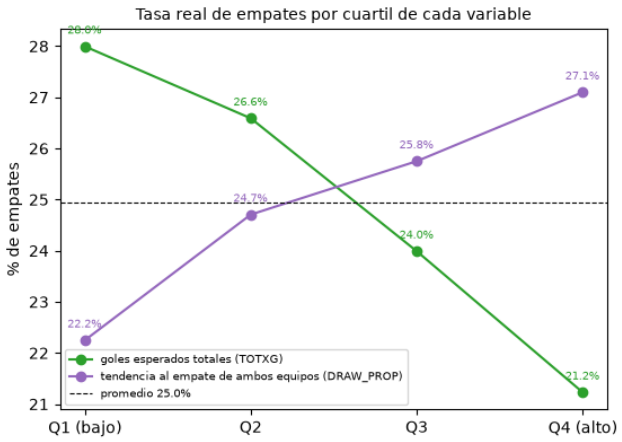


Figura 6. Tasa real de empates por cuartil de goles esperados totales y de tendencia al empate: solo los goles esperados totales muestran una relación clara (28 % a 21 %).

IV. Metodología y modelos

Todos los modelos se comparan con dos baselines sin aprendizaje: el prior (frecuencias de $H/D/A$ del entrenamiento) y el mercado crudo (probabilidades implícitas del consenso, Ec. 2). Un modelo aporta valor solo si mejora al prior y, sobre todo, al mercado. Los modelos de clasificación son: regresión logística (LR, estandarizada, regularización ℓ_2; recibe F1); HGB (gradient boosting con histogramas, tolera NaN) y XGBoost, que reciben F2; SVM con núcleo RBF (entrenado con las 9,000 filas más recientes por su coste cuadrático) y MLP (ReLU, early stopping, tres semillas), que reciben F1; y un ensemble que promedia sus probabilidades. Para la tarea de regresión de GD se usan regresión lineal, Random Forest y HGB (y SVR en una comprobación), promediados como en [2], y se convierten en probabilidades 1X2 con una regresión logística multinomial ajustada en la temporada anterior.

Se añaden dos análisis de selección de variables: MI univariada (top-k) frente a PCA, ambos calculados solo con el entrenamiento de cada fold. Se consideran dos escenarios: con cuotas, donde el precio es una variable dominante, y sin cuotas, el modelo de fundamentos que se compara con el mercado.

Modelo final. Con $x_1 = \ln(p_H/p_A)$ y $x_2 = p_D$ de la apertura de Pinnacle, la LR multinomial estima $P(c \mid x) = \exp(w_c^\top x + b_c)/\sum_k \exp(w_k^\top x + b_k)$ con penalización ℓ_2 de fuerza $1/C$, $C = 0{,}01$. Con solo dos entradas y tres clases son nueve parámetros, de modo que el modelo no puede sobreajustar y su única función es reescalar el precio: aumentar o reducir la confianza del mercado y ajustar la probabilidad de empate. Se eligió esta familia porque el log loss es una regla de puntuación propia y porque las rejillas extendidas (Sección V) indicaron que la relación es casi lineal. Los modelos más flexibles se mantienen como contraste: si hubiera una relación no lineal entre el precio y el resultado, HGB, XGBoost o el MLP la habrían encontrado.

V. Diseño experimental y evaluación

Partición train/val/test. Las 36,119 filas modelables se dividen por temporada (Tabla V): train/val son 30,120 partidos de 2014/15 a 2023/24, y el test holdout son los 5,999 de 2024/25 y 2025/26. El test no se usa para entrenar, validar ni elegir variables, hiperparámetros, regularización ni umbrales, y se evalúa una sola vez, con el modelo ya entrenado, en la Sección VI-D. Los archivos de la partición (train_val.csv y test.csv) los genera scripts/split_holdout.py.

Cuadro V
Partición de los datos por temporada.

Conjunto	Temporadas	Partidos
Train/val (ajuste inicial)	2014/15–2017/18 (la ventana 2016/17–2017/18 se usa para elegir hiperparámetros)	11,936
Train/val (6 folds)	2018/19–2023/24; cada fold se entrena con todo lo anterior	18,184
Test holdout	2024/25 y 2025/26	5,999

Validación temporal. Para cada una de las seis temporadas de validación (2018/19–2023/24; 18,184 predicciones) se entrena con todas las anteriores y se predice la temporada siguiente. Un K-fold aleatorio y leave-one-season-out, restringidos también a train/val, dan un log loss entre 0.0001 y 0.0014 menor (más optimista, porque ven el futuro), con el mismo orden de modelos.

Hiperparámetros. Se eligen con rejilla corta en una ventana de ajuste disjunta (2016/17–2017/18), criterio de menor log loss y desempate por la configuración más simple si la diferencia es menor a 0.0005. La Tabla VI resume los valores. Dos comprobaciones: la validación anidada (elegir en las dos temporadas previas a cada fold) reproduce el log loss con diferencia $\leq 0{,}0001$, y las rejillas extendidas (Fig. 7) mostraron que el óptimo de los árboles tiene profundidad 1 y el del SVM tiende a $\gamma \to 0$: la relación entre el precio y el resultado es aditiva y casi lineal.

Cuadro VI
Hiperparámetros elegidos (ventana 2016/17–2017/18) y, entre paréntesis, con las rejillas extendidas.

Modelo	Valores
LR	$C = 0{,}05$ (anidada: 0,01 en 5 de 6 folds)
HGB	lr=0.03, profundidad 2, leaf=50, 100 iter. (extendida: profundidad 1)
XGBoost	lr=0.03, profundidad 2, 100 árboles, mcw=5 (profundidad 1, lr=0.1)
SVM (RBF)	$C = 0{,}1$, $\gamma = 0{,}01$ ($C = 0{,}3$, $\gamma = 10^{-4}$, probabilidades corregidas)
MLP	capas $(32, 16)$, $\alpha = 1$ (capa (16), $\alpha = 1$)

Inferencia. Las comparaciones son pareadas por partido, con bootstrap por bloques (temporada–semana, 244 bloques), que produce intervalos solo 2 % más anchos que el de partidos sueltos, y corrección de Benjamini–Hochberg [9] sobre las 11 comparaciones de log loss entre modelos. La calibración se mide con diagramas de fiabilidad con intervalos de Wilson y con el ECE de tramos de igual ancho y de igual masa.

Eficiencia del mercado. Cuatro pruebas independientes: modelo de residuo sobre $GD - \hat{y}_M$; correlación entre la discrepancia del modelo con la apertura y el movimiento apertura→cierre de Pinnacle, con prueba de encompassing; valor frente a la línea de cierre (CLV); y backtest de una unidad con cuotas de apertura de Bet365 y Pinnacle, con τ elegido en los cuatro primeros folds, reportado en los dos últimos de validación y, sin volver a elegirlo, aplicado una vez al test holdout.

Control de fugas y reproducibilidad. Todo ajuste (escalado, selección de variables, PCA, recalibración, hiperparámetros) se hace dentro del fold de entrenamiento y nunca ve la temporada que se predice, y ninguna fila del test holdout puede entrar en un ajuste porque los folds terminan en 2023/24 (los cuadernos lo comprueban con una aserción); los umbrales y las reglas de decisión se fijaron antes de ver los resultados de evaluación. Los notebooks están numerados del 01 al 08 en el orden del flujo (EDA, variables, preprocesamiento, modelos, hiperparámetros, mercado, evaluación y modelo final), las semillas son fijas y el repositorio incluye las predicciones fuera de muestra con las que se generan todas las figuras y tablas del informe.

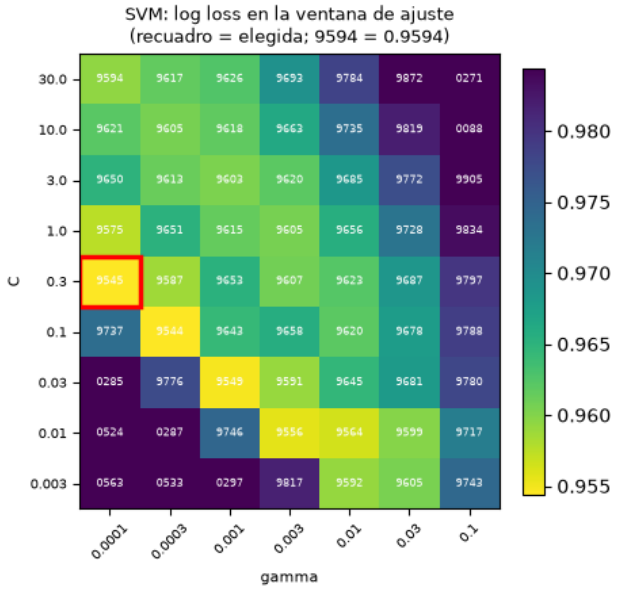


Figura 7. Log loss en la ventana de ajuste de las rejillas extendidas del SVM (C, γ): el número de cada celda es el log loss sin el "0." y el recuadro rojo marca la configuración elegida, en el borde de γ mínimo. El XGBoost muestra lo mismo (óptimo con profundidad 1); MLP y HGB también.

VI. Resultados y análisis

VI-A. Bloques de variables y comparación de modelos

La Fig. 8 responde a la hipótesis (i) y a la pregunta P2: añadir plantilla, forma o estadísticas de partido a las cuotas no mejora el log loss en ningún modelo (mejora en 0–1 de 6 folds con LR y en 1–4 con HGB). Sin cuotas, la plantilla sí ayuda a la forma ($\Delta = -0{,}039$, IC $[-0{,}043, -0{,}035]$), pero con cuotas su efecto es $+0{,}0003$ y es nulo incluso al inicio de la temporada. La Tabla VII y la Fig. 9 comparan los modelos: la regresión logística sobre las cuotas es la mejor en log loss, RPS, calibración y es indistinguible en AUC; todos los demás son significativamente peores, y a mayor flexibilidad, peor resultado. Con las rejillas extendidas XGBoost baja a 0.9680 y el SVM con probabilidades corregidas a 0.9840 (el SVM original tenía una probabilidad de empate invertida, AUC 0,44), sin alcanzar a la LR.

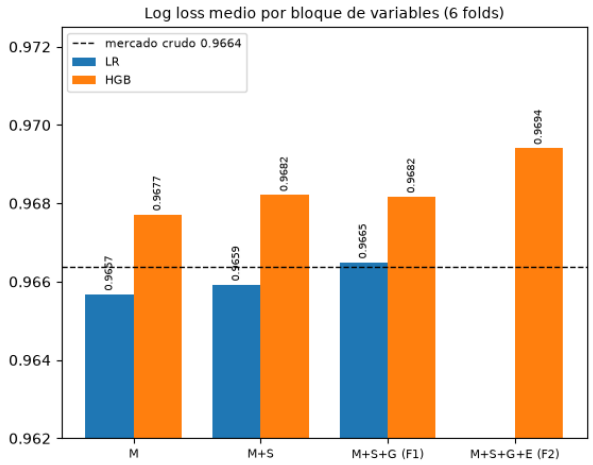


Figura 8. Aporte de cada bloque de variables (M mercado, S plantilla, G forma, E estadísticas de partido): log loss medio con LR y HGB; la línea punteada es el mercado crudo. Añadir bloques a las cuotas no mejora a la LR (mejora en 0–1 de 6 temporadas) ni al HGB.

Cuadro VII
Comparación de modelos en 6 temporadas de validación ($n = 18{,}184$). Δ: log loss frente a la LR sobre cuotas, IC 95 % por bloques.

Modelo	Log loss	RPS	AUC	ECE
Prior (baseline)	1.0720	0.2310	0.496	—
Mercado crudo (baseline)	0.9664	0.1953	0.684	0.0126
LR (cuotas)	0.9657	0.1951	0.684	0.0077
HGB (F1)	0.9680 (+0.0022)	0.1955	0.681	0.0084
MLP (F1)	0.9682 (+0.0025)	0.1957	0.681	0.0099
Ensemble	0.9688 (+0.0031)	0.1958	0.682	0.0145
XGBoost (F2)	0.9697 (+0.0039)	0.1961	0.681	0.0166
SVM (F1)	0.9940 (+0.0282)	0.2014	0.626	0.0233
Modelo final	0.9653 (−0,0011 vs. mercado)	0.1950	0.684	0.0079

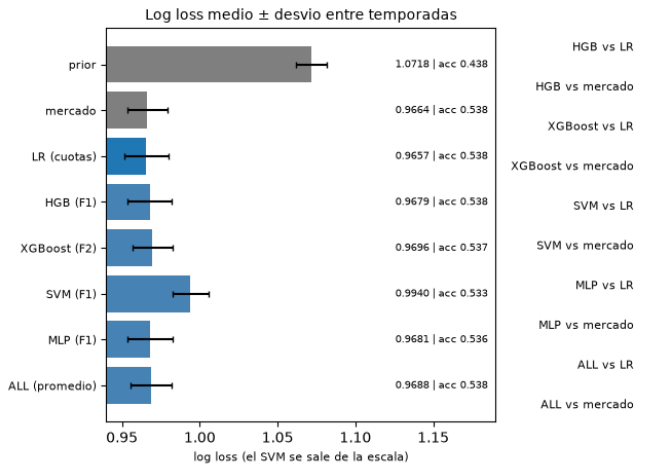


Figura 9. Log loss medio ± desvío entre temporadas de cada modelo (el SVM se sale de la escala).

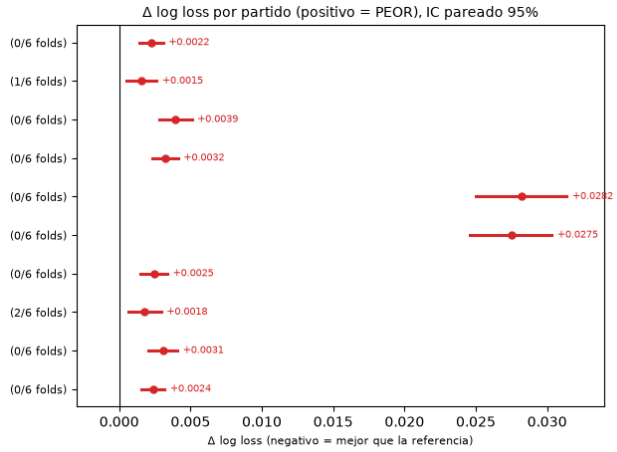


Figura 10. Δ por partido frente a la LR y frente al mercado (positivo = peor; IC pareado 95 %; entre paréntesis, temporadas en que mejora). Los contrastes entre modelos siguen siendo significativos tras Benjamini–Hochberg (10 de 11; la LR frente al mercado crudo no lo es, p ajustado 0,073).

VI-B. AUC, calibración y robustez

El AUC por resultado es 0.73 para local y visitante y 0.59 para el empate, que casi nunca es la clase más probable (10 veces en 18,184 partidos), por lo que la accuracy (53.8 %) y la balanced accuracy (46.4 %) son métricas poco informativas. La LR es también el modelo mejor calibrado (ECE 0.0077, pendientes 1.01–1.06), mientras que el mercado crudo es poco confiado (pendientes 1.10, 1.27 y 1.13 en train/val, Fig. 16) y XGBoost, SVM y el ensemble quedan peor calibrados que el propio mercado. Una recalibración posterior solo mejora el log loss de los modelos que estaban mal calibrados y ninguno supera a la LR.

Cómo leer estas métricas. El AUC mide solo el orden de las probabilidades; el log loss y el ECE miden además su escala. Por eso el modelo final y el mercado crudo pueden tener el mismo AUC (0.684) y distinto log loss: el modelo no reordena los partidos, corrige que el precio es sistemáticamente poco confiado (favoritos que ganan más y longshots que ganan menos de lo que implica la cuota). La mejora es pequeña (0.0011 en validación y 0.0016 en el test) pero consistente, y es exactamente la que cabe esperar de una recalibración y no de información nueva. El empate es el resultado peor discriminado por todos los modelos (AUC 0.59) y casi nunca es la clase más probable, por lo que ningún modelo lo predice con utilidad práctica.

VI-C. Modelo final

El modelo final es una LR de dos variables, $\ln(p_H/p_A)$ y p_D de la cuota de apertura de Pinnacle (respaldo: consenso de las otras casas en el 4.6 % de los partidos), $C = 0{,}01$ elegida por validación anidada, sin el margen de las casas. La regla de elección se fijó antes de ver los resultados (mejora con IC que excluye 0 y en al menos 5 de 6 temporadas). En validación mejora al mercado crudo en 0,0011 ($[0{,}0004, 0{,}0018]$, p ajustado 0,004) en 5 de 6 temporadas, con el mismo AUC: corrige la subconfianza del precio y no ordena mejor los partidos (Fig. 11, curvas ROC con AUC 0.727, 0.592 y 0.735 para local, empate y visitante). Frente a Pinnacle cruda la ventaja (0,0004) no es distinguible de 0. Los coeficientes son estables entre temporadas (desvío $\leq 0{,}017$), la mejora por liga es significativa solo en Portugal tras Benjamini–Hochberg, y un intercepto distinto por liga no ayuda (+0.0003 a +0.0004). El modelo se entrena solo con 2014/15–2023/24 y se evalúa en el test holdout en la Sección VI-D. El modelo se guarda en JSON y su función de uso reproduce al de scikit-learn con error de 10^{-16}.

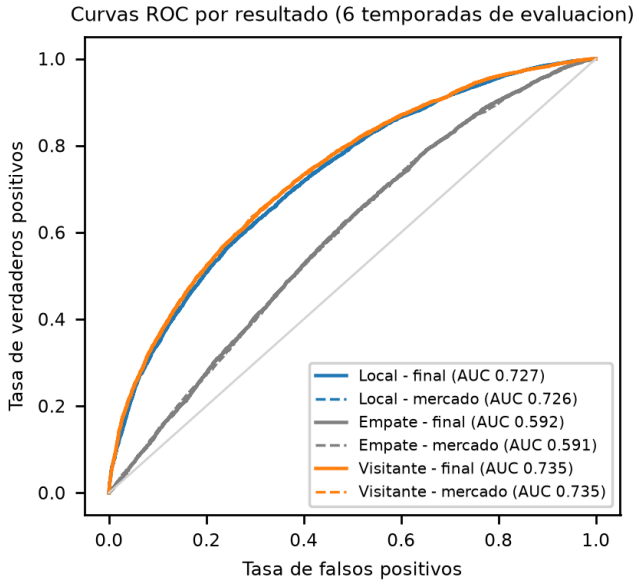


Figura 11. Curvas ROC de los tres resultados (6 temporadas de validación): modelo final (continuo) y mercado crudo (discontinuo) se superponen; AUC macro 0.684 en ambos.

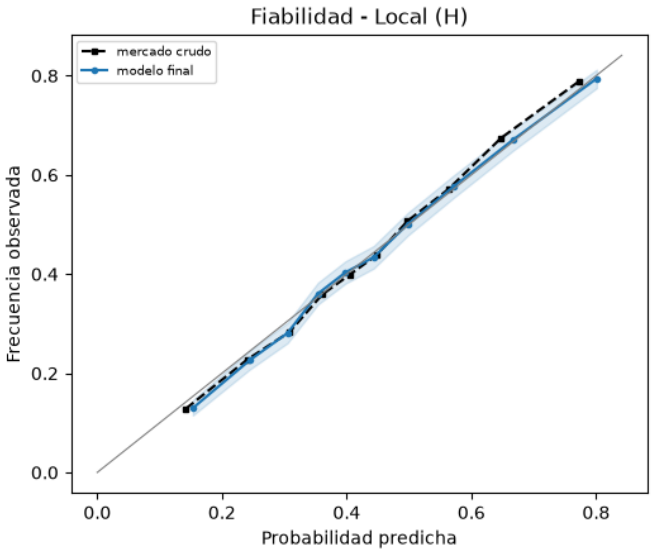


Figura 12. Diagrama de fiabilidad del resultado local (deciles de igual masa, banda de Wilson 95 %): el mercado se separa algo de la diagonal en los extremos (los favoritos ganan más de lo que implica el precio) y el modelo final queda dentro de la banda.

VI-D. Evaluación en el test holdout

Las temporadas 2024/25 y 2025/26 (5,999 partidos) no participaron en ninguna decisión: ni en variables, ni en C, ni en τ, ni en el entrenamiento. Con el modelo final ya entrenado, se evalúan una sola vez (Tabla VIII, Figs. 13 y 14). El log loss en el test (0.9651) es igual al de validación (0.9653), de modo que no hay sobreajuste a la selección, y la ventaja sobre el mercado crudo se mantiene: $-0{,}0016$ ($[-0{,}0026, -0{,}0005]$, p ajustado 0,012), con el mismo valor en las dos temporadas ($-0{,}0016$ en 2024/25 y en 2025/26, pese a que en 2025/26 Pinnacle cubra solo el 47.8 % y el resto use el respaldo). Frente a Pinnacle cruda la diferencia ($-0{,}0009$, p ajustado 0,063) y frente a la LR de tres variables ($-0{,}0001$) no es significativa. La discriminación es la del mercado (AUC macro 0.683) y el ECE empeora respecto a validación (0.0168 frente a 0.0093), pero también el del mercado (0.0221 frente a 0.0143) y el modelo sigue por debajo de él. Por liga solo Turquía es significativa tras Benjamini–Hochberg ($-0{,}0045$, p ajustado 0,027), mientras que en validación lo era Portugal: la mejora por liga no se repite y es mejor describirla como pequeña y repartida. Con el umbral elegido en validación, el backtest da $-2{,}2$ % con Pinnacle ($[-9{,}3\,\%, +4{,}9\,\%]$, 1,425 apuestas) y $+11{,}4$ % con Bet365 ($[-5{,}5\,\%, +29{,}3\,\%]$, 606 apuestas): el intervalo incluye pérdidas y no se puede afirmar rentabilidad (Fig. 15).

Cuadro VIII
Test holdout (2024/25–2025/26, $n = 5{,}999$): modelos entrenados solo con train/val. Δ: log loss del modelo final frente a cada referencia, IC 95 % por bloques.

Modelo	Log loss	RPS	AUC	ECE
Prior (train/val)	1.0750	0.2298	0.500	—
Mercado crudo	0.9667	0.1934	0.684	0.0221
Pinnacle cruda (con respaldo)	0.9660	0.1933	0.684	0.0200
LR (3 variables de mercado)	0.9652	0.1931	0.683	0.0156
Modelo final	0.9651	0.1930	0.683	0.0168

Δ vs. mercado $-0{,}0016$ $[-0{,}0026, -0{,}0005]$; vs. Pinnacle $-0{,}0009$ $[-0{,}0018, -0{,}0000]$; vs. LR $-0{,}0001$ $[-0{,}0005, +0{,}0003]$

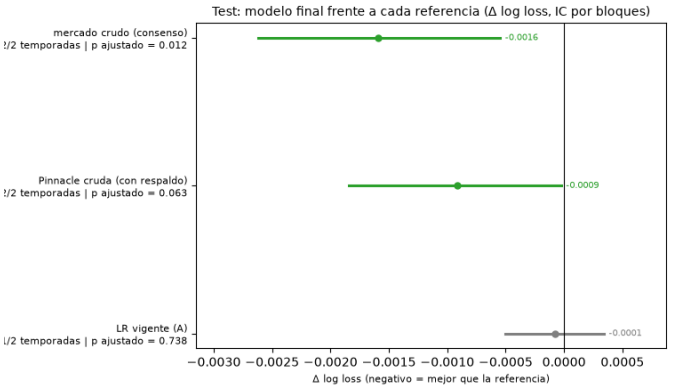


Figura 13. Test holdout: Δ de log loss del modelo final frente a cada referencia (IC por bloques; entre paréntesis, temporadas en que mejora y p ajustado).

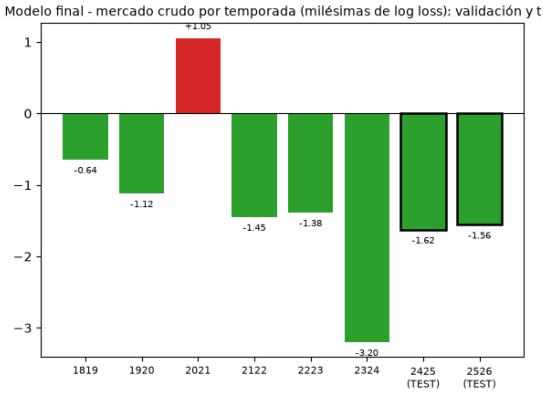


Figura 14. Modelo final − mercado crudo por temporada (milésimas de log loss): seis temporadas de validación y, con borde, las dos del test.

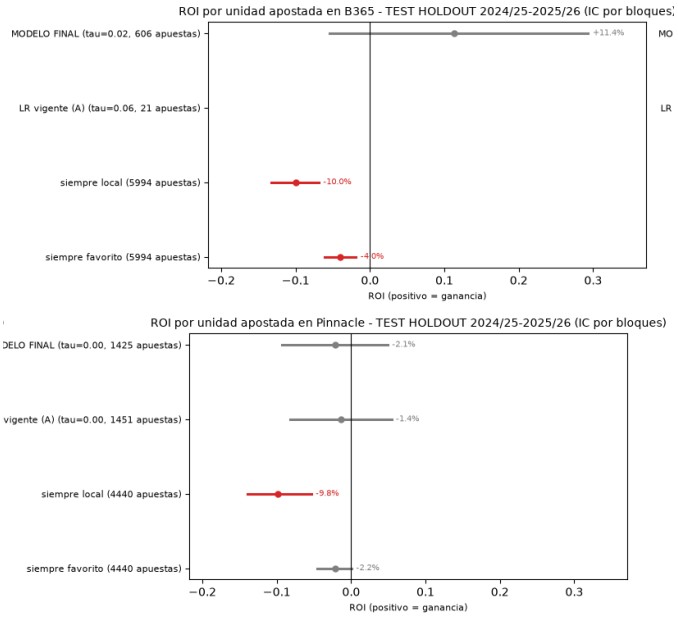


Figura 15. ROI por unidad apostada en el test holdout con cuotas de apertura de Bet365 (arriba) y Pinnacle (abajo); τ elegido en validación, IC por bloques. Con Pinnacle solo se cubren los 4,440 partidos con precio observado.

VI-E. El mercado como referencia

Sin cuotas. Un modelo de fundamentos acierta el ganador en el 69.7 % de los partidos sin empate frente al 71.6 % del modelo con cuotas; cuando discrepan (12.5 %), acierta el modelo con cuotas el 57.5 % (McNemar $p < 0{,}0001$). Lo que las cuotas no explican no es predecible con estas variables: el R^2 fuera de muestra del residuo es $-0{,}001$ y positivo en 1 de 6 folds. Las 33 habilidades individuales reducen el RMSE de GD de 1.856 a 1.683, pero empeoran el log loss al añadirse al precio.

Apertura y cierre. El cierre subsume a la apertura (log loss de Pinnacle 0.9658 → 0.9620; el coeficiente de la apertura es ≈ 0 y el del cierre ≈ 1 en el encompassing), y el modelo sin cuotas no anticipa el movimiento (correlación $-0{,}011$; CLV $-0{,}13$ pp, igual o peor que el del lado contrario, $-0{,}06$ pp).

Pruebas independientes. La Tabla IX resume las cuatro pruebas de eficiencia: ninguna encuentra información que el mercado no tenga.

Calibración del mercado. Los favoritos ganan entre 2 y 4 pp más de lo que implica el precio y los longshots menos (Fig. 17); con la normalización por potencia del margen la pendiente baja de 1,09–1,24 a 1,01–1,08, así que parte del sesgo es consecuencia del método con que se elimina el margen.

Backtest. Con cuotas de apertura (Fig. 19), el modelo sin cuotas pierde entre $-11{,}8$ % y $-16{,}5$ % por unidad apostada mientras promete entre +21 % y +38 % ("maldición del ganador": las apuestas que elige son justo aquellas donde su error es mayor); la regla $|\hat{y}| > 2$ de Stübinger et al. da $-1{,}3$ % ($[-4{,}5\,\%, +2{,}0\,\%]$) en 642 apuestas; y el modelo final obtiene $-1{,}5$ % en Pinnacle ($[-7{,}3\,\%, +4{,}4\,\%]$) en la ventana 2022/23–2023/24. El +3,0 % con Bet365 se apoya en 131 apuestas con IC de ±46 puntos y no es evidencia de rentabilidad; en el test holdout el resultado es análogo (Sección VI-D).

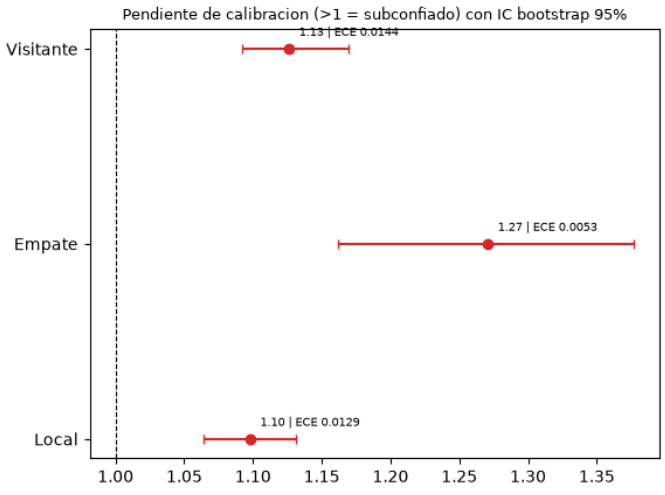


Figura 16. Pendiente de calibración del mercado para cada resultado (IC bootstrap 95 %): el mercado es poco confiado (pendiente > 1) sobre todo en el empate.

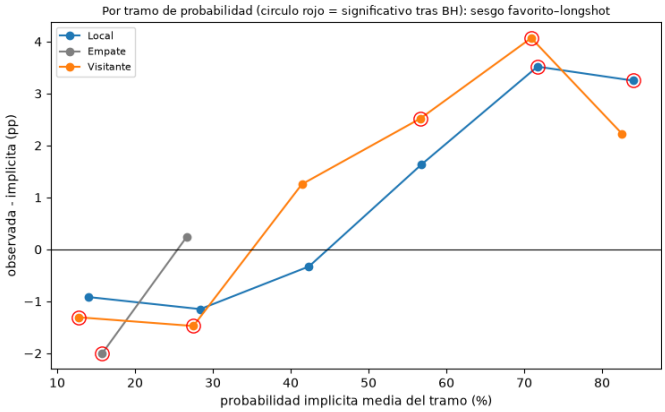


Figura 17. Diferencia entre la frecuencia observada y la implícita en el precio por tramo de probabilidad (sesgo favorito–longshot); círculos rojos = significativo tras Benjamini–Hochberg.

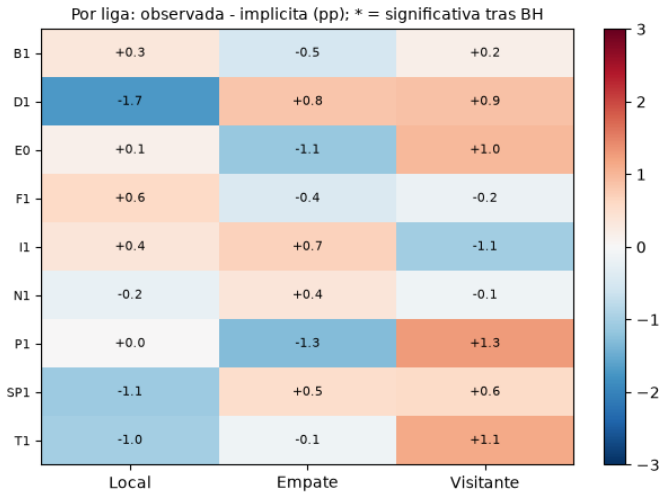


Figura 18. Diferencia observada − implícita por liga y resultado (puntos porcentuales); ninguna liga es significativa tras Benjamini–Hochberg.

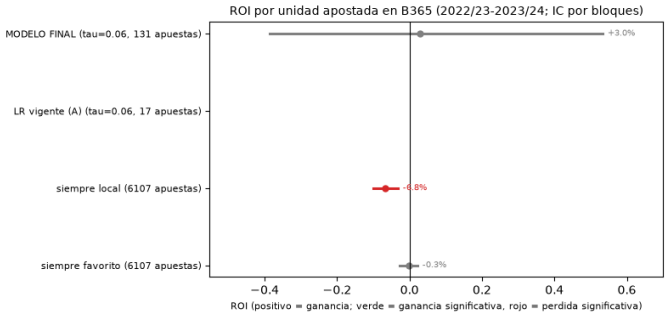


Figura 19. ROI por unidad apostada con cuotas de apertura de Bet365 (2022/23–2023/24, validación, IC por bloques). El modelo final tiene solo 131 apuestas y un IC de ±46 puntos.

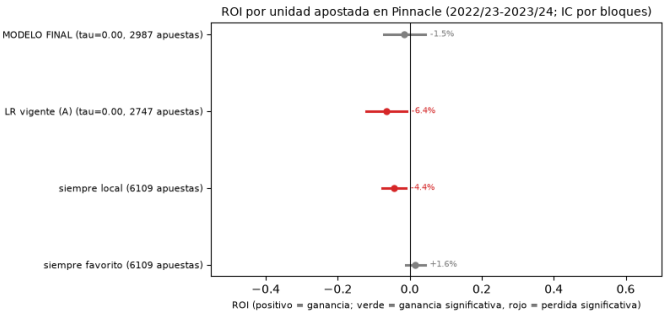


Figura 20. ROI por unidad apostada con cuotas de apertura de Pinnacle (2022/23–2023/24): ningún modelo tiene un retorno significativamente positivo.

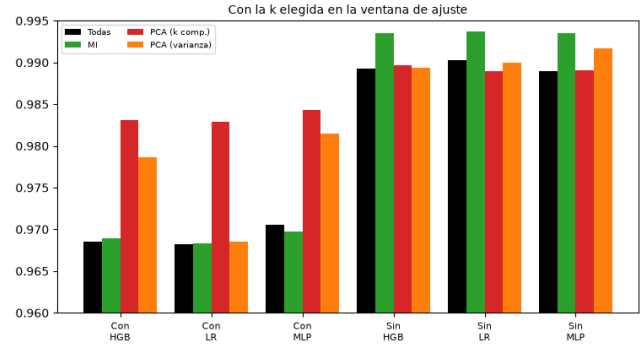


Figura 21. MI frente a PCA (pregunta P3): log loss medio por conjunto y modelo con la k elegida en la ventana de ajuste. Con cuotas gana MI y en ningún caso reducir supera a usar todas las variables.

VI-F. Análisis de errores e interpretación

La matriz de confusión (Fig. 22) muestra dónde se equivoca el modelo: acierta al local en el 82 % de los casos (precisión 55 %) y al visitante en el 57 % (precisión 52 %), pero el empate casi nunca es la clase más probable (recall 0.1 %), incluso cuando ocurre el 25 % de las veces: un modelo bien calibrado no predice empates aunque les asigne 25–30 % de probabilidad. Los errores no se distribuyen igual entre ligas (Fig. 23): el modelo final mejora al mercado en 7 de 9 ligas en el valor puntual (Italia ≈ 0) pero solo de forma significativa en Portugal ($-0{,}0038$) tras Benjamini–Hochberg; en Francia el signo es contrario ($+0{,}0008$, no significativo). La interpretación es directa porque el modelo es lineal: un aumento de una desviación estándar de $\ln(p_H/p_A)$ sube la probabilidad del local (coeficiente $+0{,}56$) y baja la del visitante ($-0{,}61$), y p_D eleva el empate ($+0{,}13$); ejemplo de uso: con cuotas de apertura 2.10/3.50/3.60 el modelo da $P(H) = 0{,}452$, $P(D) = 0{,}289$, $P(A) = 0{,}259$ frente a 0,458/0,275/0,267 del precio sin margen.

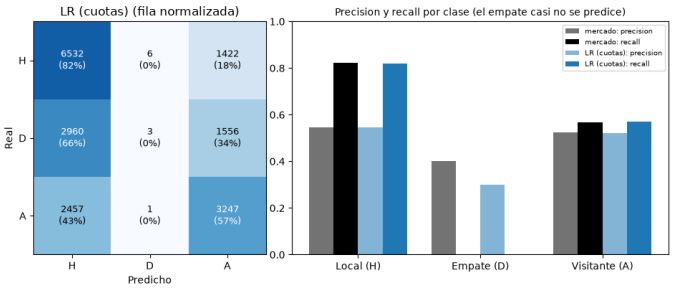


Figura 22. Matriz de confusión de la LR (filas normalizadas; la del mercado es casi igual) y precisión/recall por clase: el empate casi no se predice.

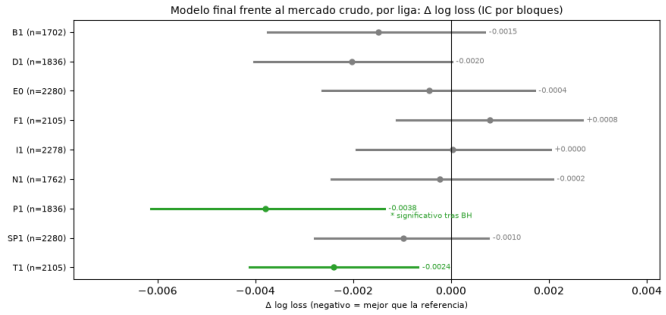


Figura 23. Modelo final frente al mercado por liga en validación (Δ de log loss, IC por bloques; * = significativo tras Benjamini–Hochberg; en verde, IC que excluye 0 sin corregir).

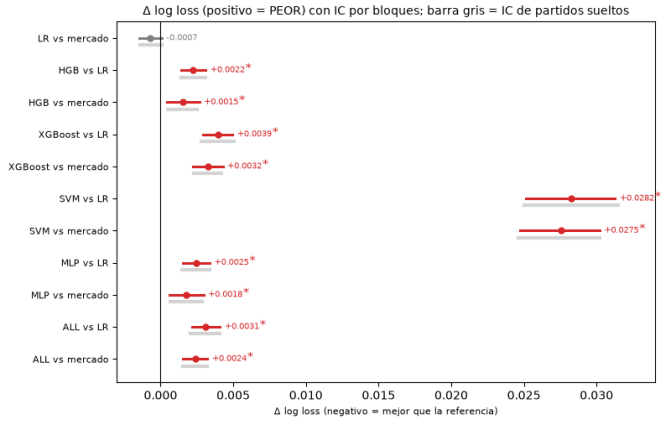


Figura 24. Robustez de la comparación: Δ de log loss con IC por bloques (barra gris = IC de partidos sueltos, solo 2 % más estrecho); * = significativo tras Benjamini–Hochberg. Brier y AUC macro dan el mismo orden.

Cuadro IX
Pruebas de eficiencia del mercado.

Prueba	Resultado
Modelo de residuo ($GD - \hat{y}_M$)	$R^2 = -0{,}001$; positivo en 1/6 folds
Apertura frente a cierre	log loss 0.9658 → 0.9620; coef. apertura ≈ 0, cierre ≈ 1
Movimiento del mercado	correlación con la discrepancia del modelo: −0,011
CLV	−0,13 pp (lado contrario: −0,06 pp)
Backtest sin cuotas	ROI −11,8 % a −16,5 %; promete +21 % a +38 %
Regla $\lvert\hat{y}\rvert > 2$	642 apuestas, ROI −1,3 % ([−4,5 %, +2,0 %])
Modelo final (Pinnacle)	ROI −1,5 % ([−7,3 %, +4,4 %]) en validación; −2,2 % ([−9,3 %, +4,9 %]) en test

VI-G. Variables más relevantes, con y sin cuotas

Se usan dos medidas distintas. La información mutua (MI) mide cuánto se sabe del resultado conociendo una sola variable (Fig. 25); no depende de ningún modelo y no distingue variables redundantes. La importancia por permutación de grupos mide cuánto sube el log loss de un HGB al barajar, en cada temporada de evaluación, todas las variables de un grupo a la vez (Fig. 26); se barajan grupos y no variables sueltas porque la calidad del once y sus habilidades están muy correlacionadas.

Con cuotas, el precio domina: barajarlo sube el log loss en 0.153 y ningún otro grupo pasa de 0.0013. Sin cuotas, el aporte se ordena así: plantilla (+0.024), Elo (+0.016), tiros a puerta (+0.008), goles y puntos recientes (+0.005) y habilidades individuales (+0.003); córners, faltas, tarjetas y contexto aportan prácticamente nada. La MI coincide en la parte alta (plantilla y Elo; los tiros a puerta quedan más abajo), pero asigna una MI alta a las habilidades aunque casi no aporten, porque son redundantes con la plantilla. Es decir, sin cuotas lo más relevante es la fuerza de largo plazo del equipo y los tiros a puerta, no los goles de los últimos partidos.

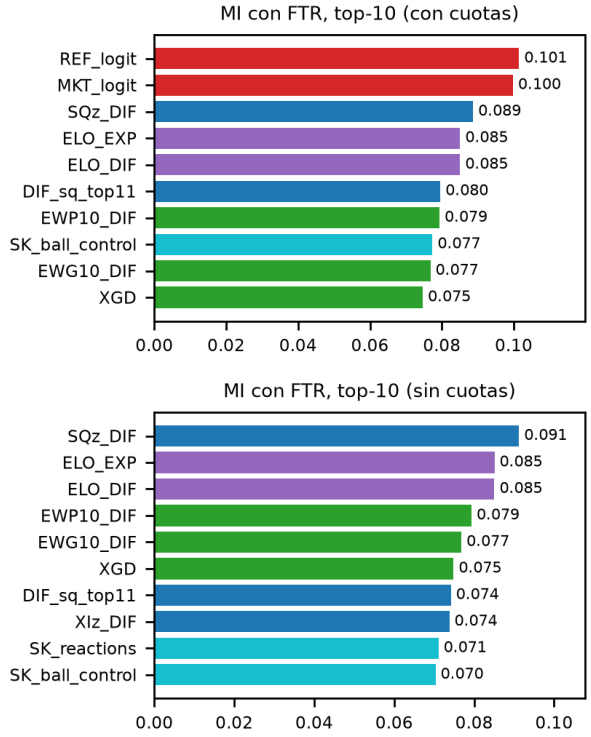


Figura 25. Las diez variables con mayor MI con el resultado, con y sin cuotas (color = grupo de variables).

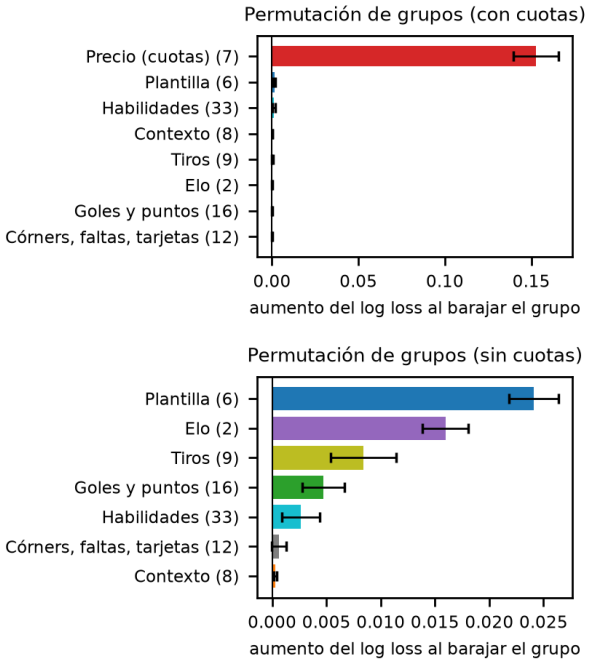


Figura 26. Aumento del log loss al barajar cada grupo (entre paréntesis, su número de variables); media de 6 temporadas e IC 95 %.

VI-H. Preguntas de investigación

- P1: no hay concept drift: el log loss del mercado no tiene tendencia (pendiente $p = 0{,}39$), la ventaja del modelo final sobre el mercado se mantiene en 5 de 6 temporadas de validación y en las dos del test, y entrenar solo con las últimas tres no mejora.
- P2: sí sin cuotas (Fig. 8), no con cuotas.
- P3: con cuotas gana MI ($\Delta = -0{,}014$, 6/6 folds), porque conserva la variable dominante que PCA diluye; sin cuotas PCA $\geq$ MI ($+0{,}004$ a $+0{,}005$); en ambos casos reducir casi no mejora a usar todas las variables (la mejor reducción gana 0.0014).
- P4: no hay value bets rentables demostrables.
- Hipótesis: (i) confirmada; (ii) parcial: la plantilla pesa más al inicio solo sin cuotas, pero no es complementaria al precio; (iii) no en esa forma: el modelo perdedor está bien calibrado en promedio y acierta menos, el problema es su calibración condicional donde discrepa del mercado.

VII. Discusión y limitaciones

Interpretación. El mercado de apertura ya incorpora la fuerza de los equipos, la plantilla y la forma; lo que mejora al precio es una recalibración, no información nueva. Por eso los modelos más flexibles pierden: la relación entre el precio y el resultado es casi lineal y el resto de variables funciona como ruido (los árboles eligen profundidad 1 y el SVM, $\gamma \to 0$). Coincide con la literatura: Tammouch et al. [1] reportan que MI supera a PCA con una variable dominante, y Stübinger et al. [2] encuentran una ventaja decreciente a medida que las casas adoptan ML.

Limitaciones.

- Se usa la cuota de apertura, no la información entre apertura y cierre (alineaciones, lesiones, dinero apostado), que es justo lo que separa a ambas y que no está en los datos.
- El "once titular" es el que el juego asigna a cada club en el snapshot, no la alineación de cada partido, y el snapshot de 2024/25 es de final de temporada (esa temporada es parte del test y el modelo final no usa habilidades).
- Pinnacle cubre solo el 48 % de 2025/26 (temporada del test), así que esa temporada se parece más al consenso.
- Solo hay partidos de liga: el descanso y la congestión no ven copas ni competiciones europeas.
- La mejora por liga no se repite entre validación (Portugal) y test (Turquía): con nueve ligas y unos 600–760 partidos por liga en el test no es una conclusión firme.
- El test holdout son solo dos temporadas (5,999 partidos): sus intervalos son amplios, y el modelo desplegado se entrenó sin esos datos; si se reentrenara con ellos, esa versión ya no tendría evaluación independiente.
- Las diferencias entre modelos son pequeñas (0.001–0.004) frente a la variación entre temporadas ($\pm 0{,}013$), por lo que se interpretan con intervalos y no con valores puntuales.
- La generalización a otras ligas, deportes u otro periodo no está probada.

Consideraciones éticas. Las apuestas pueden causar daño (adicción, pérdidas); este trabajo no es consejo financiero y su resultado apunta justamente a que no hay ventaja rentable demostrable, lo que desaconseja usarlo para apostar. Los datos son públicos (cuotas y ratings profesionales de jugadores, sin datos personales sensibles) y se obtienen respetando sus licencias; el repositorio no redistribuye los datos crudos. No se midió ningún sesgo hacia personas, pero sí un sesgo de cobertura: las ligas con menos historia y las temporadas recientes tienen datos más incompletos.

VIII. Conclusiones

1. El mercado es eficiente respecto a los fundamentos disponibles. El mejor modelo es una regresión logística de dos variables sobre la apertura de Pinnacle (log loss 0.9653 en validación y 0.9651 en el test holdout; $-0{,}0011$ y $-0{,}0016$ frente al mercado, p ajustado 0,004 y 0,012), con el mismo AUC: refina el precio, no aporta información nueva.
2. Ni la plantilla (ni siquiera la del once titular normalizada por liga), ni la forma, ni Elo, ni los goles esperados, ni las 33 habilidades, ni modelos

más complejos mejoran al precio; los tiros a puerta aportan solo sin cuotas.

3. Sin cuotas se predice casi tan bien (70.0 % frente a 71.8 % de acierto del ganador), pero no mejor, y el cierre subsume a la apertura.
4. El backtest no arroja un retorno significativamente positivo y la calibración del mercado depende del método de normalización del margen.
5. No hay concept drift, y la selección de variables por MI o PCA nunca supera a usar todas.

Trabajo futuro. (a) Alineaciones reales y lesiones previas al partido, la información que el mercado incorpora entre apertura y cierre; (b) xG de partidos pasados para las ligas que lo publican, que probablemente ayude sin cuotas pero no con el precio; (c) comparación con modelos de conteo de Poisson [3], [4]; (d) snapshots de habilidades con varias fechas por temporada.

Referencias

[1] I. Tammouch, A. Elouafi, and I. Essadik, "Betting on Machine Learning: Extracting Patterns from Football's Anarchic Odds," 2024.

[2] J. Stübinger, B. Mangold, and J. Knoll, "Machine Learning in Football Betting: Prediction of Match Results Based on Player Characteristics," Applied Sciences, vol. 10, no. 1, art. 46, 2020.

[3] M. J. Dixon and S. G. Coles, "Modelling Association Football Scores and Inefficiencies in the Football Betting Market," Journal of the Royal Statistical Society: Series C (Applied Statistics), vol. 46, no. 2, pp. 265–280, 1997.

[4] D. Karlis and I. Ntzoufras, "Analysis of sports data using bivariate Poisson models," The Statistician, vol. 52, no. 3, pp. 381–393, 2003.

[5] E. S. Epstein, "A scoring system for probability forecasts of ranked categories," Journal of Applied Meteorology, vol. 8, no. 6, pp. 985–987, 1969.

[6] A. Zheng and A. Casari, Feature Engineering for Machine Learning. O'Reilly Media, 2018.

[7] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor, An Introduction to Statistical Learning with Applications in Python. Springer, 2023.

[8] N. Siddiqi, Intelligent Credit Scoring: Building and Implementing Better Credit Risk Scorecards, 2nd ed. Wiley, 2017.

[9] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: a practical and powerful approach to multiple testing," Journal of the Royal Statistical Society: Series B, vol. 57, no. 1, pp. 289–300, 1995.

[10] football-data.co.uk, "Football Data Historical Results and Betting Odds," https://football-data.co.uk/data.php, 2025.

[11] Kaggle, "FIFA / EA Sports FC Player Ratings Datasets (sofifa)," https://www.kaggle.com/datasets/, 2025.