Predicción probabilística de fútbol con y sin cuotas: comparación temporal de modelos y mercado

José Luis Alva Espinoza
Departamento de Computación
Universidad de Ingeniería y Tecnología
Lima, Perú
jose.alva.e@utec.edu.pe

Juan Carlos Ticlia Maqui
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
juan.ticlia@utec.edu.pe

Elmer José Manuel Villegas Suárez
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
elmer.villegas@utec.edu.pe

Joseph Anderson Cose Rojas
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
joseph.cose@utec.edu.pe

Resumen—¿Se puede predecir el resultado de un partido de fútbol mejor que las casas de apuestas? Este trabajo estima la probabilidad de victoria local, empate y victoria visitante en 36.119 partidos de nueve ligas europeas, entre 2014/15 y 2025/26, con dos enfoques de igual importancia. El primero usa las cuotas de las casas como dato de entrada y pregunta si el aprendizaje automático puede mejorarlas. El segundo no mira las cuotas: construye la probabilidad solo con información deportiva (historial de resultados y valoraciones de jugadores del videojuego FIFA/FC) y mide qué tan cerca llega del mercado. Se comparan regresión logística, árboles potenciados, bosques aleatorios, redes neuronales, SVM y combinaciones de modelos, entrenando siempre con el pasado y evaluando en temporadas posteriores. La métrica principal es la pérdida logarítmica (log loss), que premia asignar probabilidades altas a lo que realmente ocurre. Con cuotas, una regresión logística sobre el precio mejora ligeramente al consenso de las casas (0,9652 frente a 0,9664 en validación y 0,9650 frente a 0,9668 en test). Sin cuotas, un promedio de modelos obtiene 0,9777 y 0,9791: recupera el 89,3 % de la ventaja que tiene el mercado sobre una predicción ingenua, sin llegar a superarlo. Ninguno de los dos enfoques demuestra ganancias estables en apuestas.

Index Terms—fútbol, predicción probabilística, cuotas de apuestas, aprendizaje automático, validación temporal, calibración.

I. Introducción y formulación del problema

Antes de cada partido, las casas de apuestas publican cuotas. Una cuota es, en el fondo, una probabilidad: si la victoria de un equipo paga 2,00 por cada sol apostado, la casa estima que ese equipo gana algo menos de la mitad de las veces. Como las casas arriesgan su propio dinero, sus cuotas suelen ser muy precisas y son una referencia difícil de superar.

Este proyecto estudia el problema desde dos lados. En el enfoque con cuotas, el modelo recibe el precio del mercado y la pregunta es si el aprendizaje automático puede corregirlo. En el enfoque sin cuotas, el modelo solo ve datos deportivos (cómo le ha ido a cada equipo y qué tan buenos son sus jugadores) y la pregunta es cuánto se acerca al mercado sin mirarlo; en la práctica funciona como un generador de cuotas propio. Ambos enfoques se evalúan con los mismos partidos, las mismas métricas y el mismo protocolo.

Nos apoyamos en dos trabajos previos. Tammouch et al. [1] predicen partidos de la liga inglesa a partir de las cuotas y comparan métodos para seleccionar variables. Stübinger et al. [2] usan las habilidades individuales de los jugadores y predicen la diferencia de goles. Tomamos ambas ideas, las extendemos a nueve ligas y las evaluamos sin usar nunca información del futuro. El código está disponible en https://github.com/jcarlos-t/MLProject.

I-A. Objetivo y tarea de aprendizaje automático

El objetivo es estimar, antes de cada partido, la probabilidad de cada uno de sus tres resultados posibles. Es una tarea de aprendizaje supervisado de clasificación multiclase con tres clases (victoria local, empate y victoria visitante), en la que interesa la probabilidad de cada clase y no solo la clase más probable. Cada observación es un partido; las entradas son variables conocidas antes de que empiece y la etiqueta es su resultado final.

I-B. Preguntas de investigación

Las dos primeras preguntas corresponden a los dos enfoques; las otras dos analizan ambos a la vez:

- P1 (con cuotas): ¿mejora el aprendizaje automático la probabilidad que ya dan las casas, tanto el consenso de varias casas como Pinnacle?
- P2 (sin cuotas): ¿qué parte de la calidad del mercado se puede reproducir solo con datos deportivos, y cuánto aporta conocer la plantilla además del historial?
- P3: ¿ayudan las técnicas para mejorar un modelo: reducir variables (MI o PCA), combinar modelos (ensembles) o dar más peso a los partidos sorpresivos?

- P4: ¿se mantienen los resultados temporada tras temporada y permiten ganar dinero apostando?

Nuestras hipótesis son que el mercado será muy difícil de superar, que un modelo deportivo podrá acercarse sin igualarlo y que predecir mejor no garantiza ganar dinero.

I-C. Cómo se mide una buena probabilidad

El modelo no entrega un ganador, sino tres probabilidades que suman uno: victoria local (H), empate (D) y victoria visitante (A). Para saber si son buenas usamos como métrica principal la pérdida logarítmica:

$$\mathrm{LL} = -\frac{1}{N}\sum_{i=1}^{N} \log \hat{p}_{i,y_i}, \tag{1}$$

donde $\hat{p}_{i,y_i}$ es la probabilidad que el modelo asignó al resultado que realmente ocurrió en el partido i. Si el modelo dio 60 % al resultado correcto, la penalización es 0,51; si dio 25 %, es 1,39; y si dio solo 5 %, sube a 3,00. Así se castiga mucho estar muy seguro y equivocarse. Un valor menor es mejor. Como punto de partida, un modelo ingenuo que siempre predice las frecuencias históricas (al que llamamos prior) obtiene 1,0720. Las diferencias entre buenos modelos son pequeñas, del orden de milésimas, porque el fútbol tiene mucho azar.

Como apoyo se usan otras medidas. El AUC indica si el modelo ordena bien los partidos, por ejemplo si da más probabilidad de victoria local a los que luego terminan así; 0,5 es azar y 1 es perfecto. El ECE (error de calibración) compara lo que se predice con lo que pasa: si de todos los partidos donde se dijo 30 % de empate terminan empatados cerca del 30 %, el modelo está bien calibrado. También se reporta el accuracy, el porcentaje de partidos donde el resultado más probable fue el correcto, y el RPS [5], que tiene en cuenta que el empate está entre las dos victorias. Preferimos el log loss al accuracy porque el accuracy ignora la confianza: un modelo que da 40 % al favorito y otro que le da 90 % obtienen el mismo acierto, aunque el segundo sea mucho más arriesgado.

II. Datos y análisis exploratorio

II-A. Fuentes y variables

Los resultados y las cuotas provienen de Football-Data [10] y cubren las primeras divisiones de Inglaterra, Alemania, España, Italia, Francia, Países Bajos, Portugal, Turquía y Bélgica. Hay 36.150 partidos de 296 equipos; 31 no tienen ninguna cuota y solo se usan para calcular el historial de los equipos, de modo que quedan 36.119 partidos para comparar modelos. La temporada 2013/14 sirve únicamente para iniciar el historial. Las valoraciones de jugadores salen de cuatro bases públicas del videojuego FIFA/FC [11], que puntúan de 1 a 99 a cada jugador en ritmo, tiro, pase, defensa y otras habilidades.

El Cuadro I resume qué información hay por partido. Es importante distinguir dos tipos: lo que se sabe antes del partido (cuotas, valoraciones, historial) y lo que solo se sabe después (goles, tiros, tarjetas). Estas últimas nunca se usan para predecir el mismo partido; solo sirven para construir el historial de los partidos siguientes. Casi todas las variables son numéricas: continuas, como cuotas, valoraciones y promedios, o discretas, como goles, tiros y tarjetas. Las categóricas son la liga, la temporada, la fecha y los nombres de los equipos, que sirven para ordenar y agrupar los partidos, pero no entran directamente al modelo. La variable objetivo es categórica, con tres valores: H, D y A.

Cuadro I
Información disponible por partido.

Bloque	N.º	Ejemplos
Identificación	5	liga, temporada, fecha, equipos
Resultado (objetivo)	3	H/D/A y goles de cada equipo
Estadísticas del partido	12	tiros, córners, faltas, tarjetas (solo para el historial)
Cuotas	Hasta 4 casas	Bet365, Bet&Win, Pinnacle y William Hill
Historia (construida)	38	Elo, forma, medias recientes, descanso
Plantilla	6	valoración media del once y de la plantilla
Habilidades	33	definición, regate, pase, defensa, portero

II-B. Distribución del resultado

La Fig. 1 resume los datos. La victoria local es el resultado más común (44,4 %), seguida de la victoria visitante (30,7 %) y el empate (25,0 %). Las clases no están muy desbalanceadas, por lo que no se rebalancean: estas proporciones son justamente el prior, la predicción más ingenua posible. A la derecha se ve que casi todos los partidos tienen valoraciones de ambos equipos y que las cuotas de Pinnacle se dejan de usar en la última temporada.

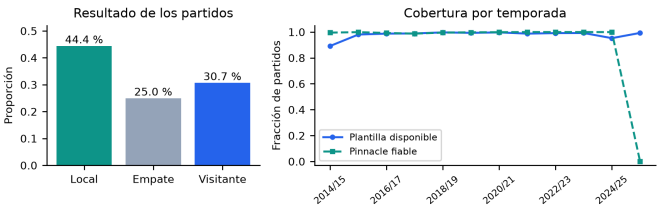


Figura 1. Izquierda: frecuencia de cada resultado. Derecha: fracción de partidos con valoraciones de plantilla disponibles antes del partido y con cuotas fiables de Pinnacle.

II-C. Calidad de los datos

Datos faltantes. La Fig. 2 muestra el porcentaje de partidos sin dato en cada columna. Las cuatro casas consideradas (en verde) tienen cobertura variable; otras casas, como Ladbrokes o Interwetten, faltan en muchos partidos y se descartan. Los faltantes no son aleatorios: dependen de la casa y de la temporada. Pinnacle falta

en el 52 % de 2025/26 y William Hill en el 100 %, respectivamente. William Hill dejó de publicarse; Pinnacle se excluye desde el 23/07/2025 por la advertencia de calidad de la fuente, incluso cuando tiene precios. Por eso las cuotas no se imputan: inventar un precio que nunca existió sería engañoso. Las estadísticas del partido faltan en el 9,7 % de los casos, concentradas en 4 ligas cuyas primeras temporadas no las publican; el modelo las recibe como promedios del pasado, con su indicador de dato faltante. El árbitro y la hora se descartan porque faltan en la mayoría de partidos.

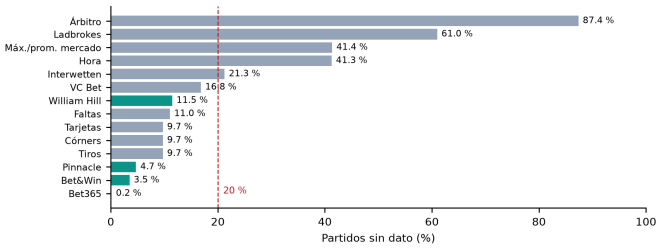


Figura 2. Porcentaje de partidos sin dato por columna (2014/15–2025/26). En verde, las casas usadas para el consenso; la línea roja marca el 20 %.

Valores extremos. La Fig. 3 muestra la dispersión de goles, tiros y cuotas. Con la regla del rango intercuartílico (IQR), que marca como atípico lo que está muy lejos de la mitad central de los datos, aparecen pocos casos en goles y tiros (a lo sumo el 1,4 %) y más en las cuotas (9,3 % en la del visitante), con valores de hasta 13 goles y cuotas de 41. Estos extremos pueden corresponder a goleadas y partidos muy desiguales; su magnitud por sí sola no demuestra que sean errores. Por eso no se eliminan ni se recortan.

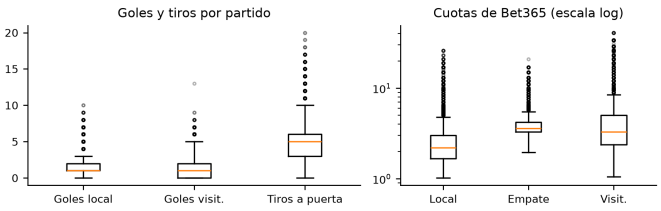


Figura 3. Diagramas de caja de goles, tiros a puerta y cuotas de Bet365. Los puntos son valores extremos según la regla IQR.

II-D. Relaciones entre variables

Las cuotas anticipan el resultado. En la Fig. 4 (izquierda), la probabilidad de victoria local según las casas es mayor cuando el local termina ganando: la mediana es 51 % en esos partidos y 33 % cuando gana el visitante. La valoración del once titular (derecha) muestra el mismo patrón: cuando gana el local, su once es en la mediana 1,8 puntos mejor que el rival; cuando gana el visitante, es −2,5. Ambas fuentes de información apuntan en la misma dirección, aunque con mucha superposición entre las cajas: el fútbol tiene mucho azar.

La Fig. 5 muestra la correlación entre las variables principales, todas expresadas como diferencia entre local y visitante. Hay tres observaciones. Primero, las variables deportivas están muy relacionadas entre sí: el Elo y los puntos recientes tienen correlación 0,95, y el once titular y la plantilla completa, 0,98; por eso muchas son redundantes y conviene regularizar o reducir variables. Segundo, el favoritismo según las cuotas se correlaciona fuerte con el Elo (0,92) y con el once titular (0,87): el mercado ya incorpora la información deportiva, lo que anticipa que añadirla al precio aportará poco. Tercero, el margen de la casa muestra baja correlación lineal con estas variables; esto no descarta asociaciones no lineales ni demuestra ausencia de información sobre el resultado. Además, las probabilidades de las cuatro casas casi coinciden (correlación mínima de 0,997), por lo que conviene resumirlas en un solo consenso.

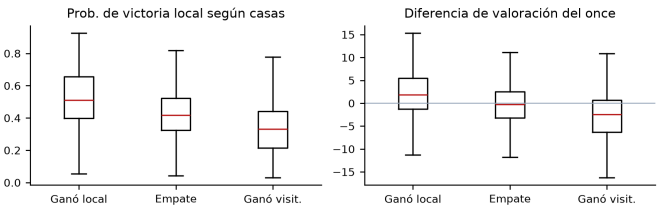


Figura 4. Probabilidad de victoria local implícita en las cuotas (izquierda) y diferencia de valoración del once titular (derecha) según el resultado real. Los valores positivos favorecen al local.

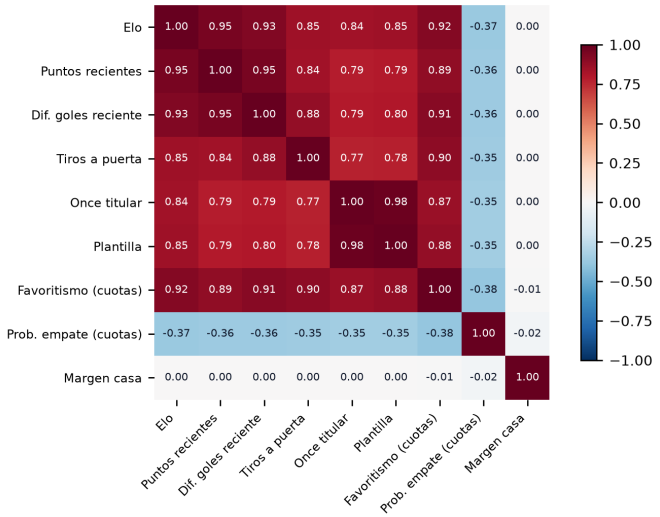


Figura 5. Correlación de Pearson entre variables clave (diferencia local menos visitante). Rojo indica relación positiva y azul negativa.

II-E. Sesgos y fuga de datos

Hay fuga de datos cuando el modelo usa, sin querer, información que no estaría disponible al momento de predecir; el resultado es un modelo que parece muy bueno en los experimentos y falla en la práctica. Identificamos estos riesgos y la forma de evitarlos:

- Estadísticas del propio partido. Goles, tiros o tarjetas solo se conocen al final; se usan únicamente como promedios de partidos anteriores.

- Valoraciones con fecha. Cada partido usa la versión del videojuego publicada antes de esa fecha. Si se usara la versión de fin de temporada, el modelo vería información del futuro, por ejemplo la mejora de un jugador que ocurrió después. El costo es que algunas valoraciones son antiguas: en 2024/25 tienen en promedio más de un año.
- Cuotas. Las cuotas de cierre se publican justo antes del inicio y no se usan como variables. Se usan cuotas previas, capturadas unos días antes y no todas a la misma hora.
- Partición y preprocesamiento. La partición es cronológica, el test no interviene en ninguna decisión y el preprocesamiento se aprende solo con datos de entrenamiento (Sección III).

También hay sesgos que no se pueden eliminar, solo medir y documentar:

- Cobertura desigual. Cuatro ligas no tienen estadísticas de partido en sus primeras temporadas, y la fuente advierte que las cuotas de Pinnacle dejan de ser fiables desde el 23 de julio de 2025; desde esa fecha se usan las demás casas.
- Valoraciones subjetivas. Las valoraciones del videojuego son la opinión de sus analistas, no una medición del rendimiento real, y pueden ser menos precisas en clubes menos conocidos.
- Cambios en el tiempo. El fútbol cambia entre temporadas; por ejemplo, 2020/21 se jugó mayormente sin público. Por eso se evalúa siempre en temporadas posteriores al entrenamiento.

Por último, no se eliminan extremos ni se imputan cuotas, por las razones descritas arriba.

III. Preprocesamiento e ingeniería de variables

III-A. Variables construidas sin mirar el futuro

Todas las variables se calculan en orden cronológico: para predecir un partido solo se usan partidos de fechas anteriores. Para cada equipo se calculan cinco grupos de variables:

- Fuerza Elo: un puntaje que sube al ganar y baja al perder, más o menos según la fuerza del rival.
- Forma: puntos y goles de los últimos cinco partidos, y promedios que dan más peso a los partidos recientes.
- Contexto: días de descanso, cantidad de partidos recientes y tendencia del equipo a empatar.
- Plantilla: valoración media del once titular según el videojuego.
- Habilidades: ataque, pase, defensa y portero de los mejores jugadores del equipo.

El modelo recibe la diferencia entre local y visitante en cada variable, porque lo que importa es qué equipo es mejor y por cuánto.

III-B. De cuota a probabilidad

Una cuota o se convierte en probabilidad con $1/o$. Por ejemplo, cuotas de 2,10, 3,40 y 3,60 dan 0,476, 0,294 y 0,278, que suman 1,048: ese 4,8 % extra es el exceso de probabilidades implícitas (overround), el margen que la casa incorpora a sus precios; no es una ganancia asegurada. Para eliminarlo se divide cada valor entre la suma,

$$p_j = \frac{1/o_j}{\sum_k 1/o_k}, \tag{2}$$

y quedan 45,4 %, 28,1 % y 26,5 %. El consenso es el promedio de estas probabilidades entre las casas con cuotas completas.

III-C. Limpieza dentro de cada entrenamiento

Los valores faltantes se rellenan con la mediana y se marca que faltaban; las variables se llevan a la misma escala y se elimina una de cada par de variables casi idénticas (correlación mayor a 0,95). Todas estas operaciones se aprenden solo con los datos de entrenamiento y después se aplican a los datos de evaluación. Si se calcularan con todos los datos, la mediana o la escala ya incluirían información de los partidos que se quieren predecir, un error conocido como fuga de datos [6]. Por la misma razón, el modelo sin cuotas nunca recibe precios, ni como variable ni de forma indirecta.

III-D. Codificación

No hay variables categóricas que codificar como entrada. La liga y los equipos no entran directamente, sino a través de variables numéricas como la diferencia de Elo. Así se evita crear cientos de columnas one-hot para 296 equipos y el modelo puede predecir partidos de equipos recién ascendidos, de los que tiene poca historia; esos equipos se marcan con una variable binaria (0/1). La variable objetivo se codifica como 0 (local), 1 (empate) y 2 (visitante).

IV. Metodología y modelos

IV-A. Baselines

Para saber si un modelo aporta algo hay que compararlo con algo más simple. Usamos dos baselines. El baseline ingenuo es el prior: asigna a todos los partidos las frecuencias de local, empate y visitante del entrenamiento, sin mirar quién juega. Cualquier modelo útil debe superarlo. El baseline fuerte es el mercado: la probabilidad directa del consenso de casas y la de Pinnacle, una casa conocida por cobrar márgenes bajos, ambas sin ningún aprendizaje. Es la referencia que de verdad importa: el modelo con cuotas debe superarla para justificar el aprendizaje, y el modelo sin cuotas se mide por cuánto se le acerca.

IV-B. Enfoque con cuotas

Además de los baselines, se entrenan modelos que reciben el precio: una regresión logística (LR) con solo dos números del precio de referencia (qué tan favorito es el local frente al visitante y la probabilidad de empate), una LR con el consenso y su margen, y modelos que combinan el precio con las variables deportivas. Compararlos con el baseline del mercado permite separar dos efectos: elegir una buena casa y aprender a corregirla.

IV-C. Enfoque sin cuotas

El segundo enfoque solo recibe las variables deportivas. Se prueban dos estrategias: clasificar directamente el resultado (H, D o A) y, siguiendo a Stübinger et al. [2], predecir la diferencia de goles para luego convertirla en las tres probabilidades.

IV-D. Modelos comparados

En ambos enfoques se prueban los mismos seis modelos. La LR combina las variables de forma lineal y es fácil de interpretar. HGB y XGBoost suman muchos árboles de decisión pequeños, cada uno corrigiendo los errores del anterior. Random Forest promedia muchos árboles entrenados por separado. La red neuronal (MLP) aprende relaciones no lineales con capas de neuronas. La SVM busca la frontera que mejor separa las clases.

Además se prueban tres formas de combinar modelos (ensembles): el promedio simple de sus probabilidades, un promedio ponderado con pesos aprendidos en temporadas anteriores y stacking, donde una LR aprende a combinar las predicciones de los demás. Para reducir variables se prueban la selección por información mutua (MI), que conserva las 5 o 10 variables más relacionadas con el resultado, y el análisis de componentes principales (PCA), que resume muchas variables en pocas combinaciones [1], [7].

El Cuadro II muestra los hiperparámetros que se buscan en cada modelo. Las rejillas son pequeñas a propósito (tres opciones por modelo) y se fijaron antes de ver resultados. Todas controlan el mismo riesgo, el sobreajuste, que es grande en datos con tanto azar. En la LR, C regula cuánto se castigan los coeficientes grandes: un valor pequeño da un modelo más simple. En HGB y XGBoost se limitan los árboles a 1–3 niveles y se usa una tasa de aprendizaje baja (0,05), para que cada árbol corrija poco a poco. En Random Forest, exigir muchos partidos por hoja evita reglas basadas en pocos casos. En la red neuronal se usan pocas neuronas y una penalización alpha alta, y se promedian tres inicializaciones. En la SVM, valores bajos de C y gamma producen fronteras suaves; además se entrena con los 9.000 partidos más recientes, porque su costo crece rápido con el tamaño, y sus salidas se convierten en probabilidades con una calibración aprendida en el último 20 % del entrenamiento.

Cuadro II
Rejillas de hiperparámetros, ordenadas en cada fila de la configuración más regularizada a la menos regularizada. HGB y XGBoost usan tasa de aprendizaje 0,05; Random Forest, 150 árboles.

Modelo	Hiperparámetro	Valores probados
LR	C	0,001; 0,05; 1
HGB	profundidad / iteraciones	1/80; 2/100; 3/150
XGBoost	profundidad / árboles	1/100; 2/150; 3/200
Random Forest	mín. partidos por hoja	200; 100; 30
Red neuronal	neuronas / alpha	16/10; 16/1; 32/1
SVM	C / gamma	0,1/0,001; 1/0,001; 1/0,01

IV-E. Más peso a los partidos sorpresivos

También probamos un enfoque centrado en los datos: dar más importancia durante el entrenamiento a los partidos donde el favorito de las casas no ganó, con peso 2, 3 o 5, o con un peso que crece cuanto más inesperado fue el resultado. Otra variante rebalancea la muestra para que los aciertos y los fallos del favorito pesen igual (50/50). La idea es que el modelo aprenda de las sorpresas, que es justamente donde el mercado se equivoca.

V. Diseño experimental y evaluación

Como el fútbol cambia con el tiempo, los datos no se mezclan al azar: siempre se entrena con el pasado y se evalúa en el futuro [7]. Las temporadas 2014/15 a 2023/24 se usan para desarrollar los modelos y las temporadas 2024/25 y 2025/26 (5.999 partidos) quedan reservadas como test.

Dentro del desarrollo se usa una validación cruzada temporal con ventana que crece (expanding window). No se usa la validación cruzada aleatoria (k-fold) porque mezclaría partidos futuros en el entrenamiento. Para evaluar 2018/19, el modelo se entrena con 2014/15 a 2017/18; para evaluar 2019/20, con 2014/15 a 2018/19; y así hasta 2023/24. Estas seis temporadas forman la validación. Los hiperparámetros, como cuánta regularización usa la LR o cuántos árboles tiene un bosque, se eligen en cada paso por búsqueda en rejilla (Cuadro II) usando las dos temporadas inmediatamente anteriores, también sin mirar el futuro. Entre las configuraciones cuya pérdida queda a no más de 0,0005 del mínimo se toma la más regularizada según el orden de la rejilla.

En cada enfoque se elige el modelo con menor log loss en validación. Entre los modelos cuya pérdida queda a no más de 0,0005 del mínimo, se prefiere el más simple según el orden predefinido. Con esa elección ya fija, los modelos se reentrenan con todas las temporadas de desarrollo y predicen el test sin ningún ajuste adicional.

Métricas. El log loss es la métrica de selección porque mide directamente la calidad de la probabilidad y es una regla de puntuación propia: un modelo obtiene su mejor valor esperado solo si dice las probabilidades que realmente cree, de modo que no se puede mejorar exagerando ni suavizando. El accuracy y el F1 solo miran la clase elegida e ignoran la confianza; el AUC mide la ordenación y el ECE la calibración. Por eso se reportan como complemento, no para elegir modelos.

Para saber si una diferencia es real o fruto del azar se usa bootstrap: se toman 5.000 muestras al azar de semanas completas de partidos y en cada una se recalcula la diferencia de log loss. Con ellas se obtiene un intervalo de confianza del 95 %; si no incluye el cero, la diferencia es consistente. Se remuestrean semanas y no partidos sueltos porque los partidos de una misma jornada comparten condiciones. Los contrastes de validación usan las mismas predicciones con las que se eligió el modelo, así que pueden ser algo optimistas y se leen como diagnósticos

de desarrollo. Como se hacen varias comparaciones a la vez, los valores p se corrigen con el método de Benjamini y Hochberg [9].

VI. Resultados y análisis

VI-A. Con cuotas: ¿se puede mejorar al mercado? (P1)

El Cuadro III muestra el log loss de validación de todos los modelos. Con cuotas, el modelo individual con menor pérdida es la LR que solo recibe los dos números del precio (0,9652). Los modelos que además reciben variables deportivas no la superan, y tampoco la red neuronal ni la SVM, que es la peor de todas. Para saber si la causa es el sobreajuste comparamos el error de entrenamiento con el de validación en dos temporadas, tomando la LR de precio como referencia descriptiva. La SVM apenas muestra una brecha adicional (0,002): su error ya es alto en el entrenamiento, por lo que este diagnóstico no apunta al sobreajuste como explicación principal. La red neuronal y el bosque aleatorio sí se ajustan más al entrenamiento (0,011 y 0,021), aunque el bosque valida bien.

Cuadro III
Log loss de validación (seis temporadas) de cada modelo. Menor es mejor.

Modelo	Con cuotas	Sin cuotas
LR solo precio	0,9652	–
LR consenso y margen	0,9657	–
LR (todas las variables)	0,9699	0,9801
HGB	0,9685	0,9795
XGBoost	0,9685	0,9787
Random Forest	0,9674	0,9791
Red neuronal	0,9732	0,9802
SVM	0,9937	0,9962
Ens.: promedio	0,9674	0,9777
Ens.: ponderado	0,9652	0,9774
Ens.: stacking	0,9738	0,9837
Diferencia de goles	–	0,9795

El Cuadro IV compara los modelos elegidos con los dos baselines, el prior y el mercado, en validación y en test. La LR con cuotas obtiene el menor log loss en ambos periodos. La mejora frente al consenso parece pequeña, pero es consistente: el Cuadro V muestra que en validación su intervalo de confianza no incluye el cero y que el modelo mejora en 5 de las 6 temporadas; en test ocurre lo mismo. Frente a la referencia Pinnacle con respaldo del consenso, la mejora es menor y en validación no es concluyente.

Cuadro IV
Modelos elegidos frente a las referencias. AUC y accuracy en test.

	LL val.	LL test	AUC	Acc. %
Prior	1,0720	1,0750	0,500	43,3
Consenso directo	0,9664	0,9668	0,684	53,8
Pinnacle fiable / respaldo	0,9657	0,9663	0,684	53,8
Modelo con cuotas	0,9652	0,9650	0,683	53,9
Modelo sin cuotas	0,9777	0,9791	0,668	52,5

¿De dónde viene la mejora? El AUC del modelo (0,684) es prácticamente igual al del consenso (0,684): su capacidad agregada de ordenación es similar, y por eso el accuracy también es casi igual. Lo que cambia es la calibración: el ECE baja de 0,0143 a 0,0085. La Fig. 6 lo muestra: los puntos de un modelo bien calibrado caen sobre la diagonal, es decir, cuando dice 40 % el resultado ocurre cerca del 40 % de las veces. En resumen, el modelo con cuotas no descubre información nueva; ajusta ligeramente las probabilidades del mercado para que coincidan mejor con las frecuencias reales.

Cuadro V
Diferencia de log loss e intervalo del 95 %. Un valor negativo favorece al primer modelo. La referencia mixta usa Pinnacle fiable y, en su ausencia, consenso; en 2025/26 usa solo consenso.

Comparación		Δ LL	IC 95 %
Con cuotas vs. consenso	Val.	−0,0012	[−0,0020; −0,0005]
	Test	−0,0018	[−0,0029; −0,0007]
Con cuotas vs. ref. mixta	Val.	−0,0005	[−0,0011; 0,0001]
	Test	−0,0012	[−0,0022; −0,0003]
Sin cuotas vs. consenso	Val.	0,0113	[0,0092; 0,0134]
	Test	0,0123	[0,0085; 0,0164]

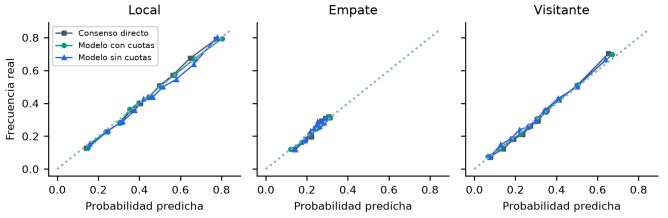


Figura 6. Calibración en validación: frecuencia real frente a probabilidad predicha, en diez grupos de partidos. La línea punteada es la calibración perfecta.

VI-B. Sin cuotas: ¿cuánto se acerca al mercado? (P2)

Sin cuotas, el modelo elegido es el promedio de ocho modelos, con log loss 0,9777 en validación y 0,9791 en test (Cuadros III y IV). Es mejor que cualquier modelo individual, pero queda claramente detrás del mercado, 0,0113 por encima en validación. El promedio de regresores de diferencia de goles supera a varios clasificadores individuales, pero no a los mejores clasificadores ni al ensemble elegido.

La Fig. 7 muestra qué información aporta cada grupo de variables. Con solo el historial de resultados, la LR obtiene 0,9798; al añadir la valoración de la plantilla baja a 0,9786. Añadir las habilidades individuales no mejora más (0,9801): este resultado es compatible con redundancia respecto a la valoración general, sin demostrar que esa sea la única causa.

Para ver si el modelo sin cuotas funciona como un generador de cuotas, la Fig. 8 compara sus probabilidades con las del mercado partido a partido. Los puntos se concentran cerca de la diagonal: la correlación es 0,95 y ambos eligen al mismo favorito en el 90,9 % de los partidos. Otra forma de verlo es medir la distancia: el prior obtiene 1,0720 y el mercado 0,9664; el modelo sin cuotas, con 0,9777, recorre el 89,3 % de ese camino. Es

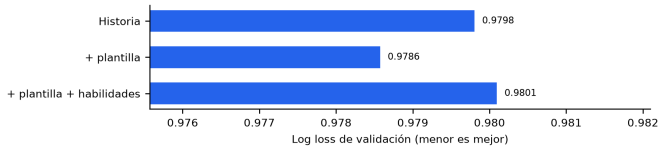


Figura 7. Log loss de validación de la LR sin cuotas al añadir grupos de variables. Menor es mejor.

decir, con información pública y sin mirar precios se reproduce la mayor parte del trabajo de las casas. El tramo restante probablemente depende de información que no tenemos, como lesiones, alineaciones confirmadas y noticias de último momento. Estas probabilidades se pueden convertir en cuotas propias con $1/p$, sin el margen de la casa.

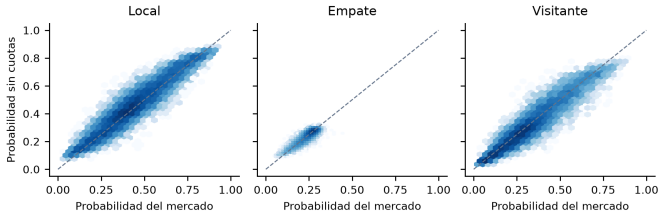


Figura 8. Probabilidad del modelo sin cuotas frente a la del mercado en cada partido de validación. Los colores más oscuros indican más partidos; la diagonal es la igualdad.

VI-C. ¿Qué variables pesan más?

Para saber qué información usa cada modelo, desordenamos al azar un grupo de variables (por ejemplo, todas las de historia) y medimos cuánto empeora el log loss. Si empeora mucho, el modelo dependía de ese grupo. La Fig. 9 muestra el resultado para la LR con todas las variables. Con cuotas, el precio domina por completo: desordenarlo sube el log loss en 0,170, mientras que la historia, el siguiente grupo, solo lo sube en 0,010. Sin cuotas, lo más importante es la historia del equipo (0,081), seguida de las habilidades (0,023). La plantilla aparece baja (0,002) no porque no sirva (la ablación de la Fig. 7 muestra que sí ayuda), sino porque las habilidades repiten casi la misma información: al desordenar la plantilla, el modelo la recupera de las habilidades.

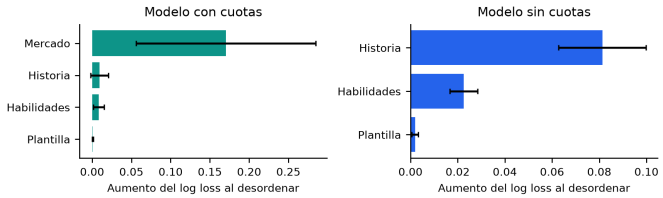


Figura 9. Importancia por permutación de grupos en la LR con todas las variables: aumento medio del log loss al desordenar cada grupo, con intervalo del 95 % entre seis temporadas.

VI-D. ¿Ayudan las técnicas para mejorar un modelo? (P3)

La Fig. 10 compara cada técnica con la LR que usa todas las variables; las barras negativas indican mejora. Con cuotas, la selección MI mejora un poco porque descarta variables deportivas redundantes, pero no alcanza a la LR de solo precio; PCA empeora porque mezcla las variables y diluye la señal del precio. Sin cuotas, reducir variables empeora en casi todos los casos: cada grupo de variables deportivas aporta algo.

Los ensembles dependen del enfoque. Sin cuotas, el promedio reduce la pérdida observada frente a la mejor LR en 0,0009 (intervalo $[-0{,}0018;\ 0{,}0001]$); el intervalo incluye cero, por lo que la mejora no es concluyente. El ponderado obtiene una pérdida algo menor, pero el promedio queda dentro de la tolerancia de 0,0005 y se elige por simplicidad. Con cuotas no ayudan: el ponderado asigna a la LR de solo precio entre el 91 % y el 99 % del peso, así que termina siendo casi la misma LR. El stacking obtiene mayor pérdida en ambos enfoques; este resultado no identifica por sí solo la causa.

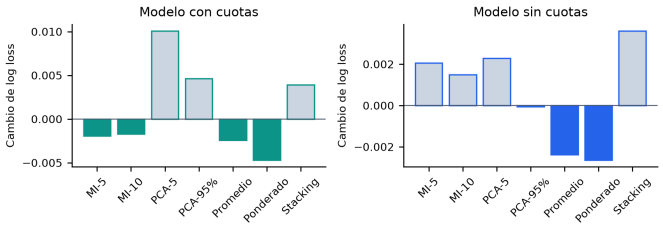


Figura 10. Cambio de log loss de validación frente a la LR con todas las variables. Valores negativos (barras de color) indican mejora.

La Fig. 11 muestra el efecto de dar más peso a los partidos sorpresivos. Las variantes probadas empeoran el log loss agregado; esto no implica empeoramiento en cada temporada: con peso 2, el modelo con cuotas pierde 0,041. El modelo aprende a predecir más empates y sorpresas, pero estas siguen siendo minoría; al exagerar su importancia, se vuelve menos confiable en la gran mayoría de partidos normales.

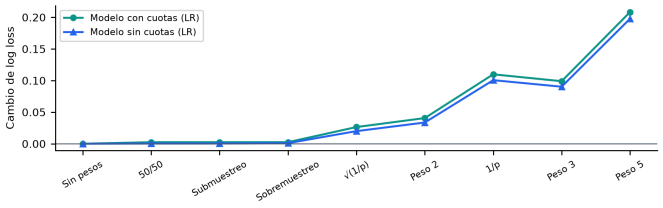


Figura 11. Cambio de log loss de validación al dar más peso o remuestrear los partidos donde el favorito del mercado no ganó.

VI-E. ¿Por qué casi nunca se predice empate?

La Fig. 12 muestra la matriz de confusión: para cada resultado real, qué porcentaje de veces el resultado más probable según el modelo fue local, empate o visitante. El

modelo con cuotas acierta el 82 % de las victorias locales y el 57 % de las visitantes, pero solo el 0,2 % de los empates: elige empate en apenas el 0,1 % de los partidos, aunque ocurren en uno de cada cuatro. No es un error del modelo. Incluso entre equipos de valoración parecida (diferencia de 2 puntos o menos) el empate ocurre el 28,4 % de las veces, frente al 23,1 % en el resto: es más frecuente, pero casi nunca es el resultado más probable. Un modelo bien calibrado le asigna entre 25 y 30 % al empate, y eso basta para que alguna de las victorias sea más probable.

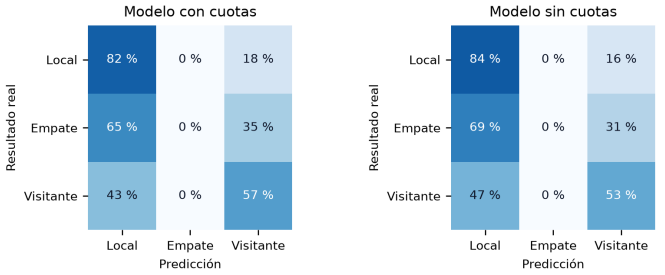


Figura 12. Matriz de confusión en validación (filas normalizadas): porcentaje de cada resultado real según la clase más probable del modelo.

Probamos forzar más empates con reglas de decisión: por ejemplo, multiplicar la probabilidad de empate por 1,5 solo al elegir la clase. Con cuotas, el F1 macro (el promedio del balance entre precisión y recall de cada clase) sube de 0,402 a 0,484 y el recall del empate llega al 36 %, pero el accuracy baja de 53,9 % a 50,9 %. Sin cuotas pasa lo mismo: el F1 sube de 0,393 a 0,474 y el accuracy baja de 53,1 % a 48,8 %. Con cuotas, el multiplicador solo cambia la decisión y conserva el log loss. Sin cuotas, el detector reemplaza la probabilidad de empate: el log loss pasa de 0,9777 a 0,9785 en validación y de 0,9791 a 0,9802 en test. La mejora de F1 no implica mejores probabilidades. Se ganan aciertos de empate a cambio de perder más aciertos de victorias. Como nuestro objetivo es estimar probabilidades y no etiquetas, mantenemos el log loss como métrica principal.

VI-F. Estabilidad y rentabilidad (P4)

La Fig. 13 muestra el log loss por temporada. Las tres curvas suben y bajan juntas: hay temporadas más difíciles para todos. La más clara es 2020/21, jugada mayormente sin público, en la que la victoria local bajó al 40 % frente al 45 % habitual. El modelo con cuotas queda por debajo del consenso en 7 de 8 temporadas, y el modelo sin cuotas siempre queda por encima del mercado. Esta regularidad indica que las conclusiones no dependen de una sola temporada [8].

Por último, simulamos apuestas con una regla fija, decidida antes de ver los resultados: apostar una unidad al resultado cuya ganancia esperada según el modelo supere el 2 % ($p_j\, o_j - 1 > 0{,}02$). La Fig. 14 muestra el retorno por unidad apostada (ROI) con su intervalo. El modelo con cuotas gana 4,7 % en test con Bet365 (572 apuestas),

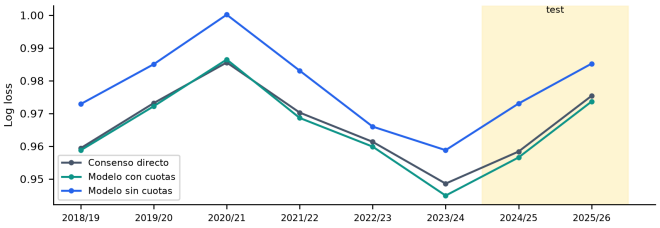


Figura 13. Log loss por temporada; la zona sombreada es el test. Menor es mejor.

pero su intervalo va de -11 % a +20 %: incluye pérdidas, así que no se puede afirmar que gane dinero de forma estable. El modelo sin cuotas pierde (−10,5 %), porque cuando difiere del mercado suele ser el mercado quien tiene razón. El consenso directo contra Bet365 obtiene un ROI alto en validación y negativo en test; el diagnóstico por apuesta muestra ganancias concentradas en resultados de alta cuota. Sin capturas sincronizadas no se puede confirmar su ejecución. Predecir un poco mejor no basta para superar el margen que cobra la casa.

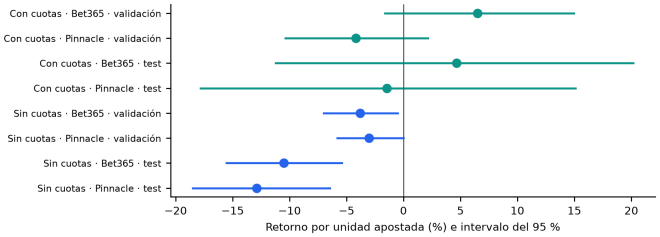


Figura 14. Retorno por unidad apostada (punto) e intervalo del 95 % (línea) con la regla fija. Cero significa no ganar ni perder.

VII. Discusión, limitaciones y ética

En estas ligas y periodos, el mercado constituye una referencia predictiva difícil de superar. El experimento no establece su eficiencia general. Con cuotas, el aprendizaje automático solo logra recalibrar el precio; sin cuotas, los datos deportivos públicos se acercan, pero no lo alcanzan. Tiene sentido: las casas combinan toda la información disponible, incluida la que nosotros no tenemos, y ajustan sus precios con el dinero de miles de apostadores.

Otra lección es que los modelos simples resistieron. Con cuotas, una LR de dos variables ganó a la red neuronal y a la SVM; sin cuotas, un promedio simple ganó al stacking. Con estas rejillas, la complejidad adicional no produjo mejores predicciones. La red neuronal y el bosque aleatorio muestran una brecha adicional entre entrenamiento y validación, compatible con sobreajuste; la SVM apenas la muestra. La comparación entre temporadas también puede reflejar cambios de distribución. También comprobamos que un accuracy parecido puede esconder diferencias de calibración: por eso conviene evaluar probabilidades con log loss y no solo con aciertos.

Limitaciones. No tenemos alineaciones reales ni lesiones: las plantillas son las del videojuego y algunas valoraciones

tienen más de un año. El historial solo incluye partidos de liga, no copas ni torneos europeos. Las cuotas no tienen la hora exacta de captura, por lo que las apuestas simuladas podrían no haber estado disponibles a esos precios. Las búsquedas de hiperparámetros son acotadas. La disponibilidad de cuotas cambia en el test: en 2024/25 Bet&Win y William Hill cubren el 62 % y el 75 % de los partidos, y en 2025/26 el consenso depende solo de Bet365 y Bet&Win. En esa última temporada no se usa Pinnacle, de modo que la LR recibe el consenso en lugar del precio con el que se entrenó y la referencia de Pinnacle coincide con el consenso. En los modelos de diferencia de goles, la conversión a probabilidades se aprende con una temporada apartada y luego el modelo se reentrena con todos los datos, lo que puede desajustar un poco esa conversión. Además, el periodo de test se había evaluado con una versión anterior del sistema, por lo que conviene confirmar los resultados con partidos de 2026/27. Por último, los resultados no se extrapolan a otras ligas ni deportes.

Ética. Los datos se usan con fines académicos y no se redistribuyen. No se usan datos personales sensibles. Los equipos con menos historial o sin valoraciones tienen predicciones de menor calidad, por eso publicamos la cobertura en lugar de ocultarla. Las apuestas pueden generar adicción y pérdidas económicas: este análisis es experimental y no es una recomendación para apostar.

VIII. Conclusiones

Construimos dos predictores con el mismo protocolo: uno que usa las cuotas y otro que solo usa datos deportivos. Las respuestas a las preguntas de investigación son:

P1 (con cuotas). Sí, aunque por poco. Una LR que recalibra el precio reduce el log loss del consenso en 0,0012 en validación (intervalo $[-0{,}0020; -0{,}0005]$, mejora en 5 de 6 temporadas) y en 0,0018 en test. Frente a Pinnacle con respaldo del consenso la mejora es de 0,0005 en validación, no concluyente, y de 0,0012 en test. La mejora observada se acompaña de menor error de calibración, con AUC similar.

P2 (sin cuotas). Un promedio de modelos deportivos reproduce el 89,3 % de la mejora del mercado sobre el prior, con correlación 0,95 con sus probabilidades y el mismo favorito en el 90,9 % de los partidos, pero no lo supera. La plantilla aporta frente al historial solo; las habilidades individuales no añaden más.

P3. MI y PCA no mejoran al mejor modelo de ningún enfoque. El promedio reduce la pérdida observada sin cuotas, aunque su mejora frente a la mejor LR no es concluyente; con cuotas no se observa una mejora clara. Dar más peso a los partidos sorpresivos empeora el log loss agregado de las variantes probadas, aunque no necesariamente en cada temporada.

P4. Los resultados son estables: el modelo con cuotas supera al consenso en 7 de 8 temporadas y el modelo sin cuotas queda detrás del mercado en todas. Predecir mejor no garantiza ganar dinero: el ROI del modelo con cuotas en test (4,7 %) tiene un intervalo que incluye pérdidas, y el del modelo sin cuotas es negativo.

Como trabajo futuro, proponemos incorporar alineaciones y lesiones confirmadas, datos de goles esperados (xG) y valoraciones más frecuentes; probar modelos de conteo de goles [3], [4]; y evaluar el protocolo ya congelado en la temporada 2026/27.

Referencias

[1] I. Tammouch, A. Elouafi, and I. Essadik, "Betting on Machine Learning: Extracting Patterns from Football's Anarchic Odds," in Proc. 7th Int. Conf. Advanced Communication Technologies and Networking (CommNet), 2024, doi: 10.1109/CommNet63022.2024.10793344.

[2] J. Stübinger, B. Mangold, and J. Knoll, "Machine Learning in Football Betting: Prediction of Match Results Based on Player Characteristics," Applied Sciences, vol. 10, no. 1, art. 46, 2020, doi: 10.3390/app10010046.

[3] M. J. Dixon and S. G. Coles, "Modelling Association Football Scores and Inefficiencies in the Football Betting Market," Journal of the Royal Statistical Society: Series C (Applied Statistics), vol. 46, no. 2, pp. 265–280, 1997.

[4] D. Karlis and I. Ntzoufras, "Analysis of sports data by using bivariate Poisson models," Journal of the Royal Statistical Society: Series D (The Statistician), vol. 52, no. 3, pp. 381–393, 2003.

[5] E. S. Epstein, "A scoring system for probability forecasts of ranked categories," Journal of Applied Meteorology, vol. 8, no. 6, pp. 985–987, 1969.

[6] A. Zheng and A. Casari, Feature Engineering for Machine Learning. O'Reilly Media, 2018.

[7] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor, An Introduction to Statistical Learning with Applications in Python. Springer, 2023.

[8] N. Siddiqi, Intelligent Credit Scoring: Building and Implementing Better Credit Risk Scorecards, 2nd ed. Wiley, 2017.

[9] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: a practical and powerful approach to multiple testing," Journal of the Royal Statistical Society: Series B, vol. 57, no. 1, pp. 289–300, 1995.

[10] football-data.co.uk, "Football Results, Statistics & Soccer Betting Odds Data," https://football-data.co.uk/data.php, consultado en noviembre de 2026.

[11] Kaggle, conjuntos de ratings de jugadores: "FIFA Players Dataset" (luisfucros, FIFA 15–22), https://www.kaggle.com/datasets/luisfucros/fifa-players; "EA Sports FC 24 complete player dataset" (stefanoleone992, FC 23–24), https://www.kaggle.com/datasets/stefanoleone992/ea-sports-fc-24-complete-player-dataset; "EA Sports FC 25 + Real Player Data (SoFIFA Merge)" (sametozturkk), https://www.kaggle.com/datasets/sametozturkk/ea-sports-fc-25-real-player-data-sofifa-merge; "FC 26 (FIFA 26) Player Data" (rovnez), https://www.kaggle.com/datasets/rovnez/fc-26-fifa-26-player-data.