Predicción probabilística de fútbol con y sin cuotas: comparación temporal de modelos y mercado

José Luis Alva Espinoza
Departamento de Computación
Universidad de Ingeniería y Tecnología
Lima, Perú
jose.alva.e@utec.edu.pe

Juan Carlos Ticlia Maqui
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
juan.ticlia@utec.edu.pe

Elmer José Manuel Villegas Suárez
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
elmer.villegas@utec.edu.pe

Joseph Anderson Cose Rojas
Departamento de computación
Universidad de Ingeniería y Tecnología
Lima, Perú
joseph.cose@utec.edu.pe

Resumen—Se estudian dos problemas complementarios con la misma evaluación: cuánto añade el aprendizaje a las probabilidades implícitas de las casas de apuestas y cuánto puede predecirse sin consultar sus precios. Se construye una base de 36,119 partidos modelables de nueve ligas europeas, de 2014/15 a 2025/26, con resultados históricos y ratings FIFA/FC. Se corrige la disponibilidad temporal de los ratings, el preprocesamiento fuera de las particiones, la calibración del SVM y la propagación de las configuraciones revisadas. Se comparan clasificación directa, regresión de diferencia de goles, selección MI/PCA, ensembles y reponderación. En seis temporadas de validación, los modelos elegidos con y sin cuotas obtienen log loss 0.9652 y 0.9776, frente a 0.9664 del consenso. En la evaluación revisada de 5,999 partidos obtienen 0.9650 y 0.9793, frente a 0.9668. El predictor sin cuotas reproduce el 89.4 % de la reducción de pérdida del mercado respecto al prior en validación. El test ya había sido observado antes de la auditoría: esta reevaluación no constituye evidencia prospectiva independiente. Se distinguen calidad probabilística, parecido al mercado y rentabilidad; las conclusiones se limitan a los métodos y datos evaluados.

Index Terms—fútbol, clasificación probabilística, cuotas, ratings, validación temporal, calibración, data leakage.

I. Introducción y formulación del problema

I-A. Dos enfoques de igual importancia

El precio de una apuesta resume la expectativa de una casa sobre un resultado. Un sistema predictivo puede utilizar esa expectativa como entrada o construir una propia a partir de los equipos. Son objetivos distintos: el primero pregunta si se mejora una referencia informativa; el segundo busca generar una distribución comparable sin observar el precio. Se presentan en ese orden y se evalúan con los mismos partidos y métricas. El código reproducible está en https://github.com/jcarlos-t/MLProject.

El trabajo combina la selección de variables de Tammouch et al. [1] con el uso de habilidades y regresión de diferencia de goles de Stübinger et al. [2]. No se presupone que un ensemble ni una red neuronal deban ganar. Tampoco se interpreta una accuracy alta como evidencia suficiente de una buena probabilidad: interesa penalizar la confianza equivocada y comprobar la calibración.

I-B. Tarea, métricas y preguntas

Cada partido tiene tres resultados: victoria local H, empate D y victoria visitante A. Se estima un vector de probabilidades que suma uno. La métrica primaria es la pérdida logarítmica,

$$\mathrm{LL} = -N^{-1} \sum_{i} \log \hat{p}_{i,y_i}, \tag{1}$$

que penaliza especialmente asignar poca probabilidad al resultado ocurrido. Como medidas complementarias se utilizan Brier, RPS [5], AUC macro uno-contra-el-resto, accuracy 1X2 y error de calibración ECE. El AUC evalúa ordenación; el ECE compara frecuencias y probabilidades en diez grupos de igual masa. También se publica ECE de igual ancho, sin intercambiar ambas definiciones.

Se conservan cuatro preguntas: P1, estabilidad entre temporadas; P2, aporte de plantilla frente a historia deportiva; P3, comparación MI frente a PCA; y P4, rentabilidad de probabilidades y ensembles. Las hipótesis son que el mercado constituye una referencia difícil, que la plantilla puede complementar la historia y que acertar más no garantiza rentabilidad. Se comprueban en ambas ramas, sin convertir la falta de significación en una prueba de eficiencia universal.

II. Datos y análisis exploratorio

II-A. Fuentes y cobertura

Football-Data [10] proporciona 36.150 partidos originales de nueve primeras divisiones europeas: Inglaterra, Alemania, España, Italia, Francia, Países Bajos, Portugal, Turquía y Bélgica. Se conservan 36,119 con al menos una casa válida; los otros 31 alimentan la historia, pero

no la comparación pareada. Los resultados de 2013/14 inicializan el historial y no se modelan. Los ratings FIFA/FC proceden de cuatro conjuntos públicos [11].

La Fig. 1 muestra el balance de clases y la cobertura. Las estadísticas de tiros, córners, faltas y tarjetas tienen faltantes estructurales; se mantienen hasta el ajuste del imputador. La disponibilidad de plantilla ya no se fuerza al 100 %: se exige que el snapshot preceda al partido. No se eliminan automáticamente las colas de cuotas o goles por ser extremas, porque pueden corresponder a partidos reales.

II-B. Disponibilidad temporal de los ratings

La auditoría detectó que asignar un único snapshot a todos los partidos de su temporada introducía datos posteriores. Se acreditaron las fechas de doce versiones: las antiguas se enlazaron por identificador de actualización SoFIFA y coincidencia de ratings con los metadatos de la misma fuente; las recientes conservan una fecha explícita. Cada equipo utiliza su snapshot verificable más reciente estrictamente anterior a la fecha del partido; si falta, retrocede a una versión anterior del club y, en ausencia de ella, conserva NaN.

Esto evita atribuir el snapshot de julio de 2025 a partidos de 2024/25. Como consecuencia, durante esa temporada se usan en ocasiones ratings anteriores: la antigüedad es una limitación medible, no una imputación encubierta. Los titulares son los asignados por el juego al club, no alineaciones conocidas de cada encuentro. Los nombres de los clubes se armonizan mediante una tabla de identidad, que no aporta resultados deportivos.

II-C. Qué representan las cuotas

Las columnas sin sufijo de cierre son capturas pre-cierre, tomadas después de abrir el mercado; no se las denomina apertura real. La fuente no garantiza que todos los precios sean simultáneos. Además, advierte de la falta de fiabilidad de Pinnacle desde el 23 de julio de 2025. Desde esa fecha se excluye esa casa de la referencia y del consenso; se utilizan las otras casas disponibles. El backtest de Pinnacle se restringe al periodo considerado fiable. La existencia de un número no se confunde con su vigencia.

III. Preprocesamiento e ingeniería de características

III-A. Una historia que solo avanza

Las variables se calculan cronológicamente. Se leen los estados previos de todos los partidos de una fecha y solo después se actualizan con sus resultados. La forma resume los cinco encuentros previos, con respaldo en medias anteriores de la liga cuando la ventana está incompleta. Se añaden Elo, medias exponenciales de puntos y diferencia de goles, tendencia al empate, goles totales previos, descanso y congestión. Esta última solo observa liga: no mide copas ni competiciones continentales.

El prior suavizado de puntos se calcula con resultados anteriores a la fecha. La normalización de plantilla utiliza clubes de snapshots ya disponibles, una vez por club, sin ponderarlos por partidos futuros. Las habilidades resumen los cuatro mejores jugadores de campo en cada atributo y el portero del once del snapshot; se usan diferencias entre equipos. Son valoraciones del juego, no mediciones de rendimiento del partido.

III-B. Transformaciones aprendidas dentro del entrenamiento

Imputación por mediana, indicadores de ausencia, escalado, poda por correlación y MI/PCA se ajustan dentro del entrenamiento de cada partición, tanto interior como exterior. Las columnas totalmente vacías se conservan con valor neutro para mantener el esquema. La poda conserva la primera variable de un par con correlación absoluta mayor que 0,95. MI elige cinco o diez variables; PCA se evalúa con cinco componentes o 95 % de varianza. Las rejillas se fijaron antes de calcular los resultados revisados.

Se diferencia entre una tabla de diagnóstico y una decisión de selección: ninguna columna se elimina por un veredicto descriptivo sin que la transformación correspondiente se aplique y evalúe dentro del pipeline. Esta separación sigue las recomendaciones sobre ingeniería de variables de Zheng y Casari [6]. El predictor puro sin cuotas no utiliza precios para construir entradas, ponderaciones ni calibradores.

IV. Metodología y modelos

IV-A. Primero: modelos con cuotas

Una cuota decimal o_j se transforma en probabilidad mediante $p_j = (1/o_j)/\sum_k (1/o_k)$. Se calcula el promedio de probabilidades de las casas completas y fiables, no el inverso de la cuota promedio. Se comparan el consenso directo, Pinnacle fiable con respaldo, una LR sobre dos variables de referencia, una LR de consenso con margen y modelos con mercado más fundamentos. Así se distingue el efecto de elegir el precio de referencia del efecto de aprender a recalibrarlo.

IV-B. Después: un predictor sin cuotas

La segunda rama recibe solamente historia deportiva, plantilla e individualidades. Se ensaya clasificación directa H/D/A y regresión de diferencia de goles. Para esta última, una función aprendida en una temporada anterior convierte la predicción de goles en tres probabilidades; después el regresor se reajusta con todo el pasado disponible. Se evalúan regresión lineal, RF, HGB, SVR y su promedio lineal/RF/HGB. La elección final se hace por log loss, no por RMSE aislado.

IV-C. Familias comunes, ensembles y ajuste

Ambas ramas comparan LR, HGB, XGBoost, Random Forest, MLP y SVM. La MLP promedia tres semillas, sin parada temprana aleatoria. El SVM se limita a los 9.000 partidos más recientes tras ordenar por fecha y utiliza calibración multinomial en el 20 % posterior del

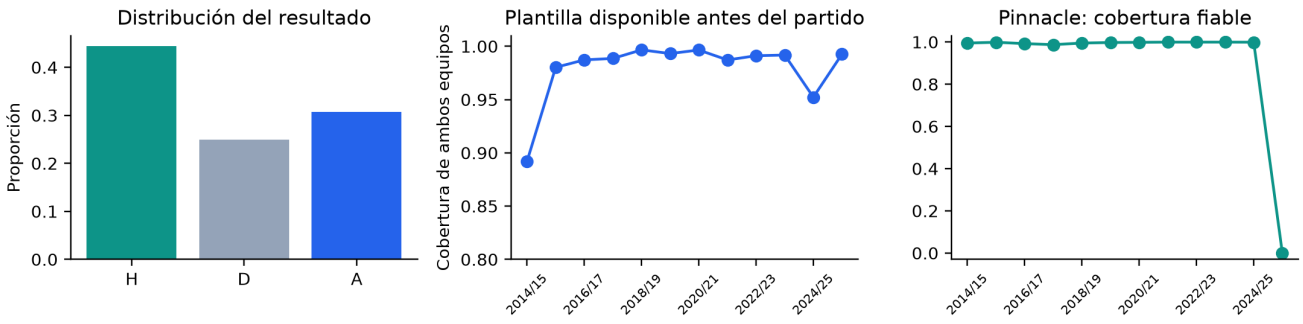


Figura 1. Distribución y cobertura. La cobertura de plantilla exige un snapshot disponible antes del partido; Pinnacle deja de considerarse fiable desde julio de 2025.

entrenamiento, con separación estricta por fecha. Los hiperparámetros de clasificación se ajustan para clasificación, no se copian del problema de regresión.

Cada rama tiene promedio, ponderación convexa y stacking multinomial. Los pesos y el metamodelo se aprenden con predicciones de temporadas anteriores. Se generan predicciones de 2017/18 para inicializar el primer fold de evaluación de 2018/19; así no se sustituye ese fold por una estrategia distinta. La regularización y la comparación temporal siguen el marco de selección de modelos de James et al. [7].

IV-D. Respuesta data-centric

Se da más peso a los errores del favorito del consenso: factores 2, 3 y 5; igualdad de peso total entre aciertos y fallos; inverso de la probabilidad del resultado y su raíz. Se ensayan submuestreo y sobremuestreo 50/50 con tres semillas y recalibración posterior del esquema balanceado. Todos se construyen exclusivamente con resultados de entrenamiento. Cuando una variante deportiva usa estos pesos se denomina entrenamiento guiado por mercado; no reemplaza al predictor sin cuotas puro.

V. Diseño experimental

El entrenamiento y desarrollo comprenden 2014/15–2023/24. Se evalúan seis temporadas exteriores, 2018/19–2023/24, mediante ventana expansiva. Para cada una se elige la configuración utilizando las dos temporadas anteriores como validación interior; cada ajuste interior también utiliza únicamente su pasado. Las dos primeras temporadas modeladas proporcionan historia de entrenamiento antes de las ventanas de ajuste.

La comparación principal usa exactamente los mismos partidos y el log loss agregado por partido. Dentro de 0,0005 del mínimo se prefiere menor complejidad: LR, HGB, XGBoost, RF, MLP, SVM y ensembles; en regresión se mantiene un orden explícito de simplicidad. Se elige un candidato por rama. La selección entre familias a partir de esas seis temporadas conserva sesgo de desarrollo; no se presenta como una validación anidada de todo el proceso científico.

Test revisado. Los resultados del periodo 2024/25–2025/26 ya se conocían antes de esta revisión. Se congelaron las decisiones usando solo train/val y después se generaron predicciones corregidas para ambas ramas. No se afirma que eliminar o reentrenar el modelo convierta esos partidos en evidencia nueva: es una reevaluación sobre un test observado, no una prueba prospectiva independiente.

Los intervalos usan bootstrap por bloques de temporada, año ISO y semana ISO, con 5.000 remuestreos. Incluir el año evita agrupar dos semanas de años distintos durante temporadas extendidas. Se declaran cinco comparaciones principales por partición y se aplica Benjamini–Hochberg [9]; los desgloses por liga son descriptivos. Los indicadores de estabilidad se interpretan como diagnósticos de cambio [8], sin asegurar ausencia de drift porque una tendencia no resulte significativa.

VI. Resultados y análisis

VI-A. Enfoque con cuotas: aportación frente al precio directo

La selección elige LR referencia, con log loss 0.9652 frente a 0.9664 del consenso en validación. En el test revisado, los valores son 0.9650 y 0.9668. El Cuadro I compara las familias; no se equipara una mejora de log loss con una mejora de ordenación. AUC y calibración se examinan de forma complementaria.

La Fig. 2 muestra el rango de resultados en ambos enfoques. Se conservan todas las configuraciones revisadas en las evaluaciones posteriores; los ensembles no reutilizan predicciones de una versión anterior del SVM ni hiperparámetros descartados.

VI-B. Enfoque sin cuotas: construcción de un precio propio

La selección deportiva elige Promedio. Obtiene log loss 0.9776 en validación y 0.9793 en el test revisado; sus accuracy 1X2 son 53.1 % y 52.4 %. Estos porcentajes usan todos los partidos, incluidos empates. El Cuadro II permite contrastar clasificación directa y regresión convertida en probabilidad.

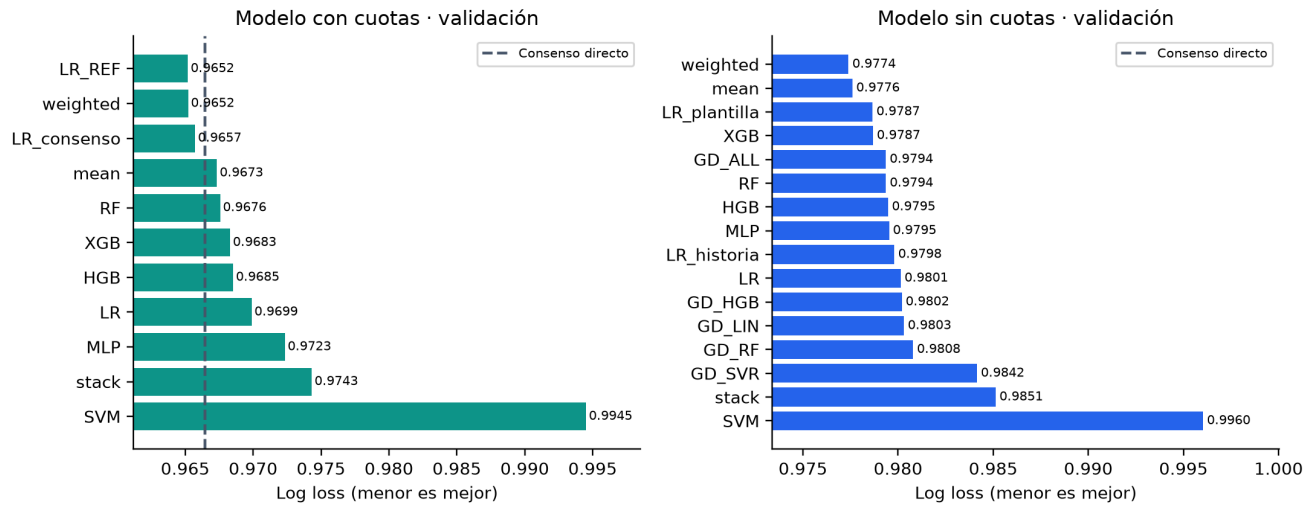


Figura 2. Comparación de familias con cuotas (izquierda) y sin cuotas (derecha), sobre los mismos seis folds. Las escalas se ajustan por panel para hacer visibles las diferencias.

Cuadro I
Modelos con cuotas: predicciones exteriores de validación, con ajustes temporales interiores. LR completa incluye fundamentos; LR de referencia y de consenso solo mercado.

Modelo	LL	AUC	ECE
LR referencia	0.9652	0.684	0.0085
LR consenso	0.9657	0.684	0.0087
LR	0.9699	0.679	0.0088
HGB	0.9685	0.681	0.0127
XGB	0.9683	0.681	0.0123
RF	0.9676	0.681	0.0088
MLP	0.9723	0.675	0.0112
SVM	0.9945	0.655	0.0228

La Fig. 3 responde P2: se compara historia sola, historia con plantilla e historia con plantilla y habilidades bajo la misma familia LR y selección de C. La diferencia observada pertenece a esa ablación; no se atribuye a todas las familias por extensión. La antigüedad de los ratings en 2024/25 puede limitar su valor.

VI-C. Comparación común de probabilidades

El Cuadro III reúne referencias y modelos finales sobre la misma cohorte.

Los contrastes pareados se detallan en el Cuadro IV. Los intervalos miden incertidumbre del remuestreo condicionado a estos procedimientos; no corrigen por sí solos todo el sesgo de exploración.

La Fig. 4 compara calibración por clase y la Fig. 5 la estabilidad temporal (P1). La variación entre temporadas no se interpreta como cambio causado por un único factor: pueden variar fuerza, cobertura y composición de ligas y casas.

Cuadro II
Modelos sin cuotas. GD identifica regresión de diferencia de goles con calibrador temporal; ALL promedia regresión lineal, RF y HGB antes de calibrar.

Modelo	LL	AUC	ECE
LR	0.9801	0.670	0.0160
HGB	0.9795	0.670	0.0133
XGB	0.9787	0.670	0.0137
RF	0.9794	0.669	0.0126
MLP	0.9795	0.669	0.0139
SVM	0.9960	0.653	0.0233
GD lineal	0.9803	0.666	0.0130
GD RF	0.9808	0.666	0.0126
GD HGB	0.9802	0.667	0.0127
GD SVR	0.9842	0.663	0.0135
GD promedio	0.9794	0.667	0.0124

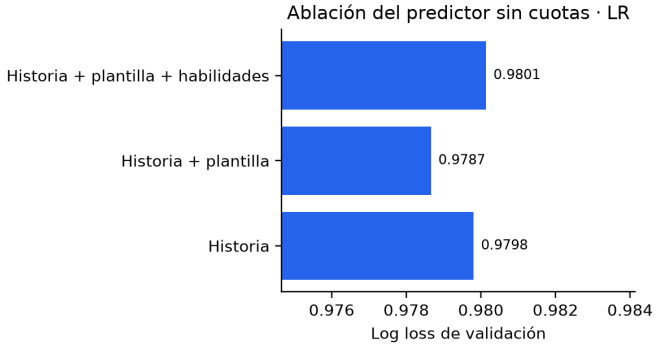


Figura 3. Ablación deportiva con LR. Todas las transformaciones se aprenden dentro del entrenamiento y los ratings preceden al partido.

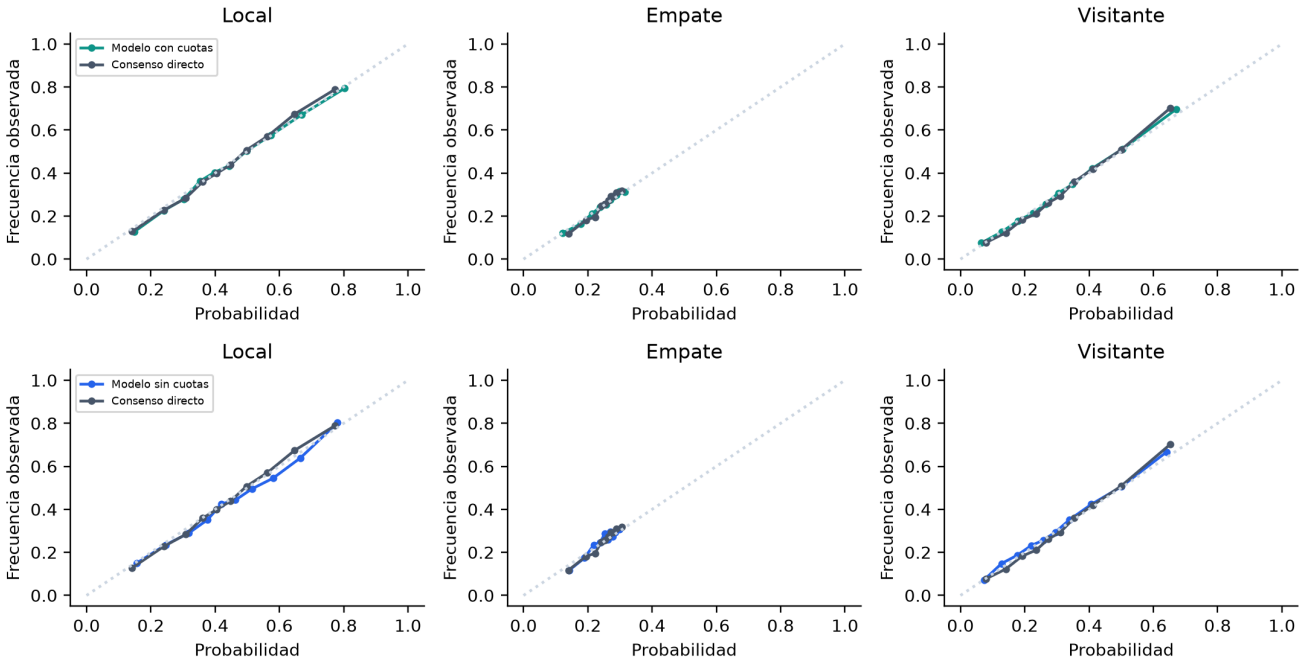


Figura 4. Calibración en validación: modelo con cuotas arriba y sin cuotas abajo, frente al consenso. Diez grupos de igual masa por clase.

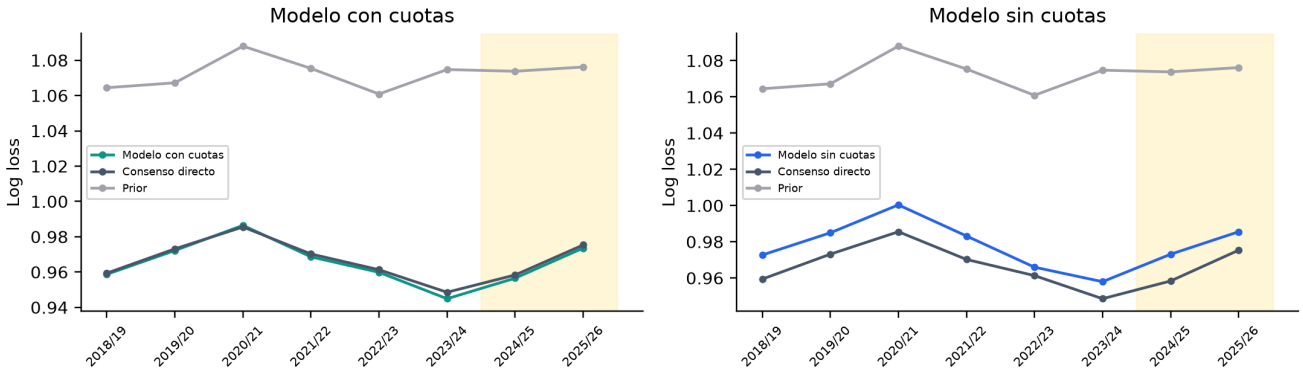


Figura 5. Log loss por temporada para cada modelo y sus referencias. El fondo destaca el test revisado; las predicciones de validación son exteriores.

Cuadro III
Comparación principal. Test revisado significa periodo previamente observado, reevaluado tras congelar las decisiones; ECE de igual masa.

Referencia/modelo	LL val.	LL test	AUC test	ECE test
Prior	1.0720	1.0750	0.500	0.0086
Consenso directo	0.9664	0.9668	0.684	0.0221
Pinnacle fiable / respaldo	0.9657	0.9663	0.684	0.0208
Modelo con cuotas	0.9652	0.9650	0.683	0.0162
Modelo sin cuotas	0.9776	0.9793	0.668	0.0121

Cuadro IV
Diferencias pareadas en test revisado; negativo favorece al primer modelo. Familia de cinco contrastes predefinidos.

Contraste	Δ LL	IC 95 %	p BH
Modelo con cuotas vs. Consenso directo	-0.0018	[-0.0029, -0.0007]	0.001
Modelo con cuotas vs. Pinnacle fiable / respaldo	-0.0012	[-0.0022, -0.0003]	0.013
Modelo sin cuotas vs. Consenso directo	0.0125	[0.0087, 0.0166]	0.001
Modelo sin cuotas vs. Pinnacle fiable / respaldo	0.0130	[0.0092, 0.0172]	0.001
Modelo sin cuotas vs. Modelo con cuotas	0.0143	[0.0102, 0.0185]	0.001

VI-D. ¿Cuánto se aproxima el predictor deportivo al mercado?

En validación, la correlación con el consenso es 0.948 para $\ln(p_H/p_A)$ y 0.867 para la probabilidad de empate; coinciden en el favorito en el 90.9 % de los partidos. La fracción de ganancia sobre el prior es 89.4 %, definida como $(LL_{prior} - LL_{sin})/(LL_{prior} - LL_{mercado})$. Esta razón depende del prior y de la métrica: no significa poseer ese porcentaje de toda la información de una casa. La Fig. 6 muestra el parecido sin confundirlo con igualdad de calidad.

Las probabilidades pueden transformarse en cuotas jus-

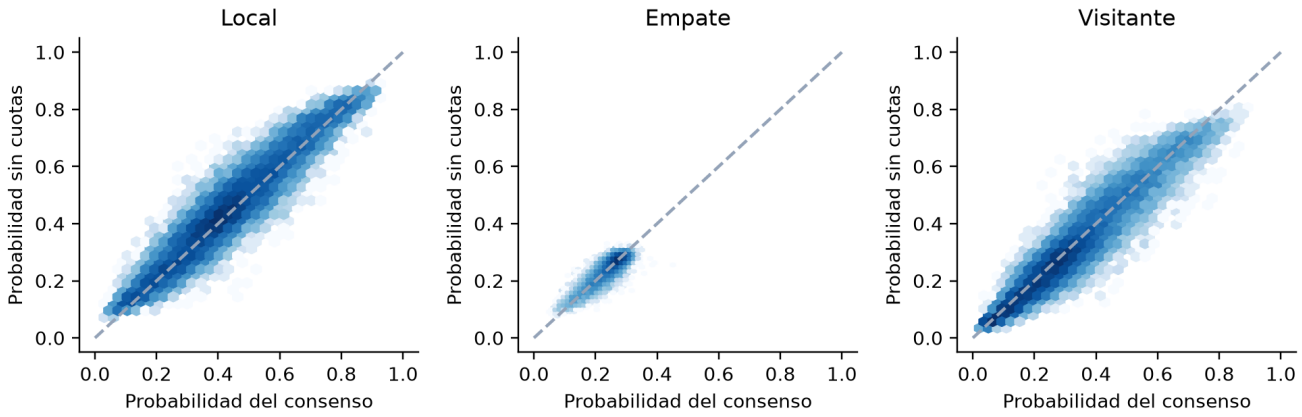


Figura 6. Probabilidades deportivas frente al consenso en validación. La diagonal indica igualdad; la densidad muestra dónde se concentran las discrepancias.

tas mediante $1/p$: estas no incluyen un margen comercial. El acierto del ganador se publica solo como indicador condicionado a partidos que realmente no empataron; la regla siempre elige entre H y A comparando sus probabilidades. No debe confundirse con accuracy 1X2 ni con una regla operativa que conozca de antemano cuáles partidos empatarán.

VI-E. PCA, ensembles y reponderación

La Fig. 7 responde P3 con las mismas alternativas en ambas ramas. Todas significa que no se añade MI/PCA, manteniendo el preprocesamiento común. La Fig. 8 compara ensembles con una inicialización temporal homogénea.

Frente a la LR deportiva con historia y plantilla, el promedio sin cuotas reduce LL en 0.0011 (IC 95 % de la diferencia [-0.0020, -0.0001]; p BH=0.036), con mejora en cinco de seis temporadas. El ponderado logra un valor algo menor, pero el promedio queda dentro de la tolerancia predefinida de 0,0005 y se prefiere por simplicidad. Con cuotas, el ponderado queda prácticamente igual a la LR de referencia y su intervalo incluye cero. Por tanto, el beneficio del ensemble depende de la rama; estos contrastes de desarrollo no sustituyen un test futuro.La Fig. 9 muestra el experimento solicitado por el profesor. El objetivo sigue siendo calibración sobre la distribución real de partidos, no maximizar el acierto en el subconjunto donde el favorito pierde. Se reporta el efecto medio sin afirmar que todos los esquemas empeoren en cada temporada; la recalibración se evalúa en las cinco temporadas para las que existe una anterior con predicciones del mismo procedimiento.

VI-F. Backtest con reglas fijas

La Fig. 10 responde P4. Se apuesta una unidad al lado con mayor $p_j o_j - 1$ si supera 0,02, sin volver a elegir el umbral por ROI. Se comparan los dos modelos y las referencias directas con precios observados de Bet365 y Pinnacle; esta última excluye el periodo de fuente no fiable. Un retorno puntual positivo no basta para declarar rentabilidad cuando el intervalo incluye pérdidas.

VII. Discusión, limitaciones y ética

La comparación con cuotas mide el aporte adicional a un precio ya informativo; el predictor sin cuotas mide cuánto puede construirse con datos deportivos. Tienen valor científico aunque ninguno supere al mercado. Un modelo de menor log loss realiza una predicción probabilística mejor según esa regla; si el AUC cambia poco, eso sugiere que buena parte de la diferencia reside en calibración, sin convertirlo en una identidad demostrada.

Los resultados actuales reemplazan los números anteriores porque se corrigieron entradas y procedimientos, no porque se buscara reproducir una conclusión previa. Cada transformación llega a las predicciones evaluadas y se documenta la configuración por fold. La disponibilidad temporal elimina una fuga, pero puede deteriorar el rendimiento al utilizar plantillas antiguas: ese coste es preferible a presentar una estimación retrospectiva como disponible en su día.

Persisten limitaciones: no hay alineaciones reales ni lesiones; la historia cubre solo liga; las cuotas carecen de sincronización exacta; los ratings de algunas temporadas son antiguos; las rejillas son acotadas; y el test revisado ya había sido observado. Ningún intervalo convierte ese último periodo en validación prospectiva. Una próxima evaluación debería fijar primero el protocolo y esperar partidos nuevos. Tampoco se descarta drift por falta de significación ni se extrapola el resultado a otras ligas o deportes.

Las fuentes se utilizan para fines académicos, sin redistribuir sus CSV crudos. No se modelan datos sensibles de personas. La calidad desigual de cobertura puede perjudicar a equipos con menos historia, por lo que se publica la cobertura en lugar de ocultarla con imputaciones globales. El análisis de rentabilidad es experimental y no constituye recomendación de apuestas.

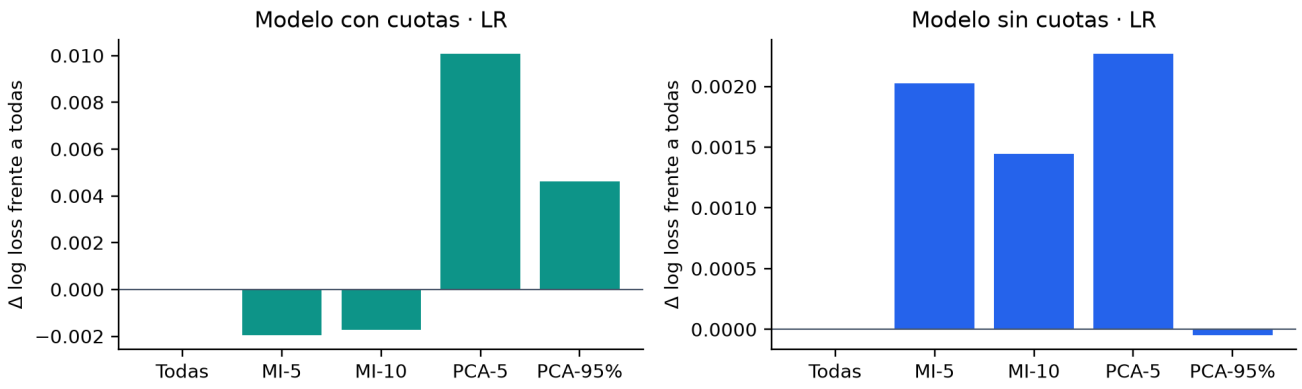


Figura 7. MI frente a PCA en LR para ambos enfoques: diferencia respecto a la LR sin reducción adicional. No se presupone que reducir variables deba mejorar.

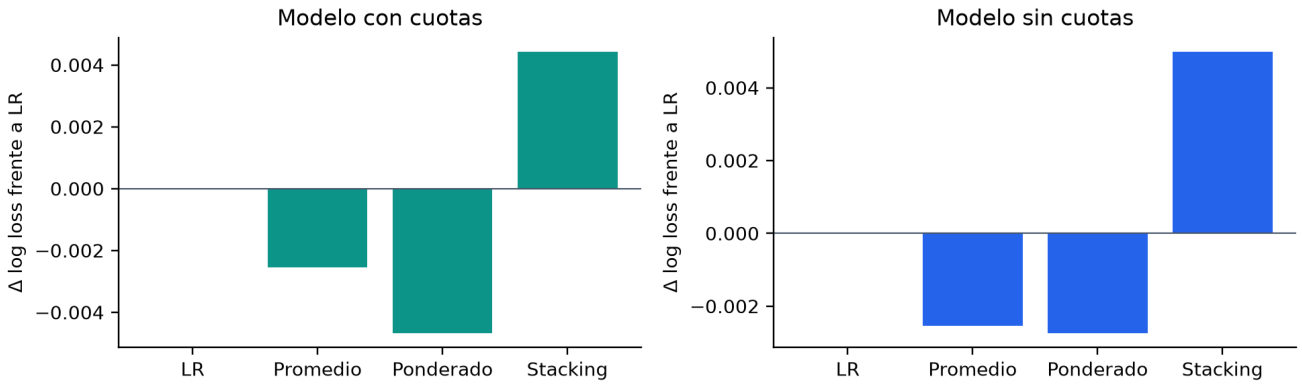


Figura 8. Ensembles frente a LR completa, evaluados en los seis folds con predicciones previas para aprender pesos y stacking.

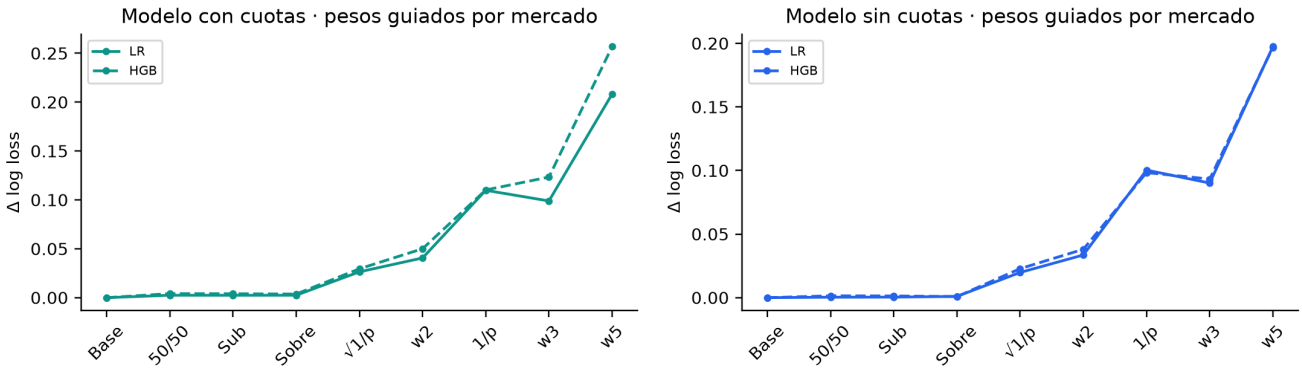


Figura 9. Pesos y remuestreo guiados por errores del mercado. La rama sin entradas de cuotas se identifica como guiada por mercado cuando usa esos pesos.

VIII. Conclusiones

Se entregan dos predictores con un protocolo común. Con cuotas se obtiene log loss 0.9652 en validación y 0.9650 en test revisado; sin cuotas, 0.9776 y 0.9793. La referencia de consenso obtiene 0.9664 y 0.9668. Estas comparaciones permiten valorar por separado el ajuste del precio y la capacidad deportiva propia.

P1 se responde mediante resultados por temporada y diagnósticos de cobertura, sin afirmar ausencia universal de cambio. P2 se responde con una ablación explícita de historia, plantilla y habilidades. P3 se responde comparando MI y PCA sobre los mismos folds y transformaciones internas. P4 se responde con backtests de reglas fijas, intervalos y referencias de mercado: no debe deducirse rentabilidad solo de un promedio positivo. Los ensembles

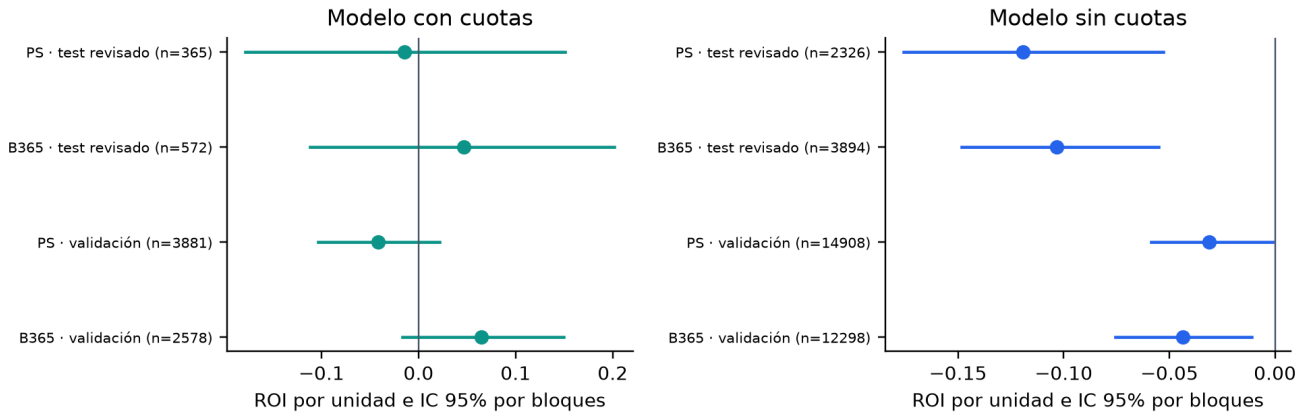


Figura 10. ROI por unidad apostada e intervalos por bloques para los dos modelos. Las cantidades de apuestas dependen de la casa y su cobertura fiable.

y la reponderación se juzgan por sus resultados corregidos en cada rama, sin exigir que superen a un método sencillo.

Como continuación, interesa incorporar snapshots más frecuentes, alineaciones y ausencias verificables, así como datos xG históricos. Los modelos de conteo de goles ofrecen otro contraste [3], [4]. El siguiente test debe ser verdaderamente futuro respecto al protocolo congelado.

Referencias

[1] I. Tammouch, A. Elouafi, and I. Essadik, "Betting on Machine Learning: Extracting Patterns from Football's Anarchic Odds," in Proc. 7th Int. Conf. Advanced Communication Technologies and Networking (CommNet), 2024, doi: 10.1109/CommNet63022.2024.10793344.

[2] J. Stübinger, B. Mangold, and J. Knoll, "Machine Learning in Football Betting: Prediction of Match Results Based on Player Characteristics," Applied Sciences, vol. 10, no. 1, art. 46, 2020, doi: 10.3390/app10010046.

[3] M. J. Dixon and S. G. Coles, "Modelling Association Football Scores and Inefficiencies in the Football Betting Market," Journal of the Royal Statistical Society: Series C (Applied Statistics), vol. 46, no. 2, pp. 265–280, 1997.

[4] D. Karlis and I. Ntzoufras, "Analysis of sports data by using bivariate Poisson models," Journal of the Royal Statistical Society: Series D (The Statistician), vol. 52, no. 3, pp. 381–393, 2003.

[5] E. S. Epstein, "A scoring system for probability forecasts of ranked categories," Journal of Applied Meteorology, vol. 8, no. 6, pp. 985–987, 1969.

[6] A. Zheng and A. Casari, Feature Engineering for Machine Learning. O'Reilly Media, 2018.

[7] G. James, D. Witten, T. Hastie, R. Tibshirani, and J. Taylor, An Introduction to Statistical Learning with Applications in Python. Springer, 2023.

[8] N. Siddiqi, Intelligent Credit Scoring: Building and Implementing Better Credit Risk Scorecards, 2nd ed. Wiley, 2017.

[9] Y. Benjamini and Y. Hochberg, "Controlling the false discovery rate: a practical and powerful approach to multiple testing," Journal of the Royal Statistical Society: Series B, vol. 57, no. 1, pp. 289–300, 1995.

[10] football-data.co.uk, "Football Results, Statistics & Soccer Betting Odds Data," https://football-data.co.uk/data.php, 2025.

[11] Kaggle, conjuntos de ratings de jugadores: "FIFA Players Dataset" (luisfucros, FIFA 15–22), https://www.kaggle.com/datasets/luisfucros/fifa-players; "EA Sports FC 24 complete player dataset" (stefanoleone992, FC 23–24), https://www.kaggle.com/datasets/stefanoleone992/ea-sports-fc-24-complete-player-dataset; "EA Sports FC 25 + Real Player Data (SoFIFA Merge)" (sametozturkk), https://www.kaggle.com/datasets/sametozturkk/ea-sports-fc-25-real-player-data-sofifa-merge; "FC 26 (FIFA 26) Player Data" (rovnez), https://www.kaggle.com/datasets/rovnez/fc-26-fifa-26-player-data.