MACHINE LEARNING · UTEC · PROYECTO FINAL, ETAPA 2

¿Puede un modelo ganarle al mercado de apuestas de fútbol?

Predicción probabilística del resultado 1X2 en nueve ligas europeas (2014/15–2025/26): modelos, evaluación honesta y un resultado negativo bien medido.

36,150 partidos **9 ligas** **12 temporadas** **test holdout 2024–26**

José Luis Alva Espinoza · Juan Carlos Ticlia Maqui · Elmer José Manuel Villegaz Suárez · Joseph Anderson Cose Rojas

EL PROBLEMA

Estimar P(local), P(empate), P(visitante) antes del partido

- **Tarea:** clasificación multiclase probabilística, no solo acertar el ganador.
- **Métrica principal:** *log loss* (regla propia: premia probabilidades honestas). También RPS, Brier, AUC, ECE.
- **Referencia a vencer:** las cuotas de apertura convertidas en probabilidad, el **mercado crudo**.
- **Pregunta central:** ¿hay información —plantilla, forma, Elo, goles esperados, tiros— que el precio **no** tenga?

44.4 %
gana el local

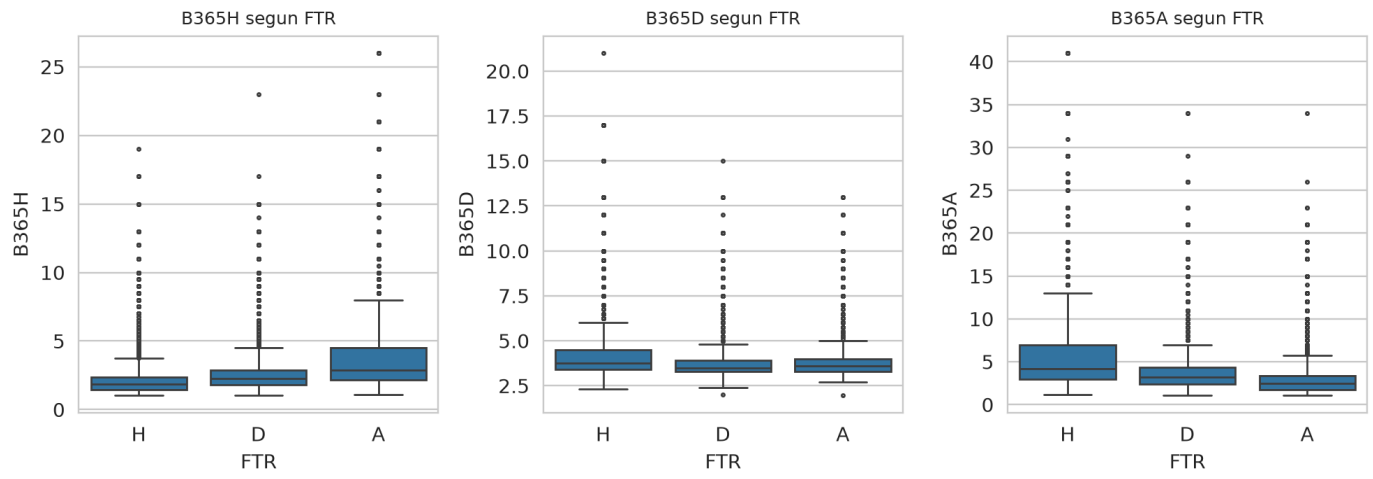
24.9 %
empate (el más difícil de predecir)

30.7 %
gana el visitante

DATOS Y EDA

Dataset propio: cuotas + estadísticas + ratings FIFA/FC

- **football-data.co.uk:** resultados, estadísticas y 159 columnas de cuotas de varias casas.
- **Ratings FIFA/EA FC:** calidad de plantilla y 33 habilidades del once titular.
- **Faltantes sin imputar:** la ausencia de una casa delata la *temporada*, no el partido.
- **Cuotas largas:** son partidos reales muy desequilibrados; no se recortan.



Cuotas de apertura según el resultado real

DISEÑO EXPERIMENTAL

Validación temporal: nunca se mira el futuro

Ventana expansiva: para cada temporada de validación se entrena con todas las anteriores; las dos últimas temporadas son un **test holdout** que no se toca



- **6 folds** de validación (2018/19–2023/24), 18,184 predicciones.
- **Test holdout:** 5,999 partidos (2024/25 y 2025/26), evaluados **una sola vez**, al final.
- **Hiperparámetros** en una ventana disjunta + validación anidada.
- **Sin fugas:** escalado, MI y PCA dentro de cada fold.
- **Bootstrap por bloques** (temporada–semana) para los IC.
- **Benjamini–Hochberg** sobre las comparaciones múltiples.
- **Dos *baselines* sin aprendizaje:** frecuencia base y mercado crudo.

K-fold aleatorio y leave-one-season-out dan 0.0001–0.0014 menos log loss: son optimistas porque ven el futuro

PREPROCESAMIENTO E INGENIERÍA DE CARACTERÍSTICAS

93 variables candidatas, una decisión por evidencia

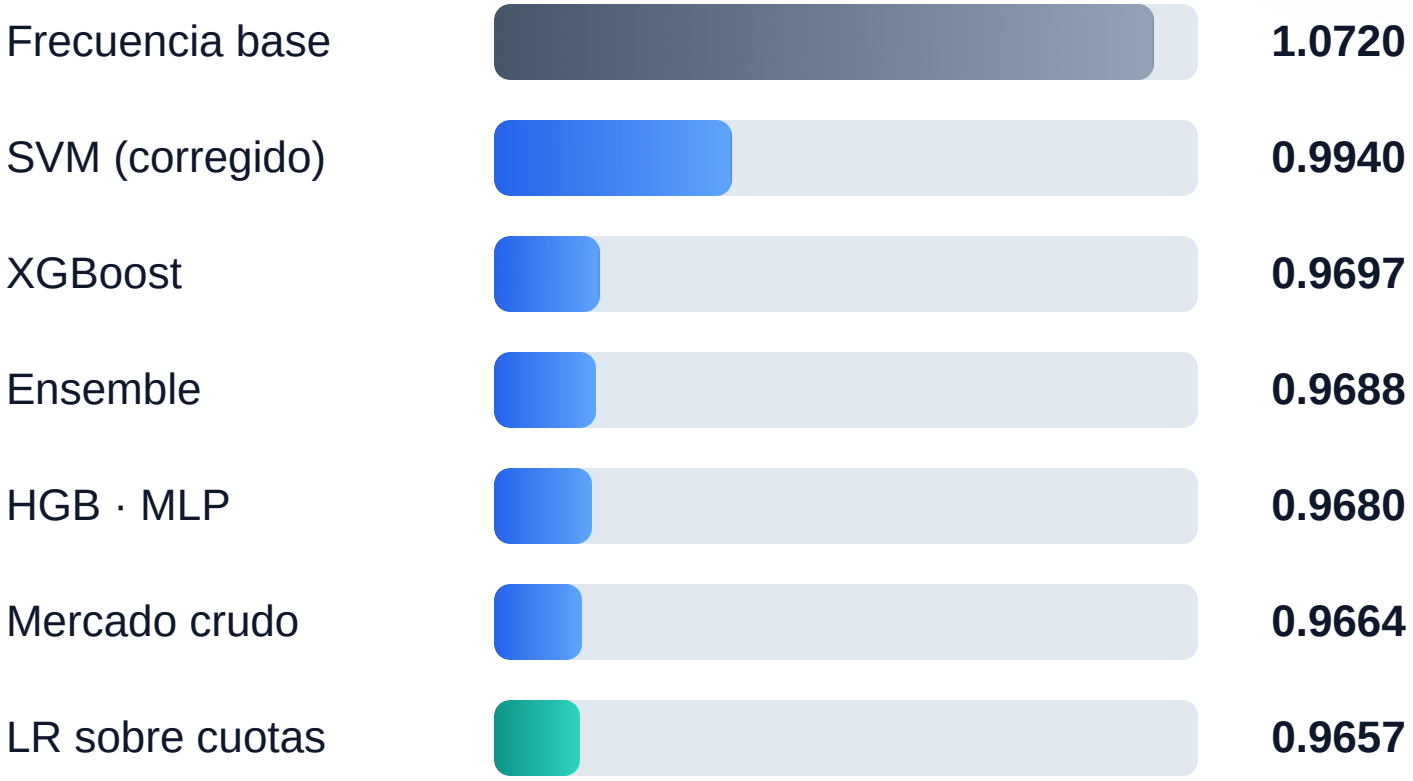
DECISIÓN	RESULTADO
Cuotas → probabilidad	única transformación que importa
Escalado, NaN, asimetría, WOE	no mejoran
Margen de las casas	variable de tiempo (PSI 0.6–1.5): se descarta
Plantilla del once titular	sin ganancia frente al mejor once
Tiros a puerta (SOT10)	**única que ayuda, y solo sin cuotas**

- **27 variables nuevas:** Elo, medias exponenciales, goles esperados al estilo Dixon–Coles, contexto.
- **Sin fuga verificada:** se alteró el resultado de 15 partidos y el Elo previo no cambió.

Siddiqi (WOE/IV/PSI) · Zheng y Casari (transformaciones y leakage)

RESULTADOS · COMPARACIÓN DE MODELOS

La regresión logística sobre las cuotas es la mejor



Log loss medio, 6 temporadas de validación (menor es mejor). El eje empieza en 0.95 para hacer visibles las diferencias.

- A mayor flexibilidad, **peor** resultado.
- Árboles: profundidad óptima **1**. SVM: $\gamma \to 0$.
- La relación precio–resultado es aditiva y casi lineal.

Añadir plantilla, forma o estadísticas a las cuotas no mejora el log loss en ningún modelo

MODELO FINAL

Dos variables, nueve parámetros, mejora real pero pequeña

0.9653
log loss del modelo final (validación)

0.9664
log loss del mercado crudo

−0.0011
IC 95 % [0.0004, 0.0018]
p ajustado 0.004

5 / 6
temporadas en que mejora

- LR sobre **ln(pH/pA)** y **pD** de la apertura de Pinnacle, **C = 0.01**, entrenada solo con 2014/15–2023/24.
- Corrige que el precio es **poco confiado**: favoritos ganan más y *longshots* menos de lo que implica la cuota.
- Regla de elección fijada *antes* de ver resultados: IC que excluye 0 y mejora en al menos 5 de 6 temporadas.
- Coeficientes estables entre temporadas (desvío máximo 0.017).

PENDIENTE DE CALIBRACIÓN DEL MERCADO

local	empate	visitante
1.10	1.27	1.13

> 1 significa que el precio es poco confiado

TEST HOLDOUT · 2024/25 Y 2025/26

La prueba final: datos que nunca participaron en una decisión

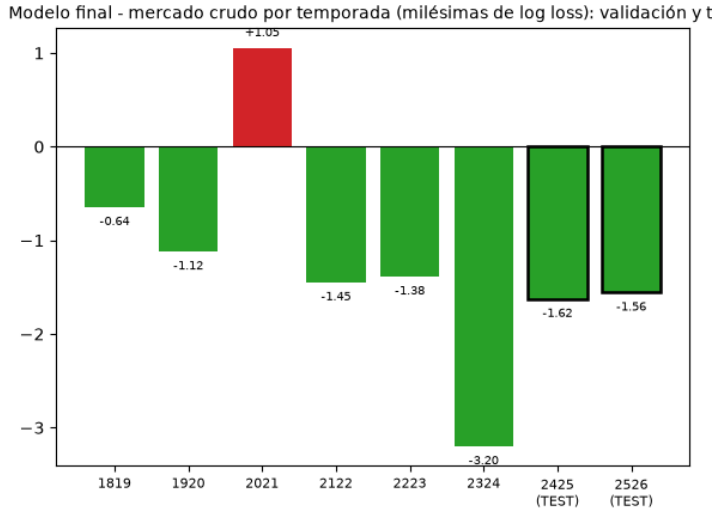
0.9651
log loss del modelo final en test (validación: 0.9653)

0.9667
log loss del mercado crudo en test

−0.0016
IC 95 % [−0.0026, −0.0005]
p ajustado 0.012

2 / 2
temporadas del test en que mejora

- **Sin sobreajuste a la selección:** 0.9651 en test frente a 0.9653 en validación.
- Frente a **Pinnacle cruda** (−0.0009, p ajustado 0.063) y a la LR de tres variables (−0.0001): **sin diferencia significativa**.
- Mismo AUC que el mercado (0.683). En **2025/26** Pinnacle cubre solo 47.8 %, y la ventaja es igual (−0.0016).
- Por liga solo **Turquía** es significativa (en validación fue Portugal): mejora pequeña y repartida.

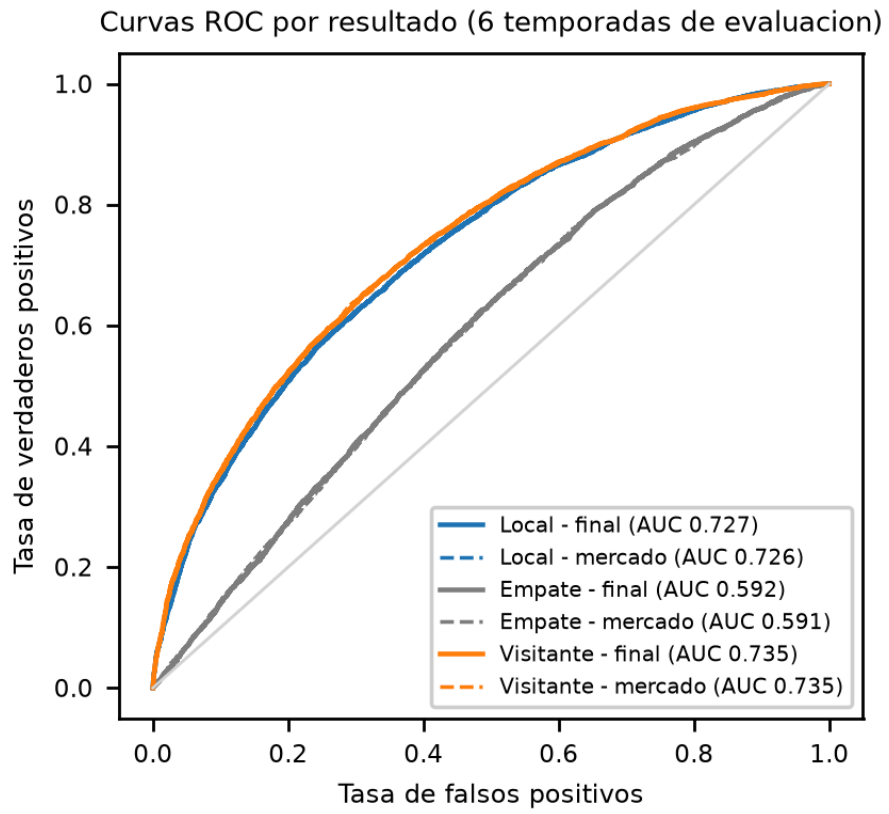


Modelo final − mercado por temporada (milésimas de log loss); con borde, las dos del test

Entrenado solo con train/val (30,120 partidos) · 5,999 partidos en test, evaluados una sola vez

AUC Y CALIBRACIÓN

No ordena mejor los partidos: recalibra el precio



Curvas ROC (validación): modelo final (continuo) y mercado (discontinuo) se superponen

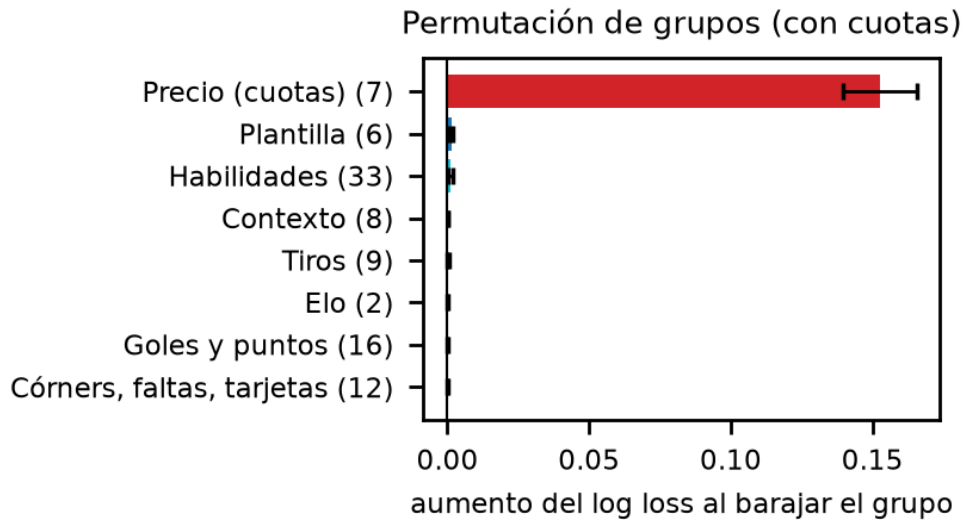
RESULTADO	AUC
Local	**0.727**
Empate	**0.592**
Visitante	**0.735**
Macro	**0.684 (igual que el mercado)**

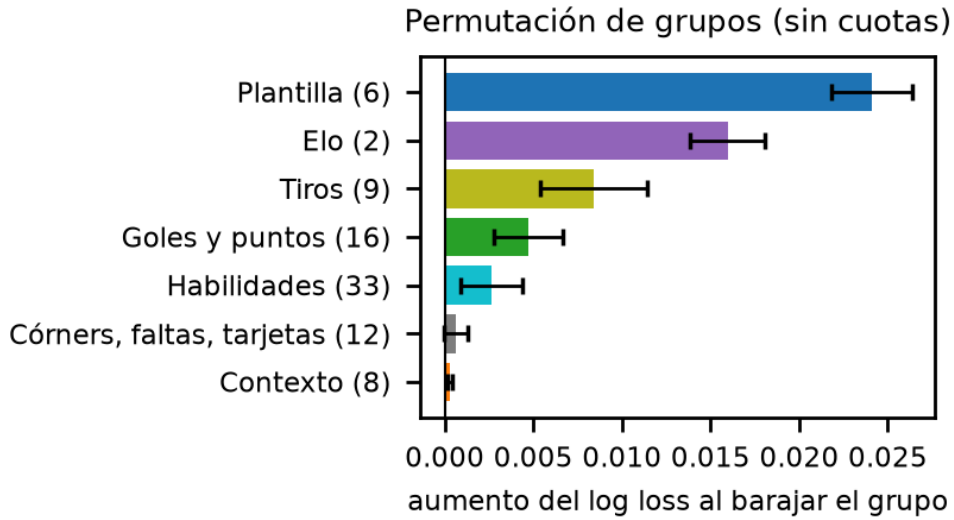
- La ventaja es de **escala** (log loss, ECE 0.0079), no de orden (AUC).
- El empate casi nunca es la clase más probable: **10 veces en 18,184** partidos.

XGBoost, SVM y el ensemble quedan peor calibrados que el propio mercado

¿QUÉ VARIABLES IMPORTAN?

Con cuotas manda el precio; sin cuotas, la fuerza del equipo





- **Con cuotas:** barajar el precio sube el log loss **+0.153**; ningún otro grupo pasa de +0.0013.
- **Sin cuotas:** plantilla **+0.024**, Elo **+0.016**, tiros **+0.008**; los goles recientes solo +0.005.

Permutación por grupos con HGB, 6 temporadas · MI coincide arriba (plantilla y Elo), pero sobrevalora las habilidades (redundantes con la plantilla)

EFICIENCIA DEL MERCADO Y RETORNO

Cuatro pruebas independientes, la misma respuesta

PRUEBA	RESULTADO
Residuo del modelo sin cuotas	$R^2 = -0.0006$
Apertura frente a cierre	0.9658 → 0.9620; el cierre subsume a la apertura
Valor frente al cierre (CLV)	−0.17 pp (lado contrario: −0.02)
Backtest, modelo final (Pinnacle), test	**ROI −2.2 % (IC −9.3 % a +4.9 %)**

El +11.4 % con Bet365 en el test (606 apuestas) tiene IC de −5.5 % a +29.3 %: incluye pérdidas, no es evidencia de rentabilidad.

−2.2 %

ROI del modelo final en test, Pinnacle
IC [−9.3 %, +4.9 %]

+11.4 %

ROI con Bet365 en test: 606 apuestas, IC [−5.5 %, +29.3 %]

Un modelo sin cuotas (con Elo y EWMA) pierde entre 8.4 % y 13.8 % por unidad apostada mientras promete +16 % a +31 %: la «maldición del ganador»

CONCLUSIONES

El mercado es eficiente respecto a los fundamentos disponibles

- Ni plantilla, ni forma, ni Elo, ni goles esperados, ni modelos más complejos **mejoran al precio**.
- El mejor modelo es una **LR de dos variables** que refina el precio: −0.0011 de log loss en validación y −0.0016 en el **test holdout**, mismo AUC.
- No hay *concept drift* y el *backtest* no arroja retorno significativamente positivo.

LIMITACIONES Y ÉTICA

- Apertura, no cierre: faltan alineaciones, lesiones y dinero apostado.
- Test de solo dos temporadas; Pinnacle cubre 47.8 % de 2025/26.
- «Once titular» del *snapshot*, no de cada partido.
- Solo ligas; mejora por liga inestable (Portugal en validación, Turquía en test).
- No es consejo de apuestas: el resultado desaconseja apostar.

Trabajo futuro: xG, alineaciones y lesiones, cuotas de cierre, otros deportes

GRACIAS

¿Preguntas?

Código, notebooks 01–08 e informe en el repositorio público:

github.com/jcarlos-t/MLProject

Informe IEEE · 13 páginas | 8 notebooks reproducibles | validación temporal