MACHINE LEARNING · UTEC · PROYECTO FINAL, ETAPA 2

¿Puede un modelo ganarle al mercado de apuestas de fútbol?

Predicción probabilística del resultado 1X2 en nueve ligas europeas (2014/15–2025/26): modelos, evaluación honesta y un resultado negativo bien medido.

36,150 partidos (36,119 modelables) | 9 ligas | 12 temporadas | test holdout 2024–26

José Luis Alva Espinoza · Juan Carlos Ticlia Maqui · Elmer José Manuel Villegas Suárez · Joseph Anderson Cose Rojas

EL PROBLEMA

Estimar P(local), P(empate), P(visitante) antes del partido

- **Tarea:** clasificación multiclase probabilística, no solo acertar el ganador.
- **Métrica principal:** *log loss* (regla propia: premia probabilidades honestas). También RPS, Brier, AUC, ECE.
- **Referencia a vencer:** las cuotas de apertura convertidas en probabilidad, el **mercado crudo**.
- **Pregunta central:** ¿hay información —plantilla, forma, Elo, goles esperados, tiros— que el precio **no** tenga?

44.4 %
gana el local

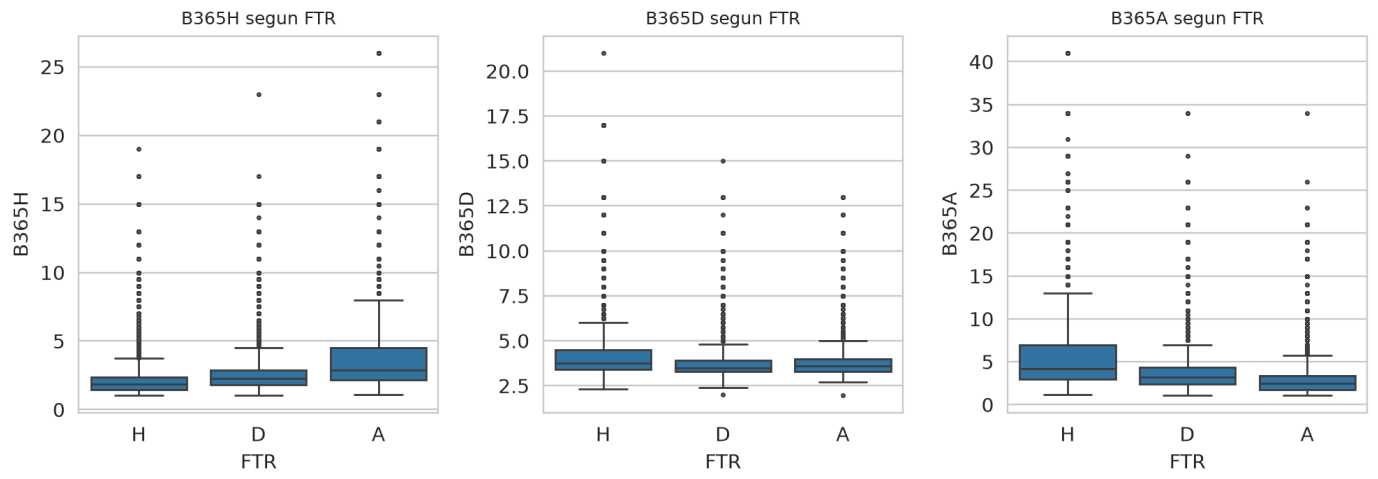
24.9 %
empate (el más difícil de predecir)

30.7 %
gana el visitante

DATOS Y EDA

Dataset propio: cuotas + estadísticas + ratings FIFA/FC

- **football-data.co.uk:** resultados, estadísticas y 159 columnas de cuotas de varias casas.
- **Ratings FIFA/EA FC:** calidad de plantilla y 33 habilidades del once titular.
- **Faltantes sin imputar:** la ausencia de una casa delata la *temporada*, no el partido.
- **Cuotas largas:** son partidos reales muy desequilibrados; no se recortan.



Cuotas de apertura según el resultado real

DISEÑO EXPERIMENTAL

Validación temporal: nunca se mira el futuro

Ventana expansiva: para cada temporada de validación se entrena con todas las anteriores; las dos últimas temporadas son un **test holdout** que no se toca



- **6 folds** de validación (2018/19–2023/24), 18,184 predicciones.
- **Test holdout:** 5,999 partidos (2024/25 y 2025/26), evaluados **una sola vez**, al final.
- **Hiperparámetros** en una ventana disjunta + validación anidada.
- **Sin fugas:** escalado, MI y PCA dentro de cada fold.
- **Bootstrap por bloques** (temporada–semana) para los IC.
- **Benjamini–Hochberg** sobre las comparaciones múltiples.
- ***Baseline*:** regresión logística sobre las cuotas. **Referencias sin aprendizaje:** frecuencia base y mercado crudo.

K-fold aleatorio y leave-one-season-out dan 0.0001–0.0014 menos log loss: son optimistas porque ven el futuro

PREPROCESAMIENTO E INGENIERÍA DE CARACTERÍSTICAS

93 variables candidatas, una decisión por evidencia

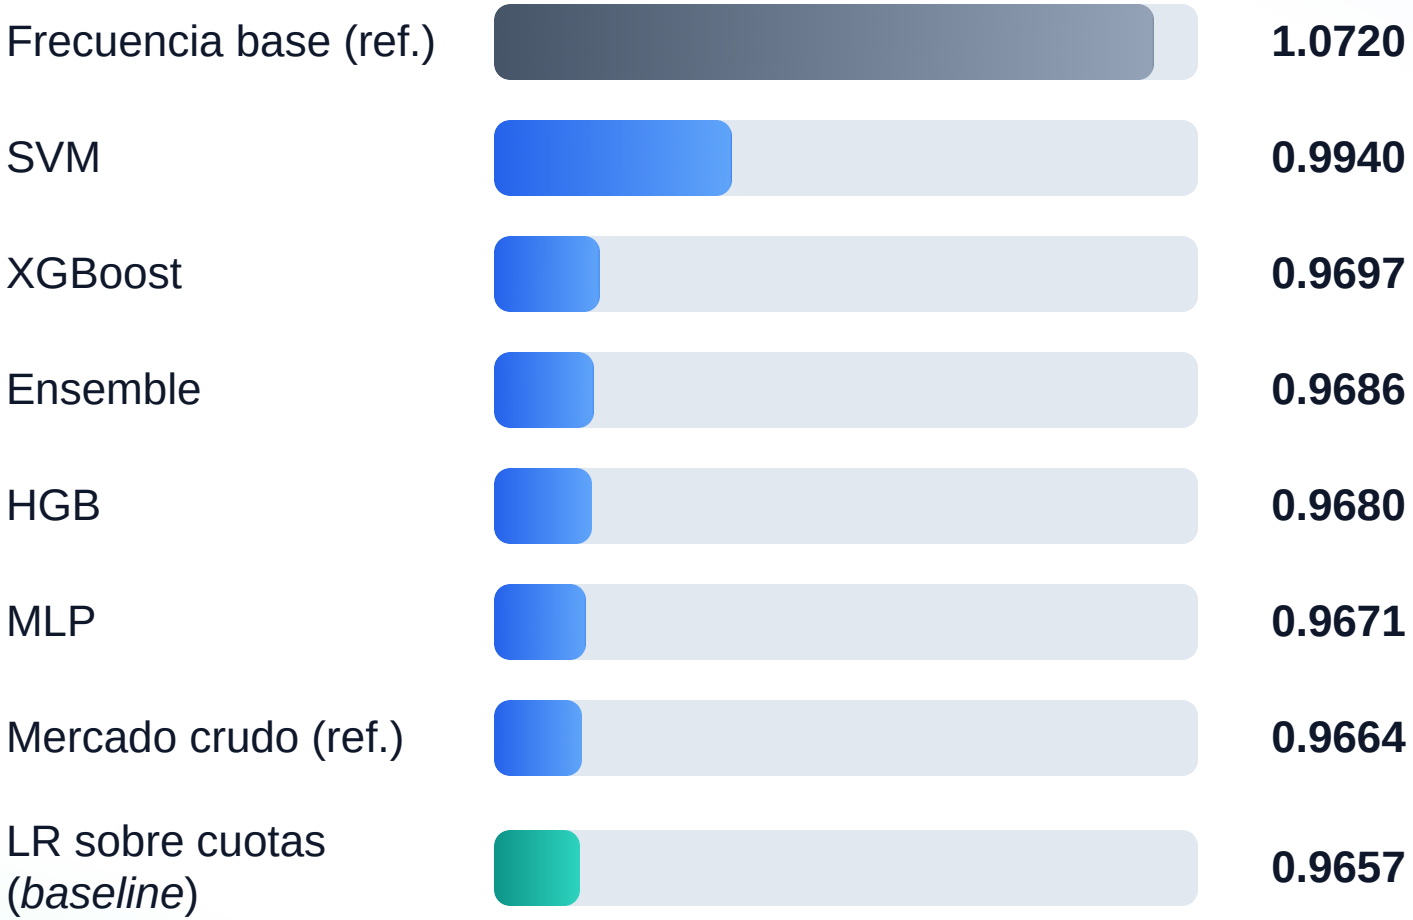
DECISIÓN	RESULTADO
Cuotas → probabilidad	única transformación que importa
Escalado, NaN, asimetría, WOE	no mejoran
Margen de las casas	variable de tiempo (PSI 0.6–1.5): se descarta
Plantilla del once titular	sin ganancia frente al mejor once
Tiros a puerta (SOT10)	**única que ayuda, y solo sin cuotas**

- **27 variables nuevas:** Elo, medias exponenciales, goles esperados al estilo Dixon–Coles, contexto.
- **Sin fuga verificada:** se alteró el resultado de 15 partidos y el Elo previo no cambió.

Siddiqi (WOE/IV/PSI) · Zheng y Casari (transformaciones y leakage)

RESULTADOS · COMPARACIÓN DE MODELOS

La regresión logística sobre las cuotas es la mejor



Log loss medio, 6 temporadas de validación (menor es mejor). «ref.» = referencia sin aprendizaje (no entrena nada). El eje empieza en 0.95 para hacer visibles las diferencias.

- Ningún modelo flexible supera a la LR (el MLP, el mejor de ellos, +0.0014). Con rejillas más amplias el SVM mejora a 0.9840 y sigue sin alcanzarla.
- Árboles: profundidad óptima **1**. SVM: $\gamma \to 0$.
- La relación precio–resultado es aditiva y casi lineal.

Añadir plantilla, forma o estadísticas a las cuotas no mejora el log loss en ningún modelo

MODELO FINAL

Dos variables, nueve parámetros: recalibra la cuota, no aporta información nueva

0.9653
log loss del modelo final (validación)

0.9664
log loss del mercado crudo (consenso de 4 casas)

−0.0011
vs. consenso, IC 95 % [0.0004, 0.0018]
p ajustado 0.004
vs. Pinnacle cruda: −0.0004, no significativo

5 / 6
temporadas en que mejora

- LR sobre **ln(pH/pA)** y **pD** de la apertura de Pinnacle, **C = 0.01**, entrenada solo con 2014/15–2023/24.
- Corrige que el precio es **poco confiado**: favoritos ganan más y *longshots* menos de lo que implica la cuota.
- Regla de elección: IC que excluye 0 y mejora en 5 de 6 temporadas, escrita tras explorar las mismas 6 temporadas (sesgo de selección: el test es la comprobación honesta).
- Coeficientes estables entre temporadas (desvío máximo 0.017).

PENDIENTE DE CALIBRACIÓN DEL MERCADO

local	empate	visitante
1.10	1.27	1.13

> 1 significa que el precio es poco confiado

TEST HOLDOUT · 2024/25 Y 2025/26

La prueba final: datos nunca usados en decisiones

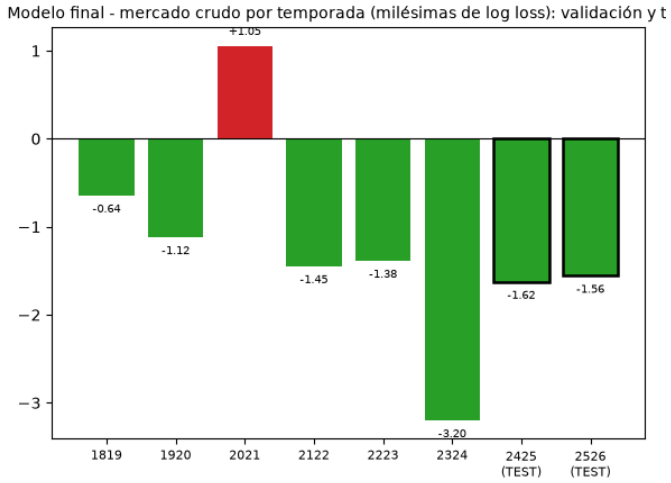
0.9651
log loss del modelo final en test (validación: 0.9653)

0.9667
log loss del mercado crudo en test

−0.0016
vs. consenso, IC 95 % [−0.0027, −0.0006]
p ajustado 0.004

2 / 2
temporadas del test en que mejora

- **Sin sobreajuste a la selección:** 0.9651 en test frente a 0.9653 en validación.
- Frente a **Pinnacle cruda** (−0.0009, p ajustado 0.045, **en el límite**) y al ***baseline*** (−0.0001): **sin diferencia clara**. El consenso es la referencia más débil.
- Mismo AUC que el mercado (0.683). Con **Pinnacle observada** (4,440 partidos) la ventaja es −0.0020; con el **respaldo de consenso** (1,559) es −0.0004, sin diferencia.
- Por liga solo **Turquía** es significativa (en validación, Portugal): mejora pequeña y repartida.

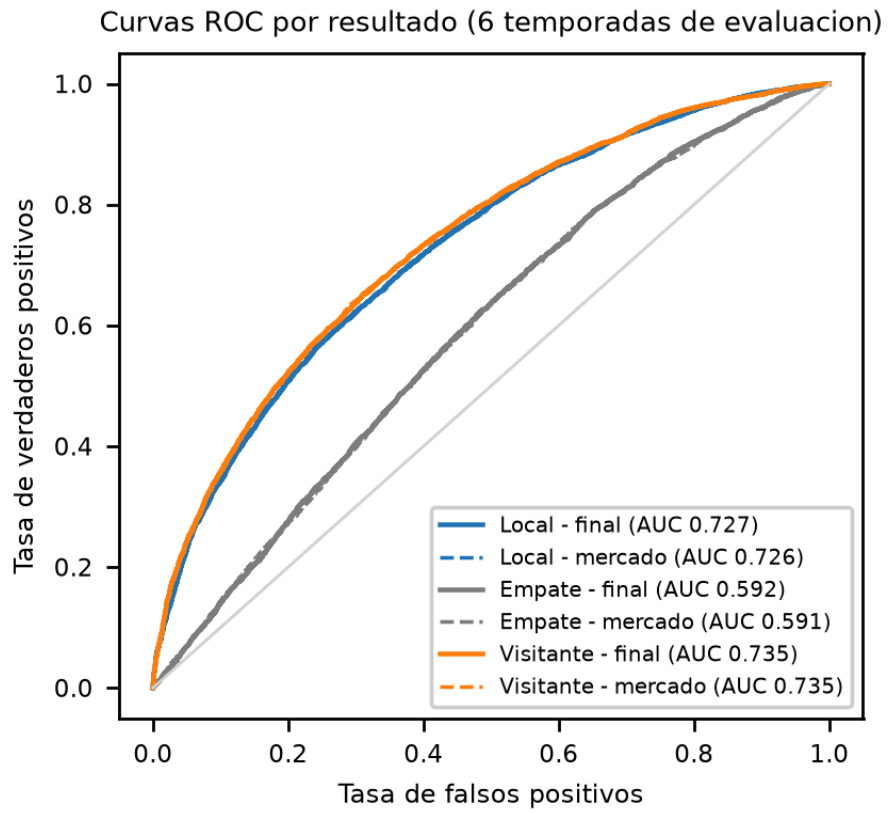


Modelo final − mercado por temporada (milésimas de log loss); con borde, las dos del test

Entrenado solo con train/val (30,120 partidos) · 5,999 partidos en test, evaluados una sola vez

AUC Y CALIBRACIÓN

No ordena mejor los partidos: recalibra el precio



Curvas ROC (validación): modelo final (continuo) y mercado (discontinuo) se superponen

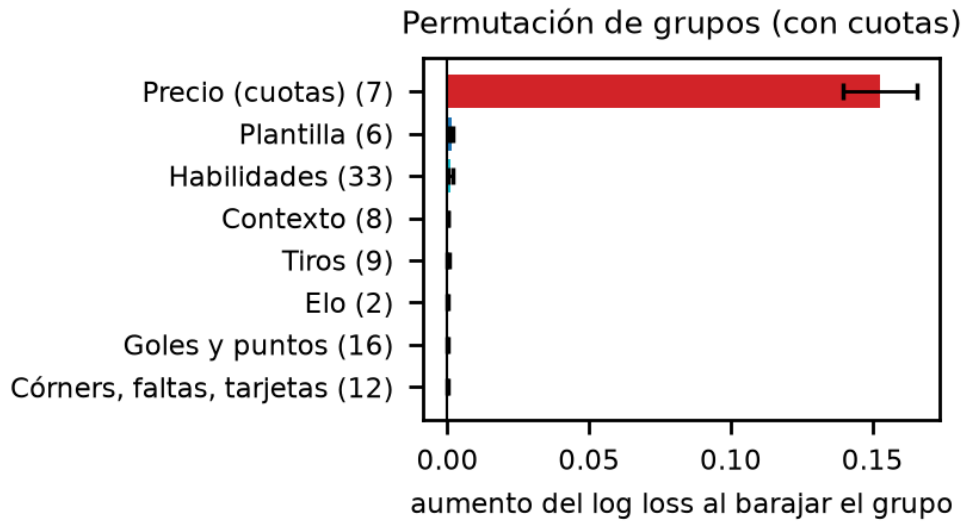
RESULTADO	AUC
Local	**0.727**
Empate	**0.592**
Visitante	**0.735**
Macro	**0.684 (igual que el mercado)**

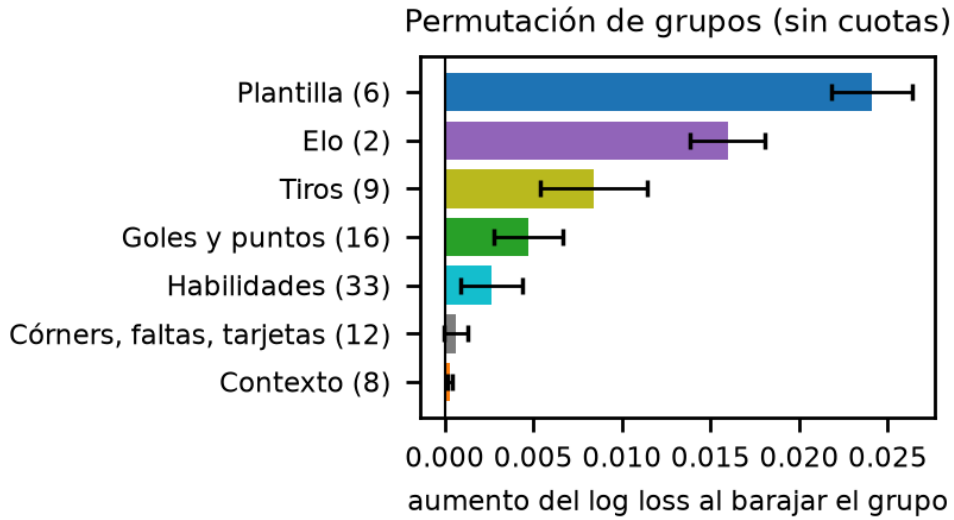
- La ventaja es de **escala** (log loss, ECE 0.0079, tramos de igual ancho), no de orden (AUC).
- El empate casi nunca es la clase más probable: **10 veces en 18,184** partidos.

XGBoost, SVM y el ensemble quedan peor calibrados que el propio mercado

¿QUÉ VARIABLES IMPORTAN?

Con cuotas manda el precio; sin cuotas, la fuerza del equipo





- **Con cuotas:** barajar el precio sube el log loss **+0.153**; ningún otro grupo pasa de +0.0013.
- **Sin cuotas:** plantilla **+0.024**, Elo **+0.016**, tiros **+0.008**; los goles recientes solo +0.005.

Permutación por grupos con HGB, 6 temporadas · MI coincide arriba (plantilla y Elo), pero sobrevalora las habilidades (redundantes con la plantilla)

EFICIENCIA DEL MERCADO Y RETORNO

Cuatro pruebas independientes, la misma respuesta

PRUEBA	RESULTADO
Residuo del modelo sin cuotas	$R^2 = -0.0006$
Apertura frente a cierre	0.9658 → 0.9620; el cierre subsume a la apertura
Valor frente al cierre (CLV)	−0.18 pp (lado contrario: −0.01)
Backtest, modelo final (Pinnacle), test	**ROI −2.6 % (IC −17.9 % a +11.4 %), τ = 0.02 fijo**

El +11.4 % con Bet365 en el test (606 apuestas) tiene IC de −4.1 % a +29.0 %: incluye pérdidas, no es evidencia de rentabilidad.

−2.6 %

ROI del modelo final en test, Pinnacle (482 apuestas) IC [−17.9 %, +11.4 %]

+11.4 %

ROI con Bet365 en test: 606 apuestas, IC [−4.1 %, +29.0 %]

Un modelo sin cuotas (con Elo y EWMA) pierde entre 7.7 % y 12.5 % por unidad apostada mientras promete +15 % a +31 %: la «maldición del ganador»

CONCLUSIONES

El mercado es eficiente respecto a los fundamentos disponibles

- Ni plantilla, ni forma, ni Elo, ni goles esperados, ni modelos más complejos **mejoran al precio**.
- El mejor modelo es una **LR de dos variables** que **recalibra** el precio de Pinnacle: −0.0011 (validación) y −0.0016 (**test**) frente al consenso, pero sin ventaja clara frente a Pinnacle ni al *baseline*; mismo AUC.
- Preguntas de investigación: **P1** sin *concept drift*; **P2** la plantilla ayuda sin cuotas, no con cuotas; **P3** con cuotas gana MI sobre PCA; **P4** el *backtest* no da *value bets* rentables demostrables.

LIMITACIONES Y ÉTICA

- Apertura, no cierre: faltan alineaciones, lesiones y dinero apostado.
- Test de solo dos temporadas; Pinnacle cubre 47.8 % de 2025/26; sesgo de selección en validación.
- «Once titular» del *snapshot*, no de cada partido.
- Solo ligas; mejora por liga inestable (Portugal en validación, Turquía en test).
- No es consejo de apuestas: el resultado desaconseja apostar.

Trabajo futuro: xG, alineaciones y lesiones, cuotas de cierre, otros deportes

GRACIAS

¿Preguntas?

Código, notebooks 01–08 e informe en el repositorio público:

github.com/jcarlos-t/MLProject

Informe IEEE · 9 páginas | 8 notebooks reproducibles | validación temporal