Predecir fútbol con y sin cuotas

Dos preguntas, el mismo estándar de evaluación.

Con cuotas

¿Qué añade un modelo al precio del mercado?

Sin cuotas

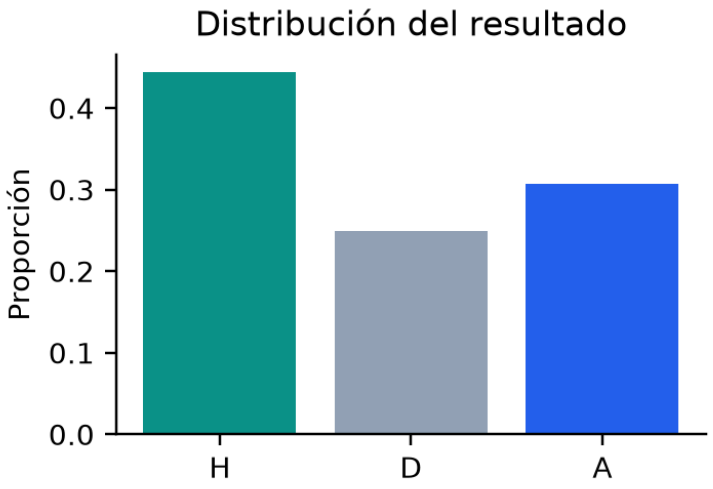
¿Qué probabilidades podemos construir con información deportiva?

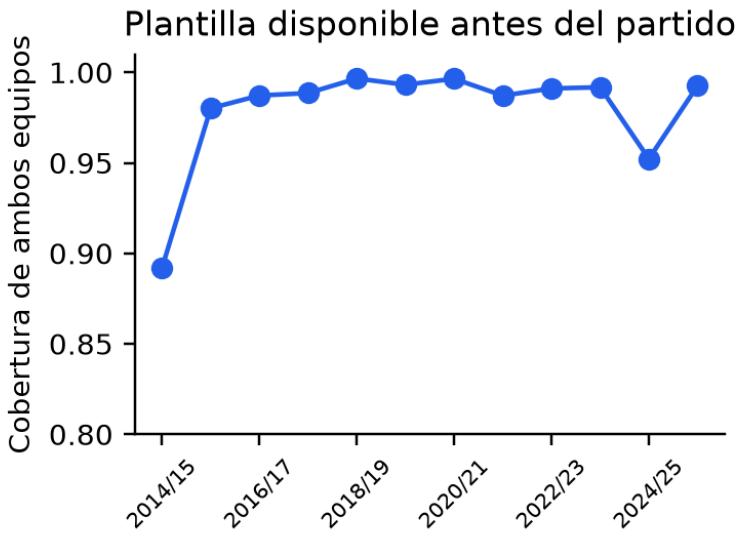
José Luis Alva · Juan Carlos Ticlia · Elmer Villegas · Joseph Cose

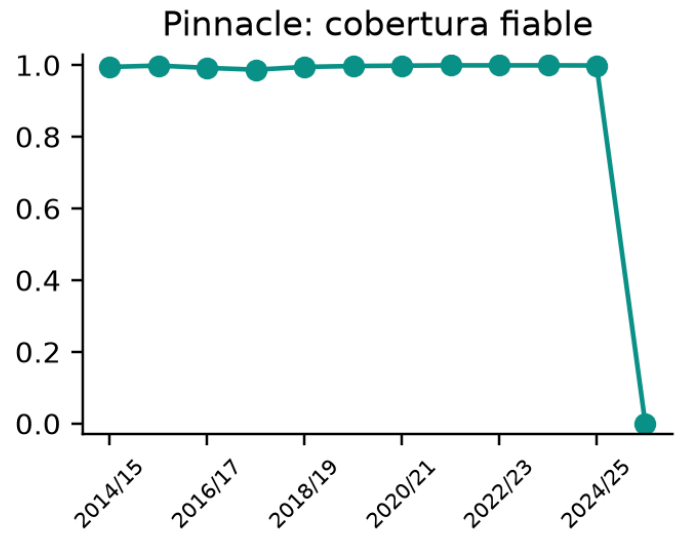
Comparar probabilidades, no solo aciertos

- Salida: P(local), P(empate), P(visitante).
- **Log loss:** penaliza la confianza equivocada.
- **AUC:** mide ordenación; **ECE:** calibración.
- El acierto del ganador excluye empates reales: no es accuracy 1X2.

Datos con disponibilidad histórica acreditada







36.150 partidos originales; 36.119 comparables. Ratings anteriores a cada partido, con faltantes y antigüedad visibles.

Entrenar con pasado y documentar el test observado

2014/15–2017/18: historia y ajuste inicial

2018/19–2023/24: seis folds exteriores; ajuste interior con pasado

2024/25–2025/26: reevaluación tras congelar decisiones

- Imputación, escalado, poda y selección dentro de cada entrenamiento.
- El test ya fue observado: reentrenar no lo vuelve desconocido.

Un experimento común para dos entradas distintas

Mercado + fundamentos

Consenso y Pinnacle fiable; comparación directa sin aprendizaje.

Solo fundamentos

Elo, forma, plantilla, habilidades y contexto histórico.

LR · HGB · XGBoost · RF · MLP · SVM

Sin cuotas: también diferencia de goles convertida a probabilidades.

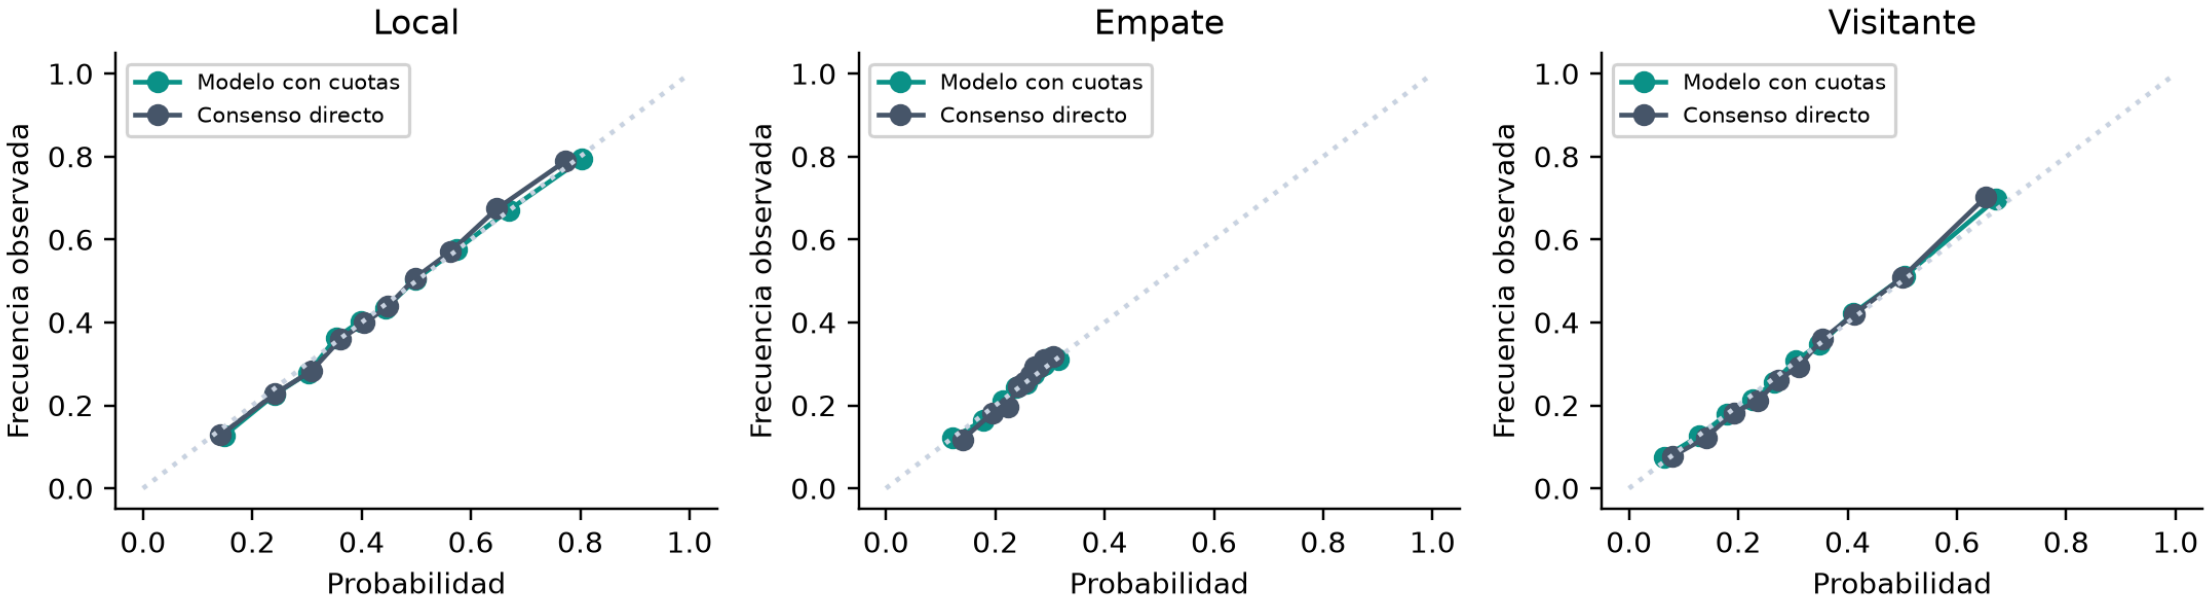
Con cuotas: medir qué añade el aprendizaje

Elegido: LR referencia

Modelo / referencia	Log loss	AUC	ECE masa
Consenso directo	0.9664	0.6840	0.0143
Pinnacle fiable / respaldo	0.9657	0.6847	0.0138
Modelo con cuotas	**0.9652**	**0.6844**	**0.0085**
Modelo sin cuotas	**0.9776**	**0.6716**	**0.0151**

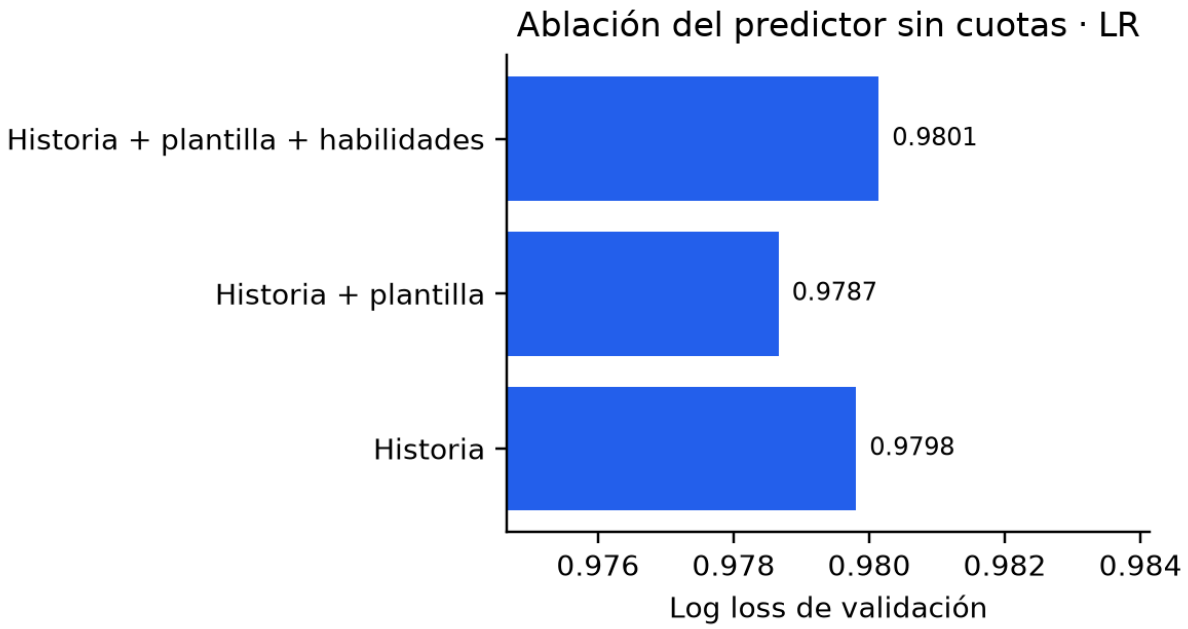
En validación: 0.9652 frente a 0.9664 del consenso.

Con cuotas: pérdidas, ordenación y calibración



Una mejora de log loss no implica necesariamente ordenar mejor: contrastamos también AUC y calibración.

Sin cuotas: construir el predictor deportivo

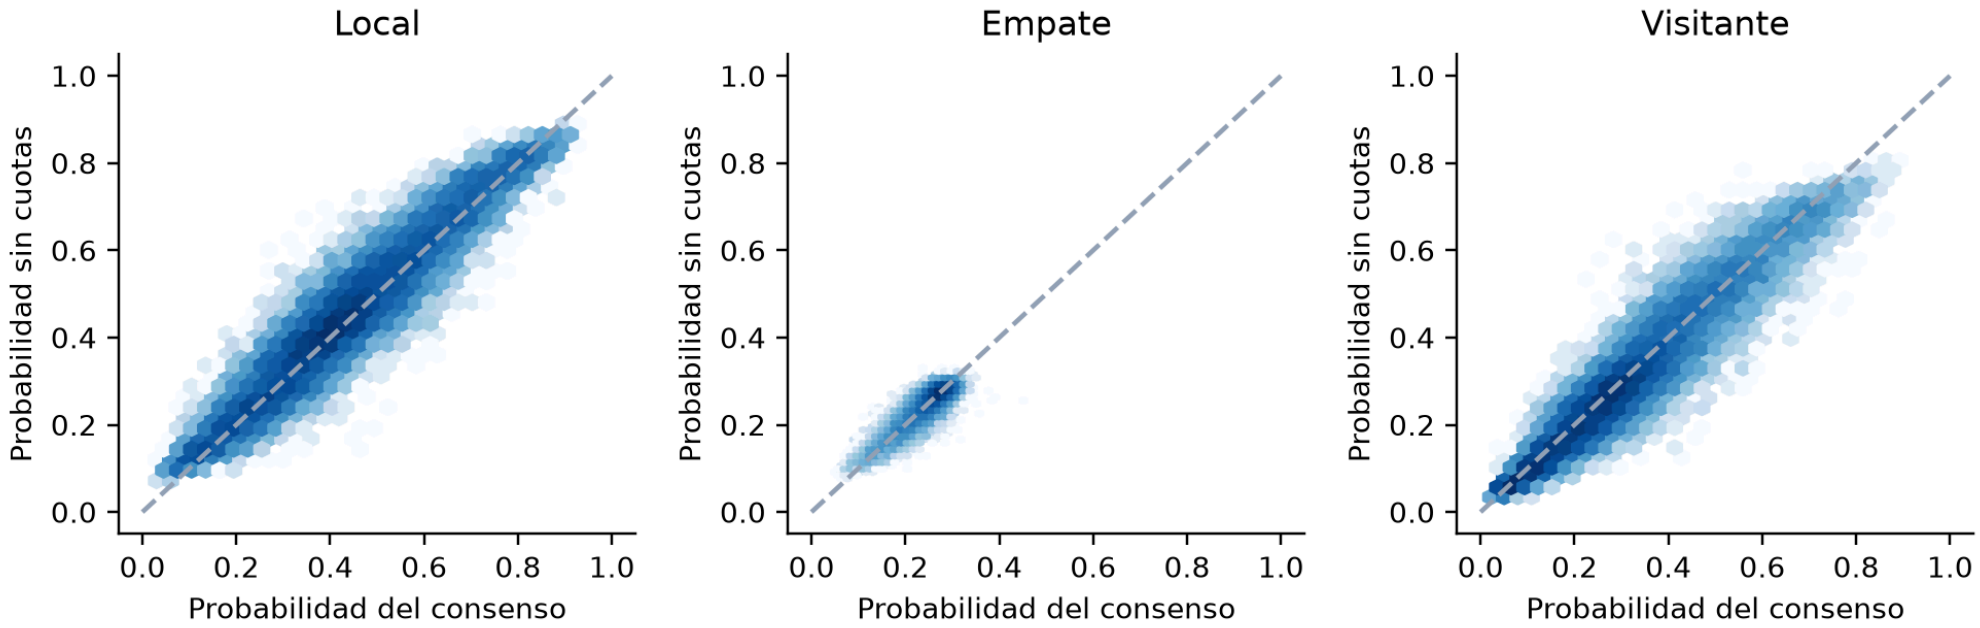


Historia → plantilla → habilidades. Los ratings se cruzan por fecha y pueden proceder de una versión anterior.

Comparación bajo LR; cada C se elige con temporadas anteriores

Sin cuotas: un precio propio que podemos contrastar

Elegido: Promedio · LL validación 0.9776



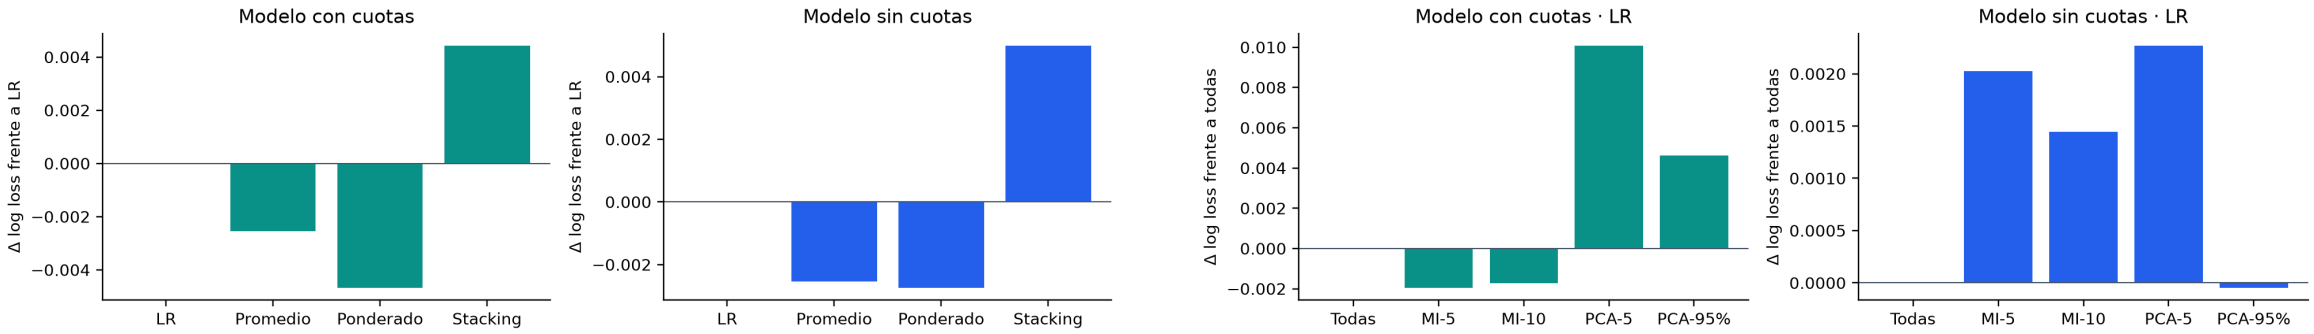
Correlación logit con consenso 0.948; favorito coincidente 90.9 %. Cuotas justas = 1/P, sin margen.

Comparación final con el mismo periodo

Modelo / referencia	Log loss	AUC	ECE masa
Consenso directo	0.9668	0.6838	0.0221
Pinnacle fiable / respaldo	0.9663	0.6837	0.0208
Modelo con cuotas	**0.9650**	**0.6834**	**0.0162**
Modelo sin cuotas	**0.9793**	**0.6678**	**0.0121**

La comparación utiliza los mismos 5.999 partidos. Los contrastes pareados y sus intervalos están en el informe.

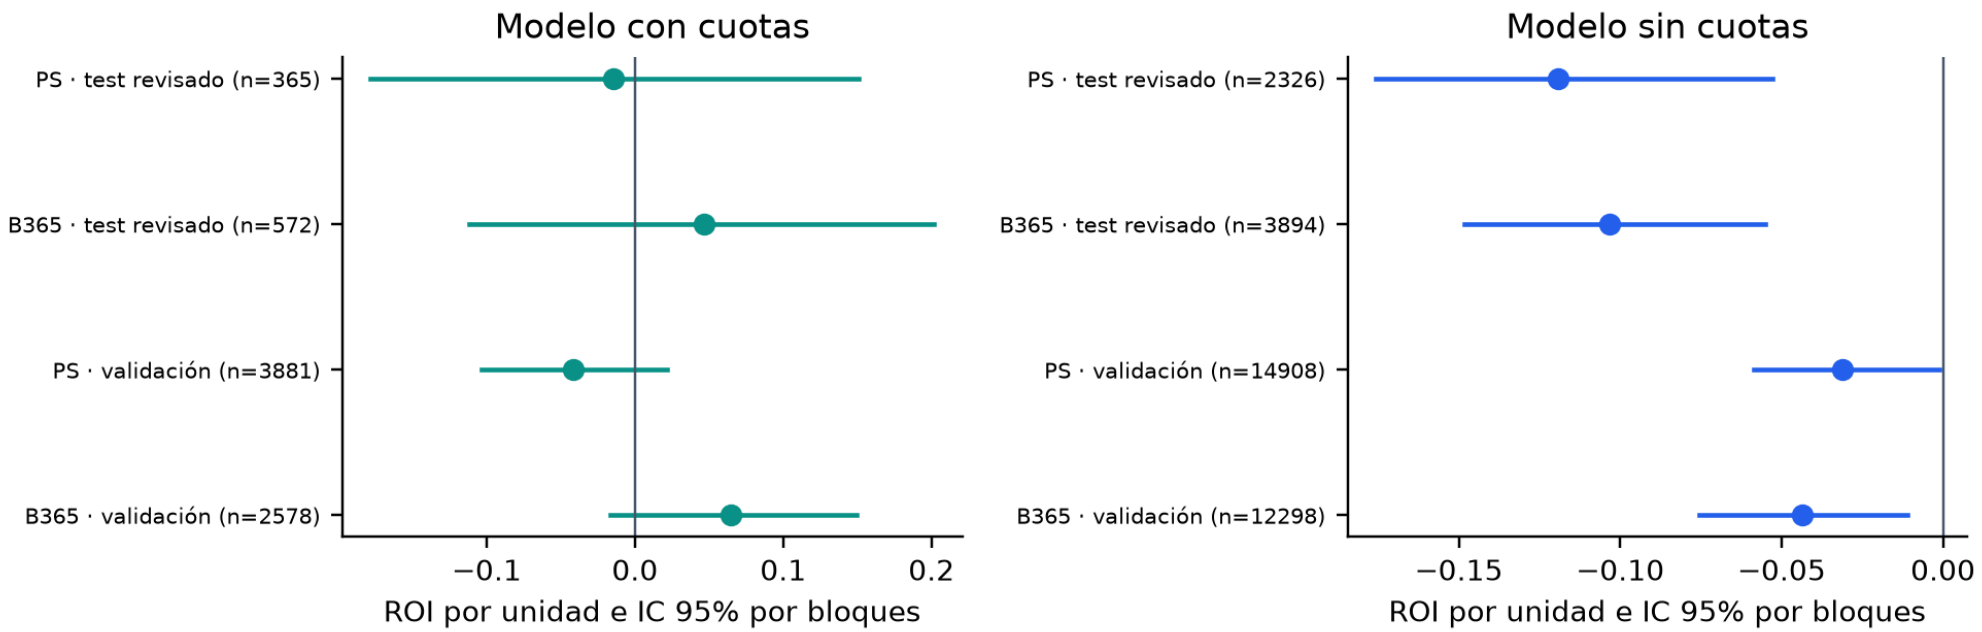
PCA, ensembles y respuesta al profesor



El ensemble mejora sin cuotas; con cuotas se prefiere LR. También probamos pesos y resampling 50/50; esas variantes son guiadas por mercado.

Predicciones previas inicializan el primer ensemble; no se cambia de método en ese fold

Rentabilidad y límites de los datos



τ=0,02 fijo; una unidad por apuesta. Pinnacle se excluye desde el 23/07/2025. Los precios no tienen sincronización exacta entre casas.

Dos contribuciones, una comparación honesta

Con cuotas

Log loss revisado: **0.9650**
Medimos el aporte respecto al precio directo.

Sin cuotas

Log loss revisado: **0.9793**
Construimos probabilidades con información deportiva.

Limitaciones: ratings antiguos, alineaciones del juego, solo ligas y test observado. La siguiente prueba debe usar partidos futuros.

github.com/jcarlos-t/MLProject