PROYECTO FINAL DE MACHINE LEARNING

¿Puede un modelo predecir el fútbol mejor que las casas de apuestas?

Probabilidades para local, empate y visitante en nueve ligas europeas, con y sin mirar las cuotas.

36.119
partidos modelados

9
ligas europeas

12
temporadas, 2014/15–2025/26

José Luis Alva · Juan Carlos Ticlia · Elmer Villegas · Joseph Cose

EL PROBLEMA

No queremos adivinar un ganador: queremos probabilidades

Local vs **Visitante**



Enfoque 1

Con cuotas

El mercado ya da un precio. **¿El aprendizaje automático lo puede mejorar?**

Enfoque 2

Sin cuotas

Solo datos deportivos. **¿Qué tan cerca llegamos del mercado?**

Ejemplo ilustrativo · las probabilidades suman 100 %

CÓMO EVALUAMOS

Medimos la calidad de la probabilidad, no solo los aciertos

Log loss = −ln(probabilidad dada a lo que ocurrió)

Prob. al resultado real	Penalización
60 %	0,51
25 %	1,39
5 % (confiado y equivocado)	**3,00**

Menor es mejor. Premia ser honesto con la incertidumbre.

AUC
¿Ordena bien qué resultado es más probable?

ECE · calibración
Si decimos 30 %, ¿ocurre ~30 % de las veces?

Accuracy
Acierto del resultado más probable. Complementaria: casi nunca elige empate.

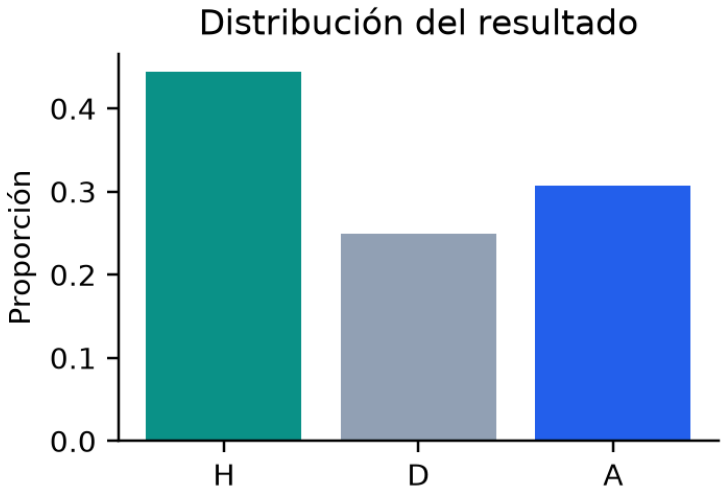
DATOS

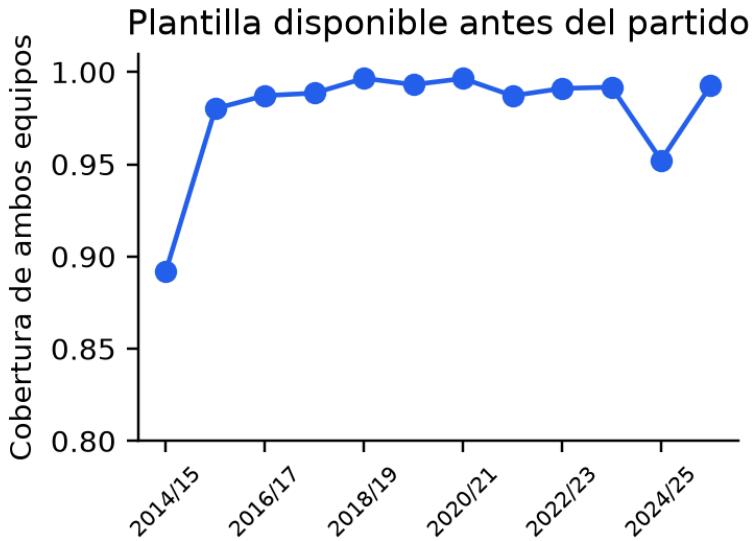
Tres fuentes, alineadas por fecha para no ver el futuro

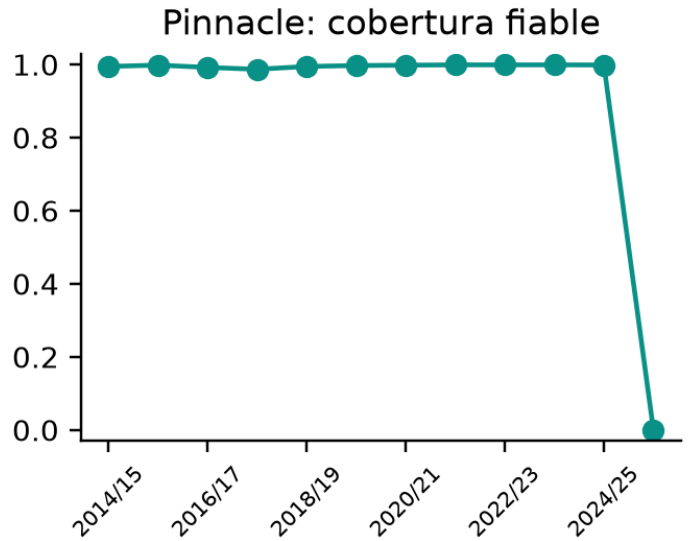
Resultados
historia de cada equipo (Elo, forma, goles)

Cuotas
Bet365, Pinnacle y otras casas

Ratings FIFA/FC
plantilla y habilidades del once







Cada partido usa solo el rating publicado **antes** de su fecha. Pinnacle se excluye desde el 23/07/2025 por aviso de la fuente.

36.150 partidos originales · 31 sin cuotas · temporada 2013/14 solo como calentamiento

PROTOCOLO EXPERIMENTAL

Entrenamos con el pasado y evaluamos en temporadas que el modelo no vio

2014/15–2017/18
historia y primer ajuste

2018/19–2023/24
6 temporadas de validación: entrenar con todo lo anterior

2024/25–25/26
test · 5.999

Variables cronológicas → **Imputar, escalar y seleccionar dentro de cada entrenamiento** → **Elegir modelo por log loss en validación** → **Congelar y predecir el test**

Mismos partidos, mismas métricas y mismo protocolo para ambos enfoques.

Ventana expansiva · ajuste interno con las dos temporadas anteriores

Una cuota ya es una probabilidad (con margen de la casa)

Enfoque 1 · con cuotas

	Cuota	1/cuota	Probabilidad
Local	2,10	0,476	**45,4 %**
Empate	3,40	0,294	**28,1 %**
Visitante	3,60	0,278	**26,5 %**
Suma		1,048	100 %

El 4,8 % sobrante es el margen de la casa: se normaliza.

Referencias directas
Consenso de casas y Pinnacle, sin aprendizaje.

Modelos
LR, HGB, XGBoost, RF, MLP y SVM sobre el precio, con o sin fundamentos deportivos.

Elegido: LR referencia
Regresión logística sobre dos variables del precio: **recalibra** la cuota.

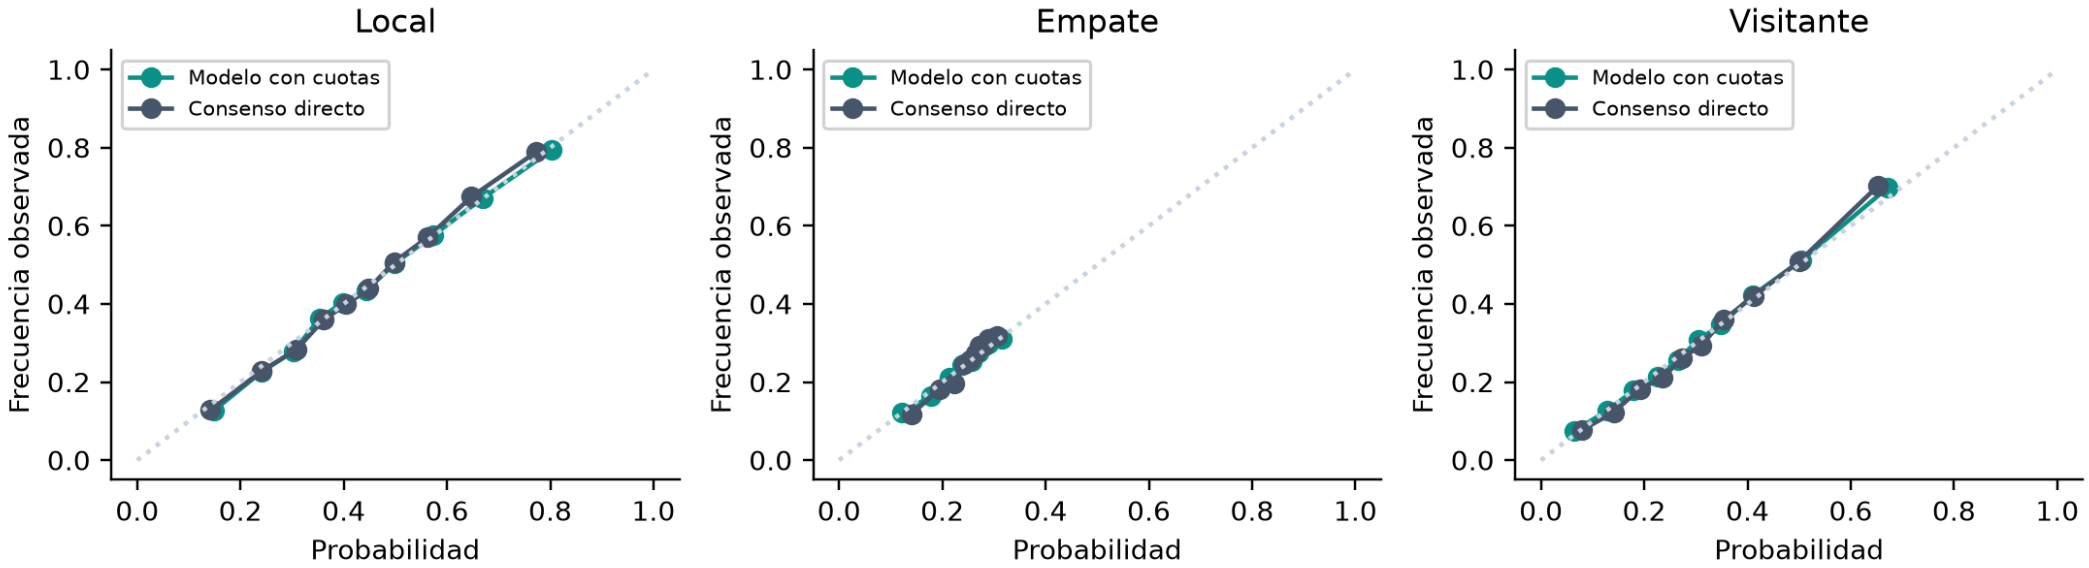
ENFOQUE 1 · CON CUOTAS

Con cuotas: el modelo afina el precio del mercado, no lo reemplaza

0.9652
log loss del modelo (validación)

0.9664
consenso de casas

5 de 6
temporadas en que mejora al consenso



Mejora sobre todo la **calibración** (ECE 0.0085 vs. 0.0143); el AUC es prácticamente igual: el mercado ya ordena muy bien.

Curvas por clase en validación · diez grupos de igual masa

Sin cuotas: construimos un precio propio con datos deportivos

Enfoque 2 · sin cuotas

Historia

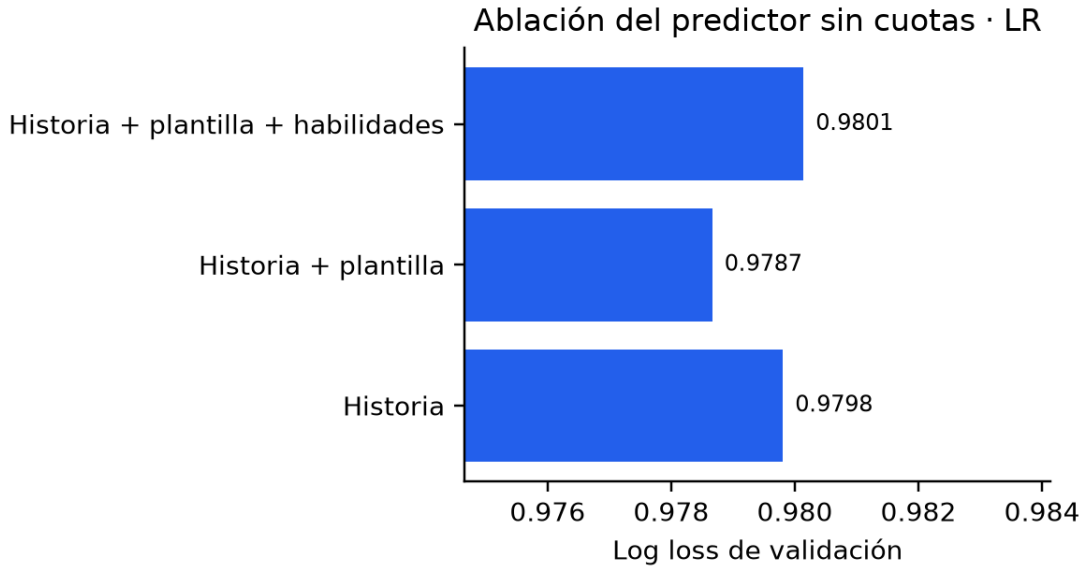
Elo, forma de 5 partidos, medias de goles y puntos, descanso.

Plantilla

Rating medio del once según el juego FIFA/FC.

Habilidades

Ataque, pase, defensa y portero de los mejores jugadores.



La plantilla reduce el log loss frente a la historia sola; las habilidades individuales no añaden más bajo LR (P2).

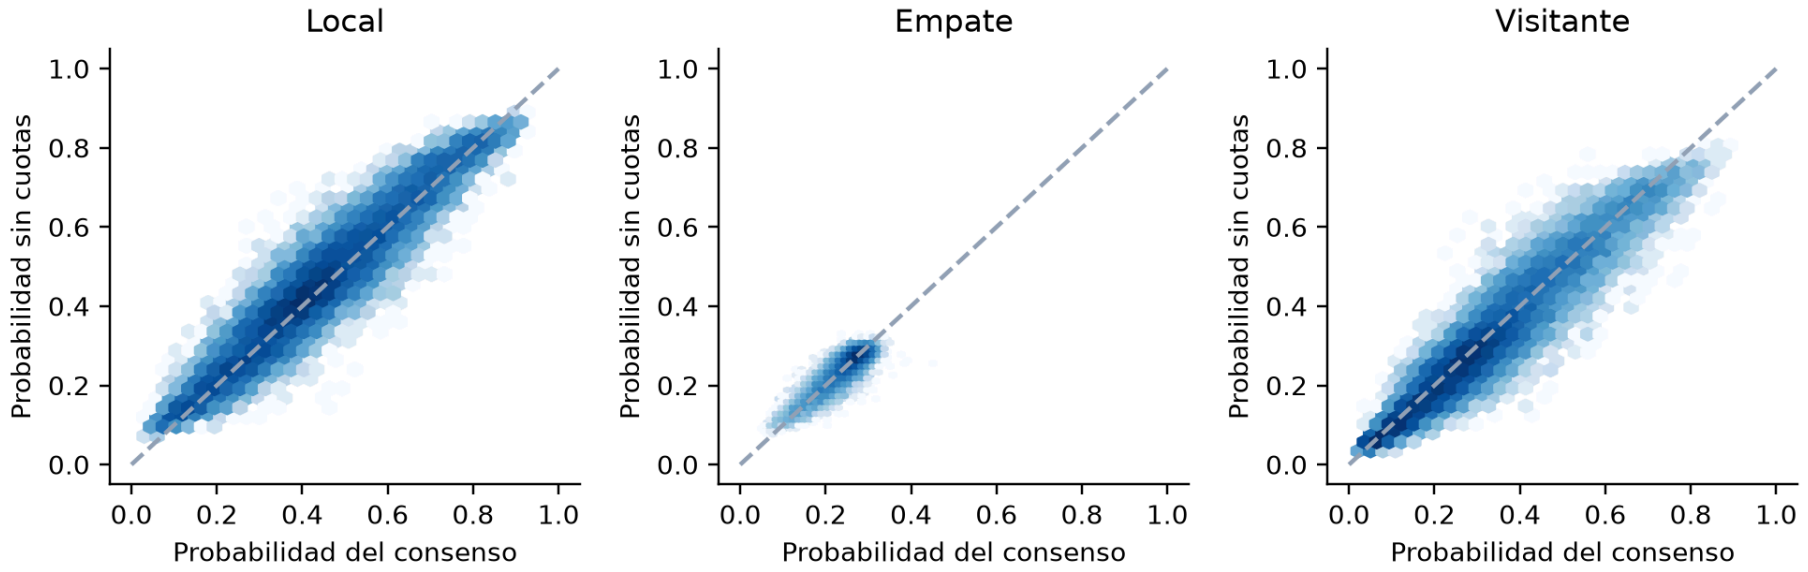
ENFOQUE 2 · SIN CUOTAS

Sin cuotas logramos el 89 % de la mejora que consigue el mercado

89 %
de la ganancia del mercado sobre el prior

0.95
correlación con el consenso

91 %
mismo favorito que las casas



Elegido: **Promedio** de modelos · log loss 0.9776 en validación, frente a 1.0720 del prior y 0.9664 del mercado. Sus cuotas justas son 1/P.

RESULTADO FINAL

En el test se mantiene el mismo orden que en validación

Modelo / referencia	Log loss ↓	AUC ↑	Accuracy
Prior	1.0750	0.500	43.3 %
Consenso directo	0.9668	0.683	53.8 %
Pinnacle fiable / respaldo	0.9663	0.683	53.8 %
Modelo con cuotas	**0.9650**	**0.683**	**53.9 %**
Modelo sin cuotas	**0.9793**	**0.667**	**52.4 %**

Con cuotas
0.9650 frente a 0.9668 del consenso: −0.18 % de log loss, con IC 95 % que excluye cero.

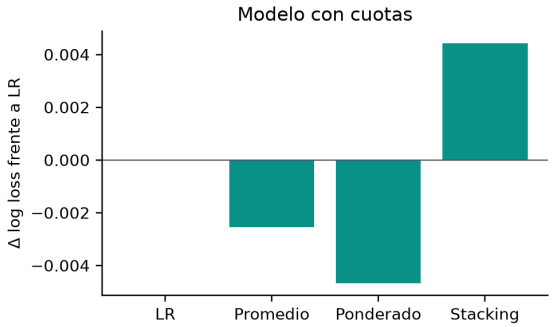
Sin cuotas
0.9793: mucho mejor que el prior (1.0750), aún por detrás del mercado.

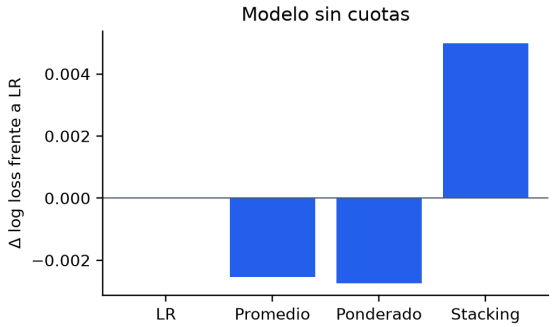
Accuracy
Con cuotas, casi igual al consenso (53,9 % vs. 53,8 %): la diferencia está en la calidad de la probabilidad.

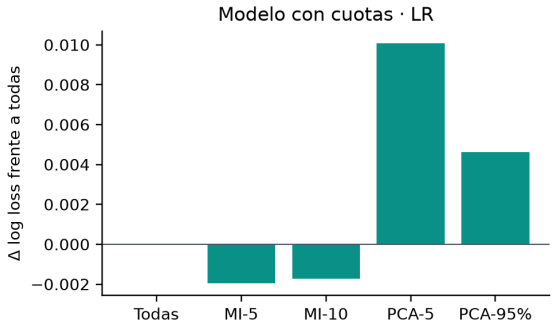
5.999 partidos de 2024/25–2025/26 · modelos congelados con train/val

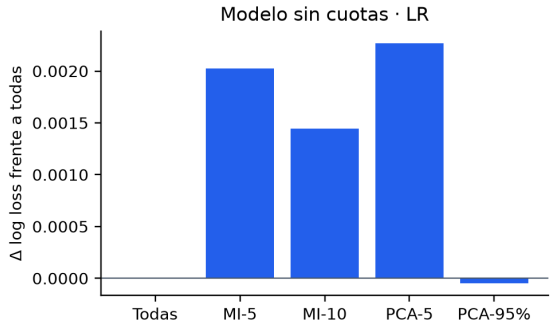
EXPERIMENTOS ADICIONALES

Más complejidad no siempre ayuda: probamos y medimos









Ensembles
Con cuotas ninguno supera a la LR de solo precio; sin cuotas el promedio sí ayuda y es el elegido.

MI / PCA (P3)
Con cuotas MI ayuda frente a usar todas, pero no al precio solo; sin cuotas reducir empeora.

Pesos y remuestreo 50/50
Más peso a los partidos donde falla el favorito empeora el log loss.

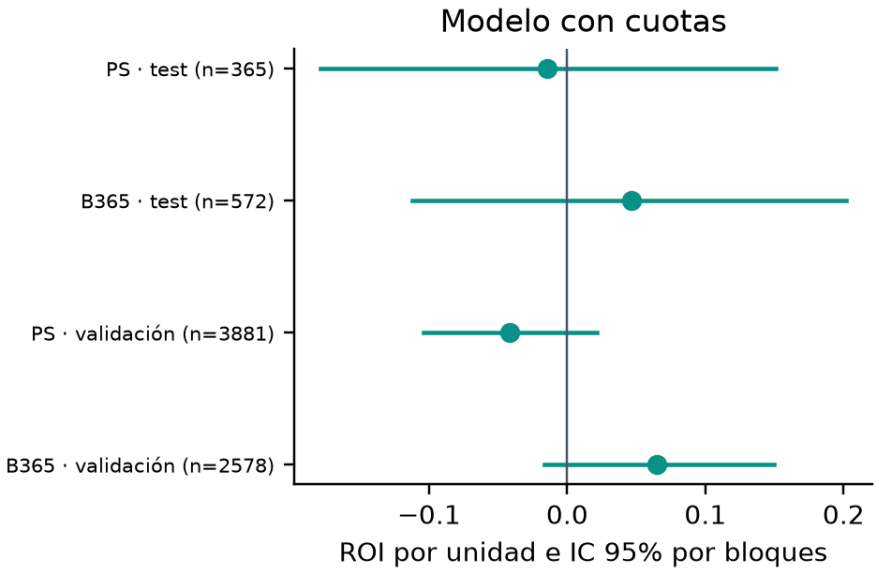
Barras = diferencia de log loss frente a la LR con todas las variables (negativo es mejor) · validación

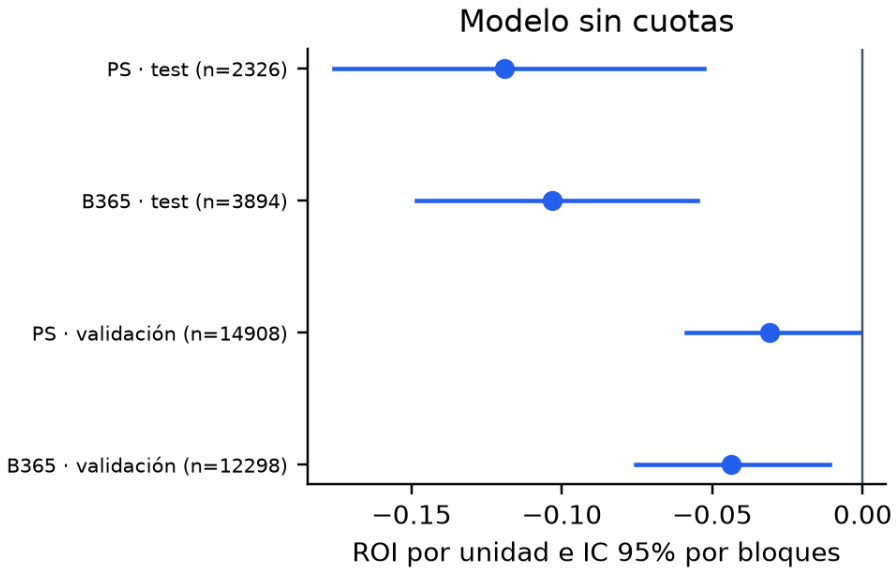
RENTABILIDAD

Predecir mejor no garantiza ganar dinero

+4.7 %
ROI con cuotas en test, Bet365 (572 apuestas)

-10.3 %
ROI sin cuotas en test, Bet365 (3894 apuestas)





Regla fija: apostar 1 unidad si el valor esperado supera 2 %. El intervalo con cuotas [-11 %, +20 %] incluye pérdidas (P4).

PARA LLEVARSE

Conclusiones

1. El mercado es una referencia muy difícil: con cuotas, una LR simple solo lo **recalibra** y gana por poco pero de forma consistente.

2. Sin cuotas, historia + plantilla + habilidades reproducen el **89 %** de la ganancia del mercado.

3. Log loss y calibración importan más que el accuracy para tomar decisiones con probabilidades.

4. Ensembles, PCA y pesos se evaluaron con el mismo rigor: el promedio ayuda sin cuotas; con cuotas gana la LR simple.

Límites: ratings del juego y no alineaciones reales, solo partidos de liga y cuotas sin hora exacta de captura.

github.com/jcarlos-t/MLProject